

Deskriptive Statistik

Emilian Hahlbrock

2026-06-01

Lizenz und Hinweise

Autor: Emilian Hahlbrock

Repository: <https://github.com/milisaur/statistik-m2>

Lizenz: Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0)

Diese Unterlagen dürfen geteilt und bearbeitet werden, sofern eine Namensnennung erfolgt, keine kommerzielle Nutzung stattfindet und abgeleitete Werke unter derselben Lizenz veröffentlicht werden.

Diese Version verwendet ausschließlich öffentliche oder synthetisch erzeugte Beispieldaten.

Diese Unterlagen sind privat erstellt und keine offiziellen Materialien der FernUniversität in Hagen.

Table of contents

1	Deskriptive Statistik	8
1.1	Öffentliche Beispieldaten für alle Beispiele	8
2	1. Ziel der Statistik	8
2.1	Deskriptive Statistik	8
2.2	Inferenzstatistik	9
3	2. Grundbegriffe	9
3.1	Merkmal / Variable	9
3.2	Ausprägung / Wert	9
3.3	Beobachtung / Fall	9
3.4	Stichprobe	10
3.5	Population / Grundgesamtheit	10
4	3. Datenmatrix	10
4.1	Indizes	10
5	4. Häufigkeiten	10
5.1	Absolute Häufigkeit	10
5.2	Relative Häufigkeit	11
5.3	Prozentuale Häufigkeit	11
5.4	Kumulierte Häufigkeit	12
6	5. Häufigkeitstabellen und Grafiken	13
6.1	Urliste	13
6.2	Tabellen kombinieren	13
6.3	Häufigkeitstabelle	14
6.4	Säulendiagramm	14
6.5	Balkendiagramm	14
6.6	Histogramm	14
6.7	Kreisdiagramm	15
7	6. Klasseneinteilung bei metrischen Daten	15
7.1	Klassenbreite	15
7.2	Klassenmitte	15
8	7. Skalenniveau	15
8.1	Nominalskala	16
8.2	Ordinalskala	16
8.2.1	1. Singuläre Daten	16
8.2.2	2. Kategoriale ordinale Daten	16
8.3	Intervallskala	17

8.4	Ratio-/ Verhältnisskala	17
8.5	Absolutskala	17
8.6	Metrisch umfasst:	17
9	8. Äquivalenzrelation	17
9.1	8.1 Reflexivität	18
9.1.1	Beispiel	18
9.2	8.2 Symmetrie	18
9.2.1	Beispiel	18
9.3	8.3 Transitivität	18
9.3.1	Beispiel	19
9.4	8.4 Äquivalenzklassen	19
10	9. Lagemaße	19
10.1	9.1 Modalwert	19
10.2	9.2 Median	20
10.2.1	Median bei ungeradem n	20
10.2.2	Median bei geradem n	20
10.3	9.3 Arithmetisches Mittel	20
11	10. Erweiterte Mittelwerte	21
11.1	10.1 Gewichtetes Mittel	21
11.2	10.2 Geometrisches Mittel	21
11.3	10.3 Getrimmtes Mittel	22
11.4	10.4 Winsorisiertes Mittel	23
12	11. Streuungsmaße	23
12.1	11.1 Relativer Informationsgehalt (nominal)	23
12.1.1	Interpretation	24
12.2	11.2 Minimum und Maximum	24
12.3	11.3 Spannweite	25
12.4	11.4 Interquartilsabstand	25
12.5	11.5 Varianz	25
12.5.1	Varianz der Grundgesamtheit	26
12.5.2	Stichprobenvarianz	26
12.6	11.6 Standardabweichung	26
12.7	11.7 Mittlere absolute Abweichung vom Mittelwert	26
12.8	11.8 Median Absolute Deviation (MAD)	27
12.9	11.9 Variationskoeffizient	27
13	12. Quantile, Perzentile und Prozentrang	28
13.1	Achtung bei der Berechnung	28
13.2	12.1 Quantile	28

13.3	12.2	Quartile	28
13.4	12.3	Dezile	29
13.5	12.4	Perzentile	29
13.6	12.5	Prozentrang	29
13.7	12.6	Rangbindungen	30
14	13.	Verteilungen	30
14.1	13.1	Symmetrische Verteilung	30
14.2	13.2	Rechtsschiefe Verteilung	31
14.3	13.3	Linksschiefe Verteilung	31
	14.3.1	Merksatz	32
14.4	13.4	Kurtosis	32
14.5	13.5	Exzess	32
	14.5.1	Interpretation	32
14.6		Gesamtübersicht	33
15	14.	Z-Transformation	33
15.1	14.1	Bedeutung	33
15.2		Eigenschaften	33
15.3	14.2	Interpretation	33
16	15.	Bedingte Kennwerte	34
16.1	15.1	Zweck	34
16.2	15.2	Darstellung	34
16.3		Wichtig	34
16.4		Übersicht Kennwerte je Gruppe	35
16.5		Spezifischer Kennwert nach Gruppe	35
16.6		Subsetting	35
	16.6.1	Werte einer Gruppe auswählen	35
	16.6.2	Zeilen aus Dataframe filtern	36
17	16.	Kovarianz	36
17.1		Interpretation	37
17.2		Problem	37
18	17.	Zusammenhangsmaße nach Skalenniveau	37
19	18.	Korrelation Kausalität	37
19.1		Drei mögliche Erklärungen	38
19.2		Für Kausalität braucht man mindestens	38
20	19.	Korrelationsmatrix	38

21	20. Pearson-Korrelation	38
21.1	Wertebereich	39
21.2	Richtung	39
21.3	Stärke	39
21.4	Cohen-Konvention	40
21.5	Korrelation in R	40
21.5.1	Bedeutung von <code>use = "pairwise.complete.obs"</code>	40
22	21. Voraussetzungen und Probleme bei Pearson-r	41
22.1	Voraussetzungen	41
22.2	Probleme	41
22.2.1	Ausreißer	41
22.2.2	Varianzeinschränkung	41
22.2.3	Heterogene Gruppen	41
23	22. Partialkorrelation	41
23.1	Interpretation	42
24	23. Kreuztabelle	42
24.1	Zeilenprozente	42
24.2	Spaltenprozente	42
24.3	Gesamtprozente	43
24.4	absolute Kreuztabelle	43
24.5	relative Anteile	43
24.6	Ausführliche Kreuztabelle mit <code>gmodels</code>	43
25	24. Dichotome Variablen und Phi-Koeffizient	44
25.1	Phi-Koeffizient	44
25.2	Über Kontingenztafel	44
25.3	in R manuell	44
26	25. Ordinale Zusammenhangsmaße / Rangkorrelation	45
26.1	Spearman-Rho	45
26.2	Kendall-Tau	45
27	26. Regression	46
27.1	Begriffe	46
27.2	Regressionsgerade	46
27.3	lineares Regressionsmodell	46
27.4	Modellzusammenfassung	47
27.5	Regressionskoeffizienten gezielt ausgeben	48
27.6	Interpretation	48
27.6.1	Steigung b / Regressionsgewicht	48
27.6.2	Achsenabschnitt a / Intercept	49

27.7	Beta-Gewichte	49
27.7.1	Interpretation	49
28	27. Vorhersagefehler und Kleinste Quadrate	50
28.1	Vorhersagewert	50
28.2	Fehler / Residuum	50
28.3	Beobachtete vs. vorhergesagte Werte	51
28.4	Residuenplot	51
28.5	Kleinste-Quadrate-Prinzip	52
29	28. Zusammenhang zwischen Regression und Korrelation	52
29.1	Interpretation	52
30	29. Z-standardisierte Regression	52
31	30. Determinationskoeffizient (R^2)	53
31.1	Bedeutung	53
32	31. Erklärte Varianz und Fehlervarianz / Residualvarianz	54
32.1	Zerlegung	54
33	32. Standardfehler der Schätzung	54
33.1	Bedeutung	54
34	33. Multiple Regression	55
34.1	b-Gewichte	55
34.2	standardisierte Beta-Gewichte	56
34.3	Adjustiertes R^2	56
34.4	Redundanz / Multikollinearität	56
34.5	Suppressoreffekt	56
34.6	Multikollinearität prüfen	56
35	34. Regression vs. Korrelation	57
36	35. Typische Interpretationsformulierungen	57
36.1	Korrelation	57
36.2	Korrelation mit r	57
36.3	Determinationskoeffizient	58
36.4	Regression	58
36.5	Multiple Regression	58

1 Deskriptive Statistik

Version: v1.0 Letzte Aktualisierung: 01.06.2026

[1] "2026-06-10"

1.1 Öffentliche Beispieldaten für alle Beispiele

Die folgenden Beispiele verwenden keine Uni-Datensätze, sondern einen reproduzierbaren synthetischen Datensatz. Dadurch kann der Lernzettel öffentlich geteilt werden.

```
set.seed(123)

demo <- data.frame(
  gruppe = rep(c("Kontrolle", "Intervention"), each = 40),
  score = c(
    rnorm(40, mean = 100, sd = 15),
    rnorm(40, mean = 108, sd = 15)
  )
)

head(demo)
```

	gruppe	score
1	Kontrolle	91.59287
2	Kontrolle	96.54734
3	Kontrolle	123.38062
4	Kontrolle	101.05763
5	Kontrolle	101.93932
6	Kontrolle	125.72597

2 1. Ziel der Statistik

2.1 Deskriptive Statistik

Die deskriptive Statistik beschreibt, ordnet und verdichtet vorhandene Daten.

Typische Fragen:

- Wie sieht die Verteilung aus?

- Wo liegt die Mitte?
- Wie stark streuen die Werte?
- Gibt es Zusammenhänge zwischen Variablen?

2.2 Inferenzstatistik

Die Inferenzstatistik zieht Schlüsse von einer Stichprobe auf eine Population.

In diesem Lernzettel geht es hauptsächlich um deskriptive Statistik.

3 2. Grundbegriffe

3.1 Merkmal / Variable

Eine Variable ist eine Eigenschaft, die gemessen oder erhoben wird.

Beispiele:

- Geschlecht
- Alter
- Körpergröße
- Einkommen
- Schulnote

3.2 Ausprägung / Wert

Eine Ausprägung ist ein konkreter Wert einer Variable.

Beispiel:

- Variable: Alter
- Ausprägung: 23

3.3 Beobachtung / Fall

Ein Fall ist eine Untersuchungseinheit.

Beispiele:

- eine Person
- ein Haushalt
- ein Unternehmen

3.4 Stichprobe

Die Stichprobe ist die tatsächlich untersuchte Teilmenge.

3.5 Population / Grundgesamtheit

Die Population ist die gesamte interessierende Menge.

4 3. Datenmatrix

Daten werden häufig in einer Matrix dargestellt:

- n = Anzahl der Fälle (Merkmalsträger)
- p = Anzahl der Variablen (Merkmale)

Die Matrix hat die Form:

$n \times p$

- Zeilen: Fälle
- Spalten: Variablen
- Zellen: Messwerte

4.1 Indizes

Zur Kennzeichnung werden Indizes verwendet:

- x_{mi} : Messwert von Person m bei Merkmal i
- m : Merkmalsträger (1 bis n)
- i : Merkmal (1 bis p)
- j : Merkmalsausprägung

5 4. Häufigkeiten

5.1 Absolute Häufigkeit

$$n_j$$

Die absolute Häufigkeit gibt an, wie oft eine Ausprägung vorkommt.

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
table(daten)
```

```
daten
 3  7 12 18 25 30 45 50 60 80 100
1  1  1  1  1  1  1  1  1  1  1
```

5.2 Relative Häufigkeit

$$h_j = \frac{n_j}{n}$$

Die relative Häufigkeit gibt den Anteil einer Ausprägung an der Gesamtzahl der Beobachtungen an.

```
daten <- c(1.3, 2.0, 1.7, 3.3, 2.3)
prop.table(table(daten))
```

```
daten
1.3 1.7  2 2.3 3.3
0.2 0.2 0.2 0.2 0.2
```

5.3 Prozentuale Häufigkeit

$$h_j \cdot 100$$

```
daten <- c(1.3, 2.0, 1.7, 3.3, 2.3)
100 * prop.table(table(daten))
```

```
daten
1.3 1.7  2 2.3 3.3
20  20 20  20 20
```

→ runden

```
x <- 0.457438723874
round(x, 2)
```

```
[1] 0.46
```

5.4 Kumulierte Häufigkeit

Kumulierte Häufigkeiten werden aufaddiert.

Sie beantworten die Frage:

Wie viele bzw. wie viel Prozent liegen bis einschließlich zu diesem Wert?

Bei ordinalen oder metrischen Variablen sinnvoll, bei nominalen Variablen meistens nicht sinnvoll.

```
daten <- c(1.3, 2.0, 1.7, 3.3, 2.3)
cumsum(table(daten))
```

1.3	1.7	2	2.3	3.3
1	2	3	4	5

→ kumulierte absolute Häufigkeiten

```
daten <- c(1.3, 2.0, 1.7, 3.3, 2.3)
cumsum(prop.table(table(daten)))
```

1.3	1.7	2	2.3	3.3
0.2	0.4	0.6	0.8	1.0

→ kumulierte relative Häufigkeiten

```
daten <- c(1.3, 2.0, 1.7, 3.3, 2.3)
cumsum(100 * prop.table(table(daten)))
```

1.3	1.7	2	2.3	3.3
20	40	60	80	100

→ kumulierte Prozentwerte

6 5. Häufigkeitstabellen und Grafiken

6.1 Urliste

Eine Urliste ist eine ungeordnete Liste aller Messwerte.

Beispiel: 3, 1, 4, 2, 2, 5, 1

Eigenschaften:

- enthält alle Rohdaten
- noch nicht sortiert
- Ausgangspunkt für Häufigkeitstabellen

6.2 Tabellen kombinieren

```
# Zeilen zusammenfügen mit `rbind()`  
a <- c(1, 2, 3)  
b <- c(4, 5, 6)  
  
rbind(a, b)
```

	[,1]	[,2]	[,3]
a	1	2	3
b	4	5	6

→ fügt Vektoren als Zeilen zusammen

```
# Spalten zusammenfügen mit `cbind()`  
a <- c(1, 2, 3)  
b <- c(4, 5, 6)  
  
cbind(a, b)
```

	a	b
[1,]	1	4
[2,]	2	5
[3,]	3	6

→ fügt Vektoren als Spalten zusammen

6.3 Häufigkeitstabelle

Eine Häufigkeitstabelle enthält typischerweise:

Wert	absolute Häufigkeit	relative Häufigkeit	kumulierte Häufigkeit
x_1	n_1	h_1	H_1
x_2	n_2	h_2	H_2

6.4 Säulendiagramm

- Kategorien auf x-Achse
- Häufigkeiten auf y-Achse

Geeignet für:

- nominale Variablen
- ordinale Variablen
- diskrete Werte

6.5 Balkendiagramm

- gedrehtes Säulendiagramm
- bessere Lesbarkeit bei vielen Kategorien

6.6 Histogramm

Geeignet für:

- metrische Variablen
- gruppierte stetige Daten

Wichtig:

Ein Histogramm zeigt Klassenintervalle, nicht einfach einzelne Kategorien.

6.7 Kreisdiagramm

Kann Anteile darstellen, ist aber oft weniger präzise als ein Balkendiagramm.

- Winkel entspricht relativer Häufigkeit
- größte Kategorie beginnt bei „12 Uhr“
- Reihenfolge im Uhrzeigersinn
- schlecht für Vergleiche

7 6. Klasseneinteilung bei metrischen Daten

Bei vielen metrischen Werten werden Daten oft in Klassen eingeteilt.

Beispiel:

Klasse	Häufigkeit
0–10	4
10–20	9
20–30	6

7.1 Klassenbreite

Klassenbreite = obere Klassengrenze – untere Klassengrenze

7.2 Klassenmitte

$$\text{Klassenmitte} = \frac{\text{untere Grenze} + \text{obere Grenze}}{2}$$

Die Klassenmitte wird oft als Stellvertreterwert für Berechnungen genutzt.

8 7. Skalenniveau

Skalenniveau	Bedeutung	Beispiele	Sinnvolle Kennwerte
nominal	Kategorien ohne Rangordnung	Geschlecht, Studienfach	Modus, Häufigkeiten

Skalenniveau	Bedeutung	Beispiele	Sinnvolle Kennwerte
ordinal	Rangordnung, Abstände nicht interpretierbar	Schulnoten, Rangplätze	Median, Quartile, Modus
intervallskaliert	gleiche Abstände, kein natürlicher Nullpunkt	Temperatur in °C	Mittelwert, Varianz, Standardabweichung
verhältnisskaliert	gleiche Abstände und natürlicher Nullpunkt	Größe, Gewicht, Alter	alle metrischen Kennwerte

8.1 Nominalskala

- Namen / Kategorien
- Unterscheidung zwischen gleich und ungleich, keine Sortierung, kein “besser” und “schlechter”
- z.B. Geschlecht, Augenfarbe, Wohnort

8.2 Ordinalskala

- Rangordnung
- Unterscheidet “Größer-Kleiner”-Relation ($A > B$)
- z.B. Tabellenplätze beim Sport, Schulnoten, Windstärken, Bildungsabschlüsse
- die Abstände zwischen den Rängen sind nicht interpretierbar!

Es gibt zwei Arten:

8.2.1 1. Singuläre Daten

- jeder Rang kommt nur einmal vor
- Median, Modus oft nicht sinnvoll

8.2.2 2. Kategoriale ordinale Daten

- Werte werden zu Klassen zusammengefasst
- Median und Modus sinnvoll

8.3 Intervallskala

- gleiche Abstände: Abstände / Intervalle zwischen den Werten gleich groß und interpretierbar
- z.B. Temperatur in °C, IQ-Werte, Kalenderjahre
- es gibt keinen natürlichen Nullpunkt, 20°C ist nicht doppelt so warm wie 10°C

8.4 Ratio-/ Verhältnisskala

- zusätzlich natürlicher Nullpunkt
- z.B. Einkommen, Alter in Jahren, Reaktionszeit in ms
- Vorteil: Verhältnisbindung, A ist doppelt so alt wie B.

8.5 Absolutskala

- auch Maßeinheit natürlich vorgeben und unveränderlich
- zumeist Häufigkeiten / Anzahl
- z.B. Anzahl der Kinder in einer Familie, Anzahl der Fehler im Test

8.6 Metrisch umfasst:

- intervallskaliert
- verhältnisskaliert
- absolutskaliert

9 8. Äquivalenzrelation

Eine Relation R heißt Äquivalenzrelation, wenn sie folgende drei Eigenschaften erfüllt:

1. reflexiv
2. symmetrisch
3. transitiv

9.1 8.1 Reflexivität

$$a \sim a$$

Jedes Element steht mit sich selbst in Relation.

9.1.1 Beispiel

„hat dieselbe Haarfarbe wie“

→ Jede Person hat dieselbe Haarfarbe wie sie selbst.

9.2 8.2 Symmetrie

Wenn:

$$a \sim b$$

dann auch:

$$b \sim a$$

9.2.1 Beispiel

„ist gleich alt wie“

Wenn A gleich alt wie B ist, dann auch B gleich alt wie A.

9.3 8.3 Transitivität

Wenn:

$$a \sim b$$

und

$$b \sim c$$

dann gilt:

$$a \sim c$$

9.3.1 Beispiel

„hat dieselbe Augenfarbe wie“

Wenn A dieselbe Augenfarbe wie B hat und B dieselbe Augenfarbe wie C, dann hat auch A dieselbe Augenfarbe wie C.

9.4 8.4 Äquivalenzklassen

Äquivalenzrelationen teilen Elemente in Gruppen gleicher Elemente ein.

Diese Gruppen heißen:

Äquivalenzklassen

10 9. Lagemaße

Lagemaße beschreiben die Mitte oder typische Lage einer Verteilung.

10.1 9.1 Modalwert

Der Modalwert ist der häufigste Wert.

Eigenschaften:

- ab nominalem Skalenniveau möglich
- kann mehrere Werte haben
- bei allen Variablentypen nutzbar

```
daten <- c(2, 10, 4, 10, 4, 4, 5)
as.numeric(names(table(daten))[which.max(table(daten))])
```

```
[1] 4
```

10.2 9.2 Median

Der Median ist der Wert, der die geordneten Daten in zwei gleich große Hälften teilt.

Er ist das 50%-Quantil.

Eigenschaften:

- ab ordinalem Skalenniveau sinnvoll
- robust gegenüber Ausreißern

```
daten <- c(2, 10, 4, 10, 4, 4, 5)
median(daten, na.rm = TRUE)
```

```
[1] 4
```

10.2.1 Median bei ungeradem n

$$Md = x_{\frac{n+1}{2}}$$

10.2.2 Median bei geradem n

$$Md = \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}$$

Achtung:

Bei ordinalen Daten wird häufig nicht sinnvoll gemittelt, sondern die mittlere Kategorie betrachtet.

10.3 9.3 Arithmetisches Mittel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Eigenschaften:

- nur für metrische Daten sinnvoll
- nutzt alle Werte
- empfindlich gegenüber Ausreißern

```
daten <- c(2, 10, 4, 10, 4, 4, 5)
mean(daten, na.rm = TRUE)
```

```
[1] 5.571429
```

11 10. Erweiterte Mittelwerte

11.1 10.1 Gewichtetes Mittel

$$\bar{x} = \frac{\sum \bar{x}_r \cdot n_r}{\sum n_r}$$

oder allgemein:

$$\bar{x}_w = \frac{\sum w_i x_i}{\sum w_i}$$

Sinnvoll, wenn Werte oder Gruppen unterschiedlich stark gewichtet werden.

```
noten <- c(1.0, 2.0, 3.0)
credits <- c(10, 5, 5)

weighted.mean(noten, credits, na.rm = TRUE)
```

```
[1] 1.75
```

11.2 10.2 Geometrisches Mittel

$$GM = \sqrt[n]{\prod_{i=1}^n x_i}$$

Sinnvoll bei:

- Wachstumsraten
- multiplikativen Prozessen
- durchschnittlichen Veränderungsfaktoren

Nur bei positiven Werten sinnvoll.

```
gm <- function(x){
  return( prod(x)^(1/length(x)) )
}
daten <- c(2, 4, 8)
gm(daten)
```

```
[1] 4
```

11.3 10.3 Getrimmtes Mittel

Beim getrimmten Mittel werden extreme Werte entfernt.

$$\bar{x}_{\text{trim}} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} x_{(i)}$$

Dabei gilt:

$x_{(i)}$ = die sortierten Werte

k = Anzahl der entfernten kleinsten und größten Werte

n = Anzahl aller Beobachtungen

Beispiel:

- die kleinsten 5% und größten 5% entfernen
- dann Mittelwert berechnen

Robuster als das arithmetische Mittel.

```
daten <- c(2, 10, 4, 10, 4, 4, 5)
mean(daten, trim = 0.1, na.rm = TRUE)
```

```
[1] 5.571429
```

11.4 10.4 Winsorisiertes Mittel

Beim winsorisierten Mittel werden extreme Werte nicht entfernt, sondern durch weniger extreme Grenzwerte ersetzt.

$$x_i < Q_{0.05} \Rightarrow x_i := Q_{0.05}, x_i > Q_{0.95} \Rightarrow x_i := Q_{0.95}$$

Beispiel:

- kleinste Werte werden auf das 5%-Quantil gesetzt
- größte Werte werden auf das 95%-Quantil gesetzt

```
x <- c(1, 2, 3, 4, 5, 100)

# Quantile berechnen
q_unten <- quantile(x, 0.05)
q_oben  <- quantile(x, 0.95)

# Winsorisieren
x_win <- x

x_win[x < q_unten] <- q_unten
x_win[x > q_oben] <- q_oben

# winsorisiertes Mittel
mean(x_win, na.rm = TRUE)
```

[1] 15.25

12 11. Streuungsmaße

Streuungsmaße beschreiben, wie stark Werte auseinanderliegen.

12.1 11.1 Relativer Informationsgehalt (nominal)

Ein Streuungsmaß für nominalskalierte Variablen.

$$H = -\frac{1}{\ln(k)} \sum_{j=1}^k h_j \ln(h_j)$$

12.1.1 Interpretation

- $H = 0 \rightarrow$ maximale Konzentration, keine Streuung (eine Kategorie enthält alle Fälle)
- $H = 1 \rightarrow$ Gleichverteilung, alle Kategorien gleich häufig
- je größer H , desto gleichmäßiger verteilen sich die Werte auf die Kategorien

Eigenschaften:

- misst Gleichverteilung vs. Konzentration
- nur für nominale Daten sinnvoll

```
x <- c("A", "A", "B", "B", "B", "C")
p <- prop.table(table(x)) # Relative Häufigkeiten
H <- -sum(p * log2(p)) # Shannon-Entropie
Hmax <- log2(length(p)) # Maximale Entropie
Hrel <- H / Hmax # Relativer Informationsgehalt
Hrel
```

```
[1] 0.9206198
```

oder kompakter:

```
x <- c("A", "A", "B", "B", "B", "C")
p <- prop.table(table(x))
-sum(p * log2(p)) / log2(length(p))
```

```
[1] 0.9206198
```

12.2 11.2 Minimum und Maximum

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
range(daten, na.rm = TRUE)
```

```
[1] 3 100
```

12.3 11.3 Spannweite

$$R = x_{\max} - x_{\min}$$

Einfach, aber sehr ausreißerempfindlich.

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
diff(range(daten, na.rm = TRUE))
```

```
[1] 97
```

12.4 11.4 Interquartilsabstand

$$IQR = Q3 - Q1$$

Beschreibt die Streuung der mittleren 50% der Daten.

Robust gegenüber Ausreißern.

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
IQR(daten, na.rm = TRUE)
```

```
[1] 40
```

12.5 11.5 Varianz

Die Varianz misst die durchschnittliche quadrierte Abweichung der Werte vom Mittelwert.

Große Varianz

→ starke Streuung

Kleine Varianz

→ Werte liegen nahe am Mittelwert.

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
var(daten, na.rm = TRUE)
```

```
[1] 976.6909
```

12.5.1 Varianz der Grundgesamtheit

$$\sigma^2 = \frac{\sum (x_i - \mu)^2}{n}$$

12.5.2 Stichprobenvarianz

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Wichtig:

In vielen Statistikaufgaben wird bei Stichproben durch $n - 1$ geteilt. Durch die Division durch $n - 1$ wird die systematische Unterschätzung korrigiert. Das nennt man Bessel-Korrektur.

```
var(daten)
```

berechnet standardmäßig s^2 , also die Stichprobenvarianz mit Division durch $n - 1$.

12.6 11.6 Standardabweichung

$$s = \sqrt{s^2}$$

Die Standardabweichung ist die Wurzel der Varianz.

Vorteil:

Sie hat wieder die ursprüngliche Einheit der Daten.

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
sd(daten, na.rm = TRUE)
```

```
[1] 31.25205
```

12.7 11.7 Mittlere absolute Abweichung vom Mittelwert

$$\frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
mean(abs(daten - mean(daten, na.rm = TRUE)), na.rm = TRUE)
```

```
[1] 25.3719
```

12.8 11.8 Median Absolute Deviation (MAD)

$$MAD = \text{Median}(|x_i - Md|)$$

Robustes Streuungsmaß.

Achtung: In R gibt `mad(x)` standardmäßig eine **skalierte MAD** aus. Für unskaliert `constant = 1` hinzufügen

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
mad(daten, na.rm = TRUE)
```

```
[1] 29.652
```

12.9 11.9 Variationskoeffizient

$$v = \frac{s}{\bar{x}}$$

oder in Prozent:

$$v \cdot 100$$

Eigenschaften:

- relatives Streuungsmaß
- einheitenfrei
- sinnvoll bei verhältnisskalierten Daten
- problematisch, wenn $\bar{x}$ nahe 0 ist

```
x <- c(2, 4, 6, 8, 10)
sd(x, na.rm = TRUE) / mean(x, na.rm = TRUE)
```

```
[1] 0.5270463
```

```
100 * sd(x, na.rm = TRUE) / mean(x, na.rm = TRUE)
```

```
[1] 52.70463
```

13 12. Quantile, Perzentile und Prozentrang

13.1 Achtung bei der Berechnung

Quantile können je nach Konvention unterschiedlich berechnet werden.

In R gibt es beim Befehl `quantile()` verschiedene Berechnungstypen.

13.2 12.1 Quantile

Ein p -Quantil ist ein Wert, unter dem ungefähr der Anteil p der Daten liegt.

Beispiele:

- Median = 0.50-Quantil
- Q1 = 0.25-Quantil
- Q3 = 0.75-Quantil

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
quantile(daten, probs = c(0.3, 0.6, 0.9), na.rm = TRUE)
```

```
30% 60% 90%
 18  45  80
```

```
quantile(daten, 0.4, na.rm = TRUE) # beliebiges Quantil
```

```
40%
 25
```

13.3 12.2 Quartile

Quartile teilen Daten in vier Teile:

- Q1: 25%
- Q2: 50% = Median
- Q3: 75%

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
quantile(daten, na.rm = TRUE)
```

```
0%  25%  50%  75% 100%
 3   15   30   55  100
```

13.4 12.3 Dezile

Dezile teilen Daten in zehn Teile.

13.5 12.4 Perzentile

Perzentile teilen Daten in hundert Teile.

13.6 12.5 Prozentrang

Der Prozentrang gibt an, wie viel Prozent der Werte kleiner oder gleich einem bestimmten Wert sind.

Beispiel:

Ein Prozentrang von 78 bedeutet: 78% der Werte liegen unterhalb oder bis zu diesem Wert.

Ergänzung:

Prozentrang (formal)

Bei nicht verbundenen Rängen:

$$PR_i = \frac{R_i}{n} \cdot 100$$

```
daten <- c(3, 7, 12, 18, 25, 30, 45, 50, 60, 80, 100)
ecdf(daten)(77)
```

```
[1] 0.8181818
```

```
100 * ecdf(daten)(77)
```

```
[1] 81.81818
```

→ berechnet die empirische Verteilungsfunktion an der Stelle: $x = 77$

Die empirische Verteilungsfunktion ist definiert als:

$$F_n(x) := \frac{\text{Anzahl der Beobachtungswerte in der Stichprobe} \leq x}{n} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{(-\infty, x)}(x_i)$$

13.7 12.6 Rangbindungen

Bei gleichen Werten:

- Mittelwert der Rangplätze bilden
- diesen Rang allen zuweisen

Beispiel:

Ränge 2, 3, 4 → alle werden zu 3

```
x <- c(10, 20, 20, 30)
rank(x) # standardmäßig Mittelwert [ties.method = "average"]
```

```
[1] 1.0 2.5 2.5 4.0
```

```
rank(x, ties.method = "min") # kleinster Rang
```

```
[1] 1 2 2 4
```

```
rank(x, ties.method = "max") # größter Rang
```

```
[1] 1 3 3 4
```

```
rank(x, ties.method = "first") # Reihenfolge des Auftretens
```

```
[1] 1 2 3 4
```

```
rank(x, ties.method = "random") # Zufällig auflösen
```

```
[1] 1 2 3 4
```

14 13. Verteilungen

14.1 13.1 Symmetrische Verteilung

Bei einer ideal symmetrischen unimodalen Verteilung gilt:

$$\bar{x} = Md = Mo$$

```
library(psych)
x <- c(1,2,3,4,5,6,7)
skew(x)
```

[1] 0

Schiefe nahe 0

14.2 13.2 Rechtsschiefe Verteilung

- langer Ausläufer nach rechts
- wenige hohe Werte ziehen den Mittelwert nach rechts
- typischerweise:

$$\bar{x} > Md > Mo$$

```
library(psych)
x <- c(1,2,2,3,3,4,20)
skew(x)
```

[1] 1.5505

Schiefe größer 0

14.3 13.3 Linksschiefe Verteilung

- langer Ausläufer nach links
- wenige niedrige Werte ziehen den Mittelwert nach links
- typischerweise:

$$\bar{x} < Md$$

```
library(psych)
x <- c(-20,1,2,3,3,4,4)
skew(x)
```

[1] -1.569637

Schiefe kleiner 0

14.3.1 Merksatz

Der Mittelwert wird in Richtung des langen Ausläufers gezogen.

14.4 13.4 Kurtosis

Kurtosis beschreibt die Form einer Verteilung im Vergleich zur Normalverteilung.

14.5 13.5 Exzess

Häufig wird der Exzess betrachtet:

$$\text{Exzess} = \text{Kurtosis} - 3$$

14.5.1 Interpretation

Exzess	Bedeutung	Begriff
0	ähnlich Normalverteilung	
> 0	eher spitz / schwere Ränder	Leptokurtisch
< 0	eher flach / leichte Ränder	Platykurtisch

Achtung:

Kurtosis bedeutet nicht einfach nur „spitz“ oder „flach“, sondern hängt stark mit der Verteilung in den Rändern zusammen.

```
x <- c(4.8,4.9,5,5,5,5.1,5.2,20)
kurtosi(x) # Leptokurtisch
```

```
[1] 1.698684
```

```
y <- c(1,2,3,4,5,6,7,8,9,10)
kurtosi(y) # Platykurtisch
```

```
[1] -1.561636
```

Berechnet den Exzess der Verteilung.

14.6 Gesamtübersicht

```
library(psych)
describe(x)
```

→ viele Kennwerte auf einmal

15 14. Z-Transformation

$$z = \frac{x - \bar{x}}{s}$$

15.1 14.1 Bedeutung

Ein z-Wert gibt an, wie viele Standardabweichungen ein Wert vom Mittelwert entfernt liegt.

15.2 Eigenschaften

Nach der Z-Transformation gilt:

$$\bar{z} = 0$$

$$s_z = 1$$

Die Form der Verteilung bleibt erhalten. Schiefe, Ausreißer und Kurtosis verändern sich nicht. Die z-Transformation standardisiert, aber normalisiert nicht die Verteilungsform.

15.3 14.2 Interpretation

- $z = 1$: eine Standardabweichung über dem Mittelwert
- $z = -2$: zwei Standardabweichungen unter dem Mittelwert

```
daten <- c(10, 12, 15, 20, 25)
scale(daten)
```

```

      [,1]
[1,] -1.0479138
[2,] -0.7204407
[3,] -0.2292311
[4,]  0.5894515
[5,]  1.4081342
attr(,"scaled:center")
[1] 16.4
attr(,"scaled:scale")
[1] 6.107373

```

16 15. Bedingte Kennwerte

Bedingte Kennwerte sind Kennwerte innerhalb von Teilgruppen.

Beispiel:

Mittelwert von X getrennt nach Gruppen von Y.

16.1 15.1 Zweck

Man untersucht, wie sich eine Variable abhängig von einer anderen Variable verhält.

16.2 15.2 Darstellung

Numerisch:

- Gruppierte Mittelwerte
- Gruppierte Mediane
- Gruppierte Standardabweichungen

Grafisch:

- Mittelwertdiagramm
- Boxplots nach Gruppen
- Balkendiagramme

16.3 Wichtig

Nicht nur den Gesamtmittelwert betrachten, sondern Gruppenunterschiede prüfen.

16.4 Übersicht Kennwerte je Gruppe

```
library(psych)

x <- c(3,5,7,10,12,15)
gruppe <- c("A","A","A","B","B","B")

describeBy(x, gruppe)
```

```
Descriptive statistics by group
group: A
  vars n mean sd median trimmed  mad min max range skew kurtosis   se
X1    1 3   5  2      5      5 2.97  3  7    4    0   -2.33 1.15
-----
group: B
  vars n mean  sd median trimmed  mad min max range skew kurtosis   se
X1    1 3 12.33 2.52    12   12.33 2.97 10 15    5 0.13   -2.33 1.45
```

16.5 Spezifischer Kennwert nach Gruppe

```
x <- c(3,5,7,10,12,15)
gruppe <- c("A","A","A","B","B","B")

by(x, INDICES = gruppe, FUN = mean, na.rm = TRUE)
```

```
gruppe: A
[1] 5
-----
gruppe: B
[1] 12.33333
```

16.6 Subsetting

16.6.1 Werte einer Gruppe auswählen

```

gruppe <- c("A", "B", "A", "C")
x <- c(10, 20, 30, 40)

x[gruppe == "A"]

```

```
[1] 10 30
```

→ gibt alle Werte aus `x` zurück, bei denen die Gruppe "A" ist

16.6.2 Zeilen aus Dataframe filtern

```

df <- data.frame(
  name = c("Anna", "Ben", "Clara"),
  alter = c(21, 25, 19)
)

df[df$alter != 25, ]

```

```

  name alter
1 Anna    21
3 Clara   19

```

→ gibt alle Zeilen zurück, bei denen `alter` nicht 25 ist

17 16. Kovarianz

Die Kovarianz beschreibt, ob zwei Variablen gemeinsam variieren.

$$\text{cov}(x, y) = \frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})$$

Bei Stichproben häufig:

$$\text{cov}(x, y) = \frac{1}{n-1} \sum (x_i - \bar{x})(y_i - \bar{y})$$

17.1 Interpretation

Für jeden Fall wird betrachtet:

$$(x_i - \bar{x})(y_i - \bar{y})$$

- beide Werte über dem Mittelwert → positiv
- beide Werte unter dem Mittelwert → positiv
- einer über, einer unter dem Mittelwert → negativ

17.2 Problem

Die Kovarianz hängt von den Einheiten der Variablen ab.

Deshalb ist sie schwer direkt interpretierbar.

```
x <- c(1, 2, 3, 4, 5)
y <- c(2, 4, 6, 8, 10)

cov(x, y)
```

```
[1] 5
```

18 17. Zusammenhangsmaße nach Skalenniveau

Variable X	Variable Y	geeignetes Maß
metrisch	metrisch	Pearson-r
ordinal	ordinal	Spearman-Rho / Kendall-Tau
dichotom	dichotom	Phi-Koeffizient
nominal	nominal	Kontingenzmaße, z.B. Cramér's V, Chi-Quadrat
metrisch	dichotom	punktbiseriale Korrelation / Gruppenvergleich

19 18. Korrelation Kausalität

Korrelation bedeutet nicht automatisch Ursache.

19.1 Drei mögliche Erklärungen

1. X verursacht Y
2. Y verursacht X
3. Eine Drittvariable Z beeinflusst X und Y

19.2 Für Kausalität braucht man mindestens

- Korrelation
- zeitliche Präzedenz
- Ausschluss plausibler Drittvariablen

20 19. Korrelationsmatrix

Eine Korrelationsmatrix zeigt die Korrelationen mehrerer Variablen untereinander.

Eigenschaften:

- Diagonale = 1
- symmetrisch
- jede Variable wird mit jeder anderen korreliert

Beispiel:

	X	Y	Z
X	1	r_{xy}	r_{xz}
Y	r_{yx}	1	r_{yz}
Z	r_{zx}	r_{zy}	1

21 20. Pearson-Korrelation

Die Pearson-Korrelation standardisiert die Kovarianz.

$$r = \frac{\text{cov}(x, y)}{s_x \cdot s_y}$$

Alternative Sichtweise mit z-Werten:

$$r = \frac{1}{n} \sum z_x z_y$$

Bei Stichproben je nach Definition entsprechend mit $n - 1$.

```
x <- c(1, 2, 3, 4, 5)
y <- c(2, 4, 6, 8, 10)

cor(x, y, use = "pairwise.complete.obs")
```

```
[1] 1
```

21.1 Wertebereich

$$-1 \leq r \leq 1$$

r	Bedeutung
+1	perfekt positiver linearer Zusammenhang
0	kein linearer Zusammenhang
-1	perfekt negativer linearer Zusammenhang

21.2 Richtung

- positiv: hohe X-Werte gehen mit hohen Y-Werten einher
- negativ: hohe X-Werte gehen mit niedrigen Y-Werten einher

21.3 Stärke

Je näher $|r|$ an 1 liegt, desto stärker der lineare Zusammenhang.

21.4 Cohen-Konvention

Betrag von r	Interpretation
0.1	schwach
0.3	mittel
0.5	stark

Achtung:

Das sind Faustregeln, keine Naturgesetze. Einfach vom Mensch mal festgelegt.

21.5 Korrelation in R

```
df <- data.frame(  
  x = c(1, 2, 3, 4, 5),  
  y = c(2, 4, 6, 8, 10),  
  z = c(5, 3, 6, 2, 7)  
)  
  
cor(df[, c("x", "y", "z")],  
    use = "pairwise.complete.obs")
```

```
      x      y      z  
x 1.0000000 1.0000000 0.2287479  
y 1.0000000 1.0000000 0.2287479  
z 0.2287479 0.2287479 1.0000000
```

→ berechnet die Korrelationen zwischen mehreren Variablen

21.5.1 Bedeutung von `use = "pairwise.complete.obs"`

- fehlende Werte (NA) werden paarweise ausgeschlossen
- jede Korrelation nutzt alle verfügbaren gültigen Wertepaare

22 21. Voraussetzungen und Probleme bei Pearson-r

22.1 Voraussetzungen

- metrische Variablen
- linearer Zusammenhang
- keine extremen Ausreißer
- sinnvoll interpretierbare Streuung

22.2 Probleme

22.2.1 Ausreißer

Ausreißer können r stark erhöhen, senken oder sogar die Richtung verändern.

22.2.2 Varianzeinschränkung

Wenn die Werte nur in einem kleinen Bereich variieren, wird r oft kleiner.

Beispiel:

Nur 10- bis 13-Jährige statt 6- bis 16-Jährige.

22.2.3 Heterogene Gruppen

Gemischte Gruppen können Zusammenhänge verfälschen.

Beispiel:

Wenn Männer und Frauen zusammen analysiert werden, obwohl die Muster getrennt verschieden sind.

23 22. Partialkorrelation

Die Partialkorrelation misst den Zusammenhang zwischen X und Y, nachdem der Einfluss einer Drittvariable Z herausgerechnet wurde.

$$r_{xy.z} = \frac{r_{xy} - r_{xz}r_{yz}}{\sqrt{1 - r_{xz}^2}\sqrt{1 - r_{yz}^2}}$$

```

x <- c(1,2,3,4,5)
y <- c(2,4,5,4,5)
z <- c(5,4,3,2,1)

# normale Korrelationen
r_xy <- cor(x, y)
r_xz <- cor(x, z)
r_yz <- cor(y, z)

# Partialkorrelation
(r_xy - r_xz * r_yz) /
sqrt((1 - r_xz^2) * (1 - r_yz^2))

```

```
[1] 1.666e-08
```

23.1 Interpretation

- Partialkorrelation deutlich kleiner als einfache Korrelation: Drittvariable erklärt einen Teil des Zusammenhangs.
- Partialkorrelation ähnlich groß: Drittvariable spielt für diesen Zusammenhang kaum eine Rolle.

24 23. Kreuztabelle

	B = ja	B = nein
A = ja	a	b
A = nein	c	d

24.1 Zeilenprozente

Zeilenprozente vergleichen innerhalb der Zeilen.

24.2 Spaltenprozente

Spaltenprozente vergleichen innerhalb der Spalten.

24.3 Gesamtprozente

Gesamtprozente beziehen sich auf alle Fälle.

24.4 absolute Kreuztabelle

```
x <- c(1, 2, 3, 4, 5)
y <- c(2, 4, 6, 8, 10)

table(x, y)
```

	y				
x	2	4	6	8	10
1	1	0	0	0	0
2	0	1	0	0	0
3	0	0	1	0	0
4	0	0	0	1	0
5	0	0	0	0	1

24.5 relative Anteile

```
x <- c(1, 2, 3, 4, 5)
y <- c(2, 4, 6, 8, 10)

prop.table(table(x, y))
```

	y				
x	2	4	6	8	10
1	0.2	0.0	0.0	0.0	0.0
2	0.0	0.2	0.0	0.0	0.0
3	0.0	0.0	0.2	0.0	0.0
4	0.0	0.0	0.0	0.2	0.0
5	0.0	0.0	0.0	0.0	0.2

24.6 Ausführliche Kreuztabelle mit gmodels

```
CrossTable(x, y, prop.chisq = FALSE)
```

25 24. Dichotome Variablen und Phi-Koeffizient

25.1 Phi-Koeffizient

$$\phi = \frac{ad - bc}{\sqrt{(a+b)(c+d)(a+c)(b+d)}}$$

Der Phi-Koeffizient ist für zwei dichotome Variablen geeignet.

Wertebereich: -1 bis +1

25.2 Über Kontingenztafel

```
library(psych)

x <- c(1,1,1,0,0,0)
y <- c(1,1,0,1,0,0)

phi(table(x, y))
```

```
[1] 0.33
```

25.3 in R manuell

```
tab <- matrix(c(10, 5,
                3, 12),
              nrow = 2)

a <- tab[1,1]
b <- tab[1,2]
c <- tab[2,1]
d <- tab[2,2]

(ad <- a*d)
```

[1] 120

```
bc <- b*c  
  
(ad - bc) /  
sqrt((a+b)*(c+d)*(a+c)*(b+d))
```

[1] 0.470871

26 25. Ordinale Zusammenhangsmaße / Rangkorrelation

26.1 Spearman-Rho

Spearman-Rho ist eine Korrelation der Rangplätze.

Geeignet für:

- ordinale Daten
- monotone Zusammenhänge

```
daten <- data.frame(  
  x = c(1,2,3,4,5),  
  y = c(2,4,6,8,10)  
)  
  
cor(x, y, method = "spearman", use = "pairwise.complete.obs")
```

[1] 0.3333333

26.2 Kendall-Tau

Kendall-Tau basiert auf Paarvergleichen.

Es betrachtet:

- gleichgerichtete Paare
- gegenläufige Paare

Begriffe:

- Proversionen: gleichgerichtete Rangpaare

- Inversionen: gegenläufige Rangpaare

Kendall-Tau ist oft robuster und gut bei kleinen Stichproben oder vielen Bindungen.

```
daten <- data.frame(
  x = c(1,2,3,4,5),
  y = c(2,4,6,8,10)
)

cor(x, y, method = "kendall", use = "pairwise.complete.obs")
```

```
[1] 0.3333333
```

27 26. Regression

Regression dient der Vorhersage einer abhängigen Variable Y durch eine unabhängige Variable X.

- Korrelation misst Zusammenhang
- Regression nutzt Zusammenhang zur Vorhersage

Je stärker die Korrelation, desto besser die Vorhersage.

27.1 Begriffe

- Y = Kriterium / abhängige Variable
- X = Prädiktor / unabhängige Variable

27.2 Regressionsgerade

$$\hat{y} = bx + a$$

oder:

$$\hat{y} = a + bx$$

27.3 lineares Regressionsmodell

```
df <- data.frame(
  x = c(1,2,3,4,5),
  y = c(2,4,5,4,5)
)

# y wird durch x vorhergesagt
lm(y ~ x, data = df)
```

Call:

```
lm(formula = y ~ x, data = df)
```

Coefficients:

(Intercept)	x
2.2	0.6

27.4 Modellzusammenfassung

```
df <- data.frame(
  x = c(1,2,3,4,5),
  y = c(2,4,5,4,5)
)

# y wird durch x vorhergesagt
summary(lm(y ~ x, data = df))
```

Call:

```
lm(formula = y ~ x, data = df)
```

Residuals:

1	2	3	4	5
-0.8	0.6	1.0	-0.6	-0.2

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.2000	0.9381	2.345	0.101
x	0.6000	0.2828	2.121	0.124

Residual standard error: 0.8944 on 3 degrees of freedom
Multiple R-squared: 0.6, Adjusted R-squared: 0.4667
F-statistic: 4.5 on 1 and 3 DF, p-value: 0.124

27.5 Regressionskoeffizienten gezielt ausgeben

```
df <- data.frame(  
  x = c(1,2,3,4,5),  
  y = c(2,4,5,4,5)  
)  
  
# y wird durch x vorhergesagt  
coef(summary(lm(y ~ x, data = df)))
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.2	0.9380832	2.345208	0.1007435
x	0.6	0.2828427	2.121320	0.1240271

27.6 Interpretation

27.6.1 Steigung b / Regressionsgewicht

$$b = \frac{\text{cov}(x, y)}{s_x^2}$$

b bedeutet:

Wenn X um 1 Einheit steigt, verändert sich die vorhergesagte Variable Y im Mittel um b Einheiten.

Ein b-Gewicht gibt an, um wie viele Einheiten sich Y verändert, wenn X um eine Einheit steigt.

- positives b → Y steigt mit X
- negatives b → Y sinkt mit X

27.6.2 Achsenabschnitt a / Intercept

$$a = \bar{y} - b \cdot \bar{x}$$

a bedeutet:

Vorhergesagter Y-Wert, wenn $X = 0$ ist.

Achtung:

a ist nur sinnvoll interpretierbar, wenn $X = 0$ inhaltlich sinnvoll ist.

27.7 Beta-Gewichte

Beta-Gewichte sind standardisierte Regressionsgewichte.

Sie ermöglichen den Vergleich der relativen Bedeutung verschiedener Prädiktoren.

```
library(lm.beta)

df <- data.frame(
  x = c(1,2,3,4,5),
  y = c(2,4,5,4,5)
)
modell <- lm(y ~ x, data = df)

lm.beta(modell)
```

Call:

```
lm(formula = y ~ x, data = df)
```

Standardized Coefficients::

(Intercept)	x
NA	0.7745967

27.7.1 Interpretation

- positives Beta → positiver Zusammenhang
- negatives Beta → negativer Zusammenhang

28 27. Vorhersagefehler und Kleinste Quadrate

28.1 Vorhersagewert

$\hat{y}$ ist der durch das Regressionsmodell vorhergesagte Wert

```
df <- data.frame(  
  x = c(1,2,3,4,5),  
  y = c(2,4,5,4,5)  
)  
  
modell <- lm(y ~ x, data = df)  
  
predict(modell)
```

```
  1  2  3  4  5  
2.8 3.4 4.0 4.6 5.2
```

```
# oder  
fitted(modell)
```

```
  1  2  3  4  5  
2.8 3.4 4.0 4.6 5.2
```

28.2 Fehler / Residuum

$$e = y - \hat{y}$$

Das Residuum ist der Unterschied zwischen beobachtetem und vorhergesagtem Wert.

```
df <- data.frame(  
  x = c(1,2,3,4,5),  
  y = c(2,4,5,4,5)  
)  
  
modell <- lm(y ~ x, data = df)  
  
resid(modell)
```

```
  1  2  3  4  5  
-0.8 0.6 1.0 -0.6 -0.2
```


28.3 Beobachtete vs. vorhergesagte Werte

```
data.frame(  
  beobachtet = df$y,  
  vorhergesagt = fitted(modell),  
  residuum = resid(modell)  
)
```

	beobachtet	vorhergesagt	residuum
1	2	2.8	-0.8
2	4	3.4	0.6
3	5	4.0	1.0
4	4	4.6	-0.6
5	5	5.2	-0.2

28.4 Residuenplot

```
plot(fitted(modell),  
     resid(modell))  
  
abline(h = 0, col = "red")
```



28.5 Kleinste-Quadrate-Prinzip

$$\sum (y - \hat{y})^2 \rightarrow \min$$

Die Regressionsgerade wird so gewählt, dass die Summe der quadrierten Fehler minimal ist.

29 28. Zusammenhang zwischen Regression und Korrelation

$$b = r \cdot \frac{s_y}{s_x}$$

29.1 Interpretation

- Bei positivem r ist b positiv.
- Bei negativem r ist b negativ.
- Je stärker r , desto stärker die lineare Vorhersage.

30 29. Z-standardisierte Regression

Wenn X und Y z-standardisiert sind:

$$\hat{z}_y = \beta z_x$$

Bei einfacher Regression gilt:

$$\beta = r$$

und:

$$a = 0$$

Das bedeutet: Bei z-standardisierten Variablen ist das Regressionsgewicht gleich der Korrelation.

31 30. Determinationskoeffizient (R^2)

$$R^2 = r^2$$

bei einfacher Regression.

31.1 Bedeutung

R^2 ist der Anteil erklärter Varianz.

Beispiel:

$$r = 0.7$$

$$r^2 = 0.49$$

Interpretation: 49% der Varianz von Y werden durch X erklärt.

```
x <- c(1, 2, 3, 4, 5)
y <- c(2, 4, 6, 8, 10)

cor(x, y, use = "pairwise.complete.obs")^2
```

```
[1] 1
```

Typischer Klausurfehler

Falsch:

$r = 0.6$ bedeutet 60% erklärte Varianz.

Richtig:

$r^2 = 0.36$, also 36% erklärte Varianz.

32 31. Erklärte Varianz und Fehlervarianz / Residualvarianz

$$R^2 = \frac{\text{erklärte Varianz}}{\text{Gesamtvarianz}}$$

konkret:

$$R^2 = \frac{s_{\hat{y}}^2}{s_y^2}$$

32.1 Zerlegung

Gesamtvarianz =

- erklärte Varianz
- nicht erklärte Varianz / Fehlervarianz

33 32. Standardfehler der Schätzung

$$s_e = s_y \cdot \sqrt{1 - r^2}$$

```
summary(modell)$sigma
```

```
[1] 0.8944272
```

```
# manuelle Berechnung (leicht abweichende Werte, da n-1, statt n-2 Freiheitsgrade)
sd(df$y) * sqrt(1 - cor(df$x, df$y)^2)
```

```
[1] 0.7745967
```

33.1 Bedeutung

Der Standardfehler der Schätzung beschreibt die typische Größe der Vorhersagefehler.

Je kleiner s_e , desto besser die Vorhersage.

34 33. Multiple Regression

Bei multipler Regression wird Y durch mehrere Prädiktoren vorhergesagt.

$$\hat{y} = a + b_1x_1 + b_2x_2 + \dots + b_kx_k$$

- a = Intercept / Achsenabschnitt
- b_i = Regressionsgewicht des jeweiligen Prädiktors

```
df <- data.frame(  
  y = c(2,4,5,4,5),  
  x1 = c(1,2,3,4,5),  
  x2 = c(5,4,3,2,1)  
)  
  
modell <- lm(y ~ x1 + x2, data = df)  
  
summary(modell)
```

Call:

```
lm(formula = y ~ x1 + x2, data = df)
```

Residuals:

```
      1      2      3      4      5  
-0.8  0.6  1.0 -0.6 -0.2
```

Coefficients: (1 not defined because of singularities)

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.2000	0.9381	2.345	0.101
x1	0.6000	0.2828	2.121	0.124
x2	NA	NA	NA	NA

Residual standard error: 0.8944 on 3 degrees of freedom

Multiple R-squared: 0.6, Adjusted R-squared: 0.4667

F-statistic: 4.5 on 1 and 3 DF, p-value: 0.124

34.1 b-Gewichte

Ein b-Gewicht gibt an, um wie viele Einheiten sich Y verändert, wenn der betreffende Prädiktor um 1 Einheit steigt und alle anderen Prädiktoren konstant gehalten werden.

34.2 standardisierte Beta-Gewichte

Vergleich der relativen Wichtigkeit der Prädiktoren

34.3 Adjustiertes R^2

```
summary(modell)$adj.r.squared
```

```
[1] 0.4666667
```

Das adjustierte R^2 berücksichtigt die Anzahl der Prädiktoren.

34.4 Redundanz / Multikollinearität

Redundanz liegt vor, wenn mehrere Prädiktoren ähnliche Information liefern.

Problem:

- instabile b-Gewichte
- schwierige Interpretation
- große Standardfehler

34.5 Suppressoreffekt

Ein Suppressor kann die Vorhersage verbessern, obwohl er selbst nur schwach mit Y korreliert.

Er entfernt irrelevante Varianz aus anderen Prädiktoren.

Dadurch kann:

- R^2 steigen
- ein anderer Prädiktor stärker werden

34.6 Multikollinearität prüfen

```
df <- data.frame(
  y = c(2,4,5,4,5),
  x1 = c(1,2,3,4,5),
  x2 = c(5,4,3,2,1)
)
cor(df)
```

```
      y      x1      x2
y  1.0000000  0.7745967 -0.7745967
x1  0.7745967  1.0000000 -1.0000000
x2 -0.7745967 -1.0000000  1.0000000
```

35 34. Regression vs. Korrelation

Korrelation	Regression
ungerichtet	gerichtet
misst Zusammenhang	dient Vorhersage
symmetrisch: $r(X,Y) = r(Y,X)$	X sagt Y vorher
keine Unterscheidung zwischen X und Y	Prädiktor und Kriterium wichtig
keine kausale Richtung	gerichtetes Vorhersagemodell

36 35. Typische Interpretationsformulierungen

36.1 Korrelation

Es besteht ein mittlerer positiver linearer Zusammenhang zwischen X und Y.

36.2 Korrelation mit r

Es besteht ein mittlerer positiver linearer Zusammenhang zwischen X und Y, $r = .30$.

36.3 Determinationskoeffizient

$r^2 = .25$ bedeutet, dass 25% der Varianz von Y durch X erklärt werden können.

oder

Das Modell erklärt 25% der Varianz von Y.

36.4 Regression

Wenn X um eine Einheit steigt, steigt/fällt der vorhergesagte Wert von Y im Mittel um b Einheiten.

36.5 Multiple Regression

Unter Kontrolle der übrigen Prädiktoren steigt/fällt der vorhergesagte Wert von Y um b Einheiten, wenn der betreffende Prädiktor um eine Einheit steigt.