

Inferenzstatistik & NHST

Emilian Hahlbrock

2026-06-01

Lizenz und Hinweise

Autor: Emilian Hahlbrock

Repository: <https://github.com/milisaur/statistik-m2>

Lizenz: Creative Commons Attribution-NonCommercial-ShareAlike 4.0 International (CC BY-NC-SA 4.0)

Diese Unterlagen dürfen geteilt und bearbeitet werden, sofern eine Namensnennung erfolgt, keine kommerzielle Nutzung stattfindet und abgeleitete Werke unter derselben Lizenz veröffentlicht werden.

Diese Version verwendet ausschließlich öffentliche oder synthetisch erzeugte Beispieldaten.

Diese Unterlagen sind privat erstellt und keine offiziellen Materialien der FernUniversität in Hagen.

Table of contents

1	Inferenzstatistik und NHST	13
1.1	Öffentliche Beispieldaten für alle Beispiele	13
2	1. Grundidee der Inferenzstatistik	15
2.1	Ziel	15
2.2	Problem	15
2.3	Warum funktioniert es trotzdem?	15
2.4	Lösung	15
3	2. Grundbegriffe	15
3.1	Population vs. Stichprobe	15
3.2	Parameter vs. Statistik	16
3.3	Stichprobentypen	16
4	3. Wahrscheinlichkeit	16
4.1	Subjektive Wahrscheinlichkeit	16
4.2	Klassische Wahrscheinlichkeit	16
4.3	Frequentistische Wahrscheinlichkeit	16
4.4	Relative Häufigkeit	16
4.5	Konjunktion	17
4.6	Bedingte Wahrscheinlichkeit	17
4.7	Unabhängigkeit	17
4.8	Produktregel	17
5	4. Stichprobenverteilung	17
5.1	Definition	17
5.2	Empirische Stichprobenverteilung	17
5.3	Theoretische Stichprobenverteilung	18
5.4	Erwartungswert	18
5.4.1	Eigenschaften guter Schätzer	18
5.5	Varianz & Standardfehler	19
5.5.1	Zusammenhang der Schreibweisen	20
5.5.2	Formal	20
5.6	Bedeutung des Standardfehlers	20
5.7	Konsequenzen	20
5.7.1	Reminder Standardabweichung vs. Standardfehler:	21
6	5. Zentrale Sätze	21
6.1	Gesetz der großen Zahlen	21
6.2	Zentraler Grenzwertsatz	21

7	6. Verteilungen	22
7.1	Normalverteilung	22
7.2	Funktionen der Normalverteilung	22
7.2.1	Dichtefunktion mit <code>dnorm()</code>	22
7.3	Wahrscheinlichkeit mit <code>pnorm()</code>	22
7.4	Quantile mit <code>qnorm()</code>	23
7.5	Zufallszahlen mit <code>rnorm()</code>	23
7.5.1	68-95-99 Regel	24
7.6	Standardisierung	24
7.7	Standardnormalverteilung	24
7.8	t-Verteilung	24
7.8.1	Warum t statt z?	25
7.8.2	Eigenschaften der t-Verteilung	25
7.9	Freiheitsgrade	25
7.10	Binomialverteilung	25
7.10.1	Wahrscheinlichkeit für genau x Erfolge mit <code>dbinom()</code>	26
7.10.2	Kumulative Wahrscheinlichkeit mit <code>pbinom()</code>	26
7.10.3	Quantile mit <code>qbinom()</code>	26
7.10.4	Zufallszahlen mit <code>rbinom()</code>	26
7.11	Normalapproximation	27
7.12	Beispiel	27
7.12.1	Wahrscheinlichkeit näherungsweise berechnen	27
7.13	Stetigkeitskorrektur	28
8	7. Konfidenzintervalle	28
8.1	Allgemeine Form	28
8.2	Mittelwert (wichtig!)	28
8.3	Anteil	29
8.4	Zusammenhang mit Alpha	29
8.5	Einflussfaktoren auf die Breite	29
8.6	Freiheitsgrade	29
8.7	Interpretation	29
8.8	Zusammenhang mit Tests	30
8.9	R-Code	30
8.9.1	Konfidenzintervall für den Mittelwert mit <code>CI()</code>	30
8.9.2	Konfidenzintervall über <code>t.test()</code>	30
8.9.3	Konfidenzintervall für einen Anteil mit <code>prop.test()</code>	31
8.9.4	Exaktes Konfidenzintervall mit <code>binom.test()</code>	31
8.9.5	Unterschied	31
9	8. Signifikanztests (NHST)	31
9.1	Nullhypothese H_0	32
9.2	Alternativhypothese H_1	32

9.3	typische Annahmen parametrischer Tests	32
9.4	Einseitig vs. zweiseitig	33
9.5	Teststatistik	33
9.6	Entscheidungsregel	33
9.7	Kritischer Wert	33
9.8	p-Wert	34
9.9	t vs. z	34
10	9. Fehler & Power	34
10.1	Fehlerarten	34
10.1.1	Fehler 1. Art	34
10.1.2	Fehler 2. Art	34
10.2	Zusammenhang	34
10.3	Power	35
10.4	Einflussfaktoren	35
10.4.1	Wichtig	35
11	10. Effektgröße / Cohen's d	35
11.1	Interpretation	35
12	11. Fisher vs. Neyman-Pearson	36
12.1	Fisher	36
12.2	Neyman-Pearson	36
13	12. Gesamtzusammenhang	36
13.1	Gesamtidee	36
13.2	Grundformel der Signifikanz	36
13.2.1	Signifikanz entsteht durch:	36
14	13. t-Tests	37
14.1	Überblick	37
14.2	13.1 t-Test für unabhängige Stichproben	37
14.2.1	Ziel	37
14.2.2	Vorraussetzungen	37
14.2.3	Nullhypothese	37
14.2.4	Alternativhypothese	38
14.2.5	Warum halbiert sich der p-Wert?	38
14.2.6	Varianzhomogenität annehmen	39
14.3	13.2 Welch-Test	39
14.3.1	Prüfgröße	40
14.3.2	Standardfehler des Mittelwertsunterschieds	40
14.3.3	Freiheitsgrade:	40
14.3.4	Interpretation des t-Werts	40

14.3.5	Zusammenhang	40
14.3.6	Durchführung in R	40
14.4	13.2 t-Test für abhängige Stichproben	43
14.4.1	Ziel	43
14.4.2	Vorraussetzungen	43
14.4.3	Idee	43
14.4.4	Nullhypothese	44
14.4.5	Prüfgröße	44
14.4.6	Standardfehler	44
14.4.7	Freiheitsgrade	44
14.4.8	Einfluss der Korrelation	44
14.4.9	Durchführung in R	44
14.5	13.3 Einstichproben-t-Test	46
14.5.1	Ziel	46
14.5.2	Vorraussetzungen	46
14.5.3	Nullhypothese	46
14.5.4	Prüfgröße	47
14.5.5	Durchführung in R	47
14.6	13.4 Effektgrößen bei t-Tests	48
14.6.1	Cohen's d mit gepoolter SD bei unabhängigen Stichproben	48
14.6.2	Effektgröße basierend auf Differenzwerten bei abhängigen Stichproben	49
14.7	13.5 Poweranalyse bei t-Tests	49
14.7.1	Ziel	49
14.7.2	Einflussfaktoren	49
14.7.3	Standardwert	49
14.8	13.6 Interpretation des p-Wertes	50
14.8.1	Definition	50
14.8.2	Entscheidungsregel	50
14.9	13.7 Zentrale Kritikpunkte am NHST (Kurzüberblick)	50
14.9.1	p-Wert ist nicht:	50
14.9.2	Probleme	50
14.10	13.8 Alternativen:	51
14.10.1	Obergrenze Bayes-Faktor	51
14.10.2	Shannon-Information (s-Wert)	52
14.10.3	Interpretation:	52
14.10.4	Berechnung in R	52
14.11	13.9 APA-Bericht	52
14.11.1	Format	52
14.11.2	Regeln	53
15	14. Einfaktorielle Varianzanalyse	53
15.1	Grundidee	53
15.2	Wann verwendet man ANOVA?	53

15.3	Warum nicht mehrere t-Tests?	54
15.4	Alternative: Bonferroni-Korrektur	54
15.5	Hypothesen	54
15.6	Logik der ANOVA	55
15.6.1	Varianzzerlegung	55
15.7	F-Wert	55
15.8	F-Verteilung	56
15.9	Quadratsummen	56
15.9.1	Innerhalb Gruppen	56
15.9.2	Zwischen Gruppen	56
15.10	Freiheitsgrade	57
15.11	ANOVA-Tabelle	57
15.12	Voraussetzungen	58
15.13	Interpretation	58
15.14	R-Code	58
15.14.1	Welch-ANOVA	59
15.15	Post-hoc-Tests	59
15.15.1	Tukey-Post-hoc-Test	60
15.16	Effektgröße Eta-Quadrat	60
15.17	Power bei ANOVA	61
15.18	APA-Bericht	61
15.19	weitere Varianten	62
16	15. Inferenzstatistik der Korrelation	62
16.1	Stichprobe vs Population	62
16.2	Ziel	62
16.3	Voraussetzungen	62
16.4	Hypothesen	63
16.4.1	Ungerichtete Hypothese	63
16.4.2	Gerichtete Hypothese	63
16.5	Teststatistik	63
16.6	Bedeutung der Bestandteile	64
16.7	Freiheitsgrade	64
16.8	Logik des Tests	64
16.9	Interpretation der Korrelation	64
16.9.1	Richtung	64
16.9.2	Stärke	65
16.10	Effektgröße	65
16.11	Konfidenzintervall	65
16.12	Unterschied t-Test vs z-Test	66
16.12.1	t-Test	66
16.12.2	z-Test	66
16.13	APA-Bericht	66

16.14R-Code	66
17 16. Inferenzstatistik der Regression	68
17.1 Ziel	68
17.2 Grundlagen	68
17.2.1 Regressionsgleichung	68
17.2.2 Interpretation von b	68
17.3 Hypothesen	69
17.3.1 Regressionskoeffizient	69
17.3.2 Bedeutung	69
17.4 t-Test für den Regressionskoeffizienten	69
17.5 Voraussetzungen	70
17.6 Hypothesen	70
17.7 Teststatistik	70
17.8 Interpretation	70
17.8.1 Großes t :	70
17.8.2 Kleines t :	70
17.9 R-Code	70
17.9.1 wichtige Teile des Outputs	71
17.9.2 Regressionsgerade visualisieren	72
17.10Zusammenhang mit Korrelation	73
17.11Residuen	73
17.12Determinationskoeffizient R^2	73
17.12.1 Interpretation	74
17.12.2Zusammenhang mit Korrelation	74
17.12.3 Varianzzerlegung	74
17.12.4Regressionsquadratsumme (erklärte Variation)	74
17.12.5 Fehlerquadratsumme (nicht erklärte Variation)	74
17.13R-Code	75
17.14APA-Bericht	75
18 17. F-Test	75
18.1 Teststatistik:	75
18.2 Interpretation	75
18.3 Freiheitsgrade	76
18.3.1 Zählerfreiheitsgrade	76
18.3.2 Nennerfreiheitsgrade	76
18.4 standadisierte Koeffizienten	76
18.4.1 Beta-Gewichte β	76
18.5 APA-Bericht	76
18.6 Zusammenhang mit R^2	77
18.7 F-Test in R	77

19 18. Chi-Quadrat-Test (χ^2)	78
19.1 Ziel	78
19.2 Grundidee	78
19.3 Eigenschaften	78
19.4 Chi-Quadrat-Test für eine Variable	78
19.4.1 Ziel	79
19.4.2 Nullhypothese	79
19.4.3 Alternativhypothese	79
19.4.4 Erwartete Häufigkeiten	79
19.4.5 Bei Gleichverteilung:	79
19.4.6 Bei vorgegebenen Anteilen	80
19.4.7 Teststatistik	80
19.4.8 Freiheitsgrade	81
19.4.9 Chi-Quadrat-Verteilung	81
19.5 Effektgröße w	81
19.5.1 Ziel	81
19.5.2 Formel	81
19.5.3 Interpretation nach Cohen	82
19.5.4 Power beim χ^2 -Test	82
19.5.5 Wichtig	82
19.6 Chi-Quadrat-Test für zwei Variablen	82
19.6.1 Ziel	82
19.6.2 Kreuztabellen / Kontingenztafeln	83
19.6.3 Nullhypothese	83
19.6.4 Alternativhypothese	83
19.6.5 Erwartete Häufigkeiten	83
19.6.6 Teststatistik	83
19.6.7 Freiheitsgrade	83
19.6.8 Interpretation	84
19.7 Effektgrößen bei zwei Variablen	84
19.7.1 Phi-Koeffizient ϕ	84
19.7.2 Cramers V / selten auch Cramers ϕ	85
19.7.3 Zusammenhang der Effektgrößen	85
19.7.4 Voraussetzungen	85
19.8 Wichtige Hinweise	86
19.9 APA-Bericht	86
19.10 R-Code	86
19.10.1 Chi-Quadrat-Test für eine Variable	86
19.10.2 Gleichverteilung testen	87
19.10.3 Eigene erwartete Wahrscheinlichkeiten	87
19.10.4 Chi-Quadrat-Test für zwei Variablen	87
19.10.5 Chi-Quadrat-Test berechnen	88
19.10.6 Erwartete Häufigkeiten anzeigen	88

19.10.7	Erweiterte Kreuztabelle	89
19.10.8	Fisher-Exact-Test	90
19.10.9	Hinweis	91
20	19. Resampling-Verfahren und non-parametrische Tests	91
20.1	19.1 Problem parametrischer Tests	91
20.2	19.2 Grundidee von Resampling	92
20.2.1	Idee	92
20.2.2	Ziehen mit Zurücklegen	92
20.2.3	Ziel	92
20.3	19.3 Bootstrap	93
20.3.1	Grundidee	93
20.3.2	Ablauf des Bootstrap	93
20.3.3	Bootstrap-Konfidenzintervall	94
20.3.4	Vorteile des Bootstrap	94
20.3.5	Nachteile	95
20.3.6	Typische Anwendungen	95
20.3.7	R-Code	95
20.4	19.4 Randomisierungstests (Permutationstests)	100
20.4.1	Grundidee	100
20.4.2	Idee der Nullhypothese	101
20.4.3	Ablauf	101
20.4.4	p-Wert	101
20.4.5	Vorteile	101
20.4.6	Einfacher Permutationstest für Mittelwertsdifferenz	102
20.5	19.5 Unterschied Bootstrap vs. Randomisierungstest	103
20.6	19.6 Non-parametrische Tests	103
20.6.1	Grundidee	103
20.6.2	Rangbildung	103
20.6.3	Vorteile	103
20.6.4	Nachteile	104
20.6.5	R-Code	104
20.7	19.7 Wichtige non-parametrische Tests	105
20.8	19.8 Mann-Whitney-U-Test	105
20.8.1	Einsatz	105
20.8.2	Idee	105
20.8.3	Formel	105
20.8.4	Hypothesen	105
20.8.5	R-Code	106
20.9	19.9 Wilcoxon-Test	106
20.9.1	Einsatz	106
20.9.2	Idee	107
20.9.3	R-Code	107

20.1019.10	Kruskal-Wallis-Test	108
20.10.1	Einsatz	108
20.10.2	Idee	108
20.10.3	Formel	108
20.10.4	Interpretation	108
20.1119.11	Spearman-Rangkorrelation	109
20.11.1	Einsatz	109
20.11.2	Idee	109
20.11.3	Formel	109
20.12	Rangkorrelation direkt über Ränge	110
20.13	Signifikanztest	110
20.1419.14	Wann welches Verfahren?	110
21	20. Kritik am NHST (Vertiefung)	111
21.1	20.1 Grundidee der Kritik	111
21.2	20.2 Zentrale Fehlinterpretationen des p-Werts	111
21.3	20.3 Probleme des NHST	112
21.3.1	20.3.1 Dichotomes Denken	112
21.3.2	20.3.2 Abhängigkeit von der Stichprobengröße	113
21.3.3	20.3.4 Unrealistische Nullhypothesen	113
21.3.4	20.3.4 Signifikanz $\neq$ praktische Relevanz	114
21.3.5	20.3.5 Replikationskrise	114
21.3.6	20.3.6 Positive Predictive Value (PPV)	115
21.3.7	20.3.7 Publication Bias / File Drawer Problem	116
21.4	20.4 Kritik von Wasserstein et al. (2019)	116
22	21 Verbesserungen innerhalb des NHST	116
22.1	Exkurs: Geoff Cumming und die „New Statistics“	117
22.2	21.1 Effektgrößen berichten	117
22.2.1	Grundidee:	117
22.2.2	Warum sind Effektgrößen wichtig?	118
22.2.3	Beispiele für Effektgrößen	118
22.2.4	R-Code	118
22.2.5	Umrechnung von Effektgrößen	126
22.3	21.2 Konfidenzintervalle berichten	127
22.3.1	Grundidee:	127
22.3.2	Konfidenzintervalle zeigen:	127
22.4	21.3 Poweranalysen durchführen	127
22.4.1	Problem	127
22.4.2	Lösung: Poweranalyse	127
22.4.3	R-Code: Poweranalysen	128
22.5	21.4 Shannon-Information / s -Wert	135
22.5.1	21.4.1 Formel	135

22.5.2	21.4.2 Interpretation	135
22.5.3	21.4.3 Beispiele	136
22.5.4	21.4.4 Warum ist das sinnvoll?	136
22.5.5	21.4.5 Wichtig	136
22.5.6	R-Code: Shannon-Information berechnen	137
22.5.7	21.4.6 Zusammenhang mit NHST-Kritik	138
22.6	21.5 Weitere moderne erweiterungen des NHST	138
22.6.1	21.5.1 Second-Generation-p-values	138
22.6.2	21.5.2 Grundidee der SGPV	139
22.6.3	21.5.3 Interpretation	139
22.6.4	Vorteil	140
22.6.5	Nachteil	140
22.6.6	21.5.4 Likelihood-Ansätze	140
22.7	21.6 Open Science	142
22.7.1	21.6.1 Präregistrierung und Replikation	142
22.8	21.7 Meta-Analysen	143
23	22 Alternativen zu NHST (Bayesianische Statistik)	143
23.1	22.1 Grundidee	143
23.1.1	Unterschiedlicher Wahrscheinlichkeitsbegriff	144
23.2	22.2 Bedingte Wahrscheinlichkeit	144
23.3	22.3 Bayes-Theorem	144
23.4	22.4 Prior-Verteilung	145
23.4.1	Noninformative Prior	145
23.4.2	Informative Prior	145
23.4.3	Sensitivitätsanalyse	146
23.5	22.5 Likelihood	146
23.6	22.6 Posterior-Verteilung	147
23.7	22.7 Posterior Mean	147
23.8	22.8 Credible Interval / Posterior Probability Interval	147
23.8.1	Posterior Predictive Checking	148
23.9	22.9 Unterschied zum Konfidenzintervall	148
23.10	22.10 Einfluss des Priors	148
23.10.1	Große Stichprobe	149
23.10.2	Kleine Stichprobe	149
23.10.3	Misspezifizierter Prior	149
23.11	22.11 MCMC-Verfahren	149
23.12	22.12 Vorteile	150
23.12.1	Vorwissen integrierbar	150
23.12.2	Updating Knowledge	150
23.12.3	Direkte Wahrscheinlichkeitsaussagen	150
23.12.4	Kleinere Stichproben möglich	150
23.12.5	Flexibel	150

23.1322.13 Kritik	150
23.13.1 Subjektivität des Priors	150
23.13.2 Hoher Rechenaufwand	151
23.13.3 Sensitivität	151
23.1422.14 Vergleich Frequentismus vs. Bayes	151
24 23. Gute wissenschaftliche Praxis / Wissenschaftlicher Forschungsprozess	151
24.1 23.1 Grundprinzip	151
24.1.1 ATOM-Prinzip	151
24.2 23.2 Regeln guter wissenschaftlicher Praxis	152
24.3 23.3 Präregistrierung	152
24.3.1 Grundidee	152
24.3.2 Vorteile	152
24.4 23.4 Idealer Forschungsprozess	153
24.5 23.5 Konfidenzintervall und Effektgrößen	153
24.6 23.6 Open Science	153
24.6.1 Ziele	153
24.6.2 Open Science Framework (OSF)	153
24.7 23.7 Replikationen	154
24.7.1 Warum wichtig?	154
24.7.2 Arten	154

1 Inferenzstatistik und NHST

Version: v1.0 Letzte Aktualisierung: 01.06.2026

[1] "2026-06-10"

1.1 Öffentliche Beispieldaten für alle Beispiele

Die folgenden Beispiele verwenden keine Uni-Datensätze, sondern einen reproduzierbaren synthetischen Datensatz. Dadurch kann der Lernzettel öffentlich geteilt werden.

```
set.seed(123)

demo <- data.frame(
  gruppe = rep(c("Kontrolle", "Intervention"), each = 40),
  score = c(
    rnorm(40, mean = 100, sd = 15),
    rnorm(40, mean = 108, sd = 15)
  )
)
```

```
)  
)
```

```
head(demo)
```

```
      gruppe      score  
1 Kontrolle  91.59287  
2 Kontrolle  96.54734  
3 Kontrolle 123.38062  
4 Kontrolle 101.05763  
5 Kontrolle 101.93932  
6 Kontrolle 125.72597
```

Zusätzlich werden einzelne öffentliche R-Datensätze genutzt:

```
data(mtcars)  
data(PlantGrowth)
```

```
head(mtcars)
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

```
head(PlantGrowth)
```

```
      weight group  
1    4.17  ctrl  
2    5.58  ctrl  
3    5.18  ctrl  
4    6.11  ctrl  
5    4.50  ctrl  
6    4.61  ctrl
```

2 1. Grundidee der Inferenzstatistik

2.1 Ziel

Von **Stichprobe** → **Population** schließen

2.2 Problem

- Stichproben sind zufällig verzerrt
- Ergebnisse schwanken
- Stichprobe → Population → Stichprobenfehler

2.3 Warum funktioniert es trotzdem?

- Stichprobenwerte streuen **systematisch um den wahren Wert**
- richtige Werte treten häufiger auf als extreme

2.4 Lösung

- Wahrscheinlichkeitstheorie
- Stichprobenverteilungen
- Konfidenzintervalle
- Signifikanztests

3 2. Grundbegriffe

3.1 Population vs. Stichprobe

- Population = Gesamtheit aller Fälle
- Stichprobe = Teilmenge

3.2 Parameter vs. Statistik

Population	Stichprobe
μ, σ, p	$\bar{x}, s, \hat{p}$

→ Statistik = Schätzung eines Parameters

3.3 Stichprobentypen

- unabhängig → getrennte Gruppen
- abhängig → Messwiederholung / Paare

abhängig → geringere Varianz → höhere Power

4 3. Wahrscheinlichkeit

4.1 Subjektive Wahrscheinlichkeit

- persönliche Einschätzung
- Erfahrung / Intuition

4.2 Klassische Wahrscheinlichkeit

$$P(A) = \frac{\text{günstige Fälle}}{\text{mögliche Fälle}}$$

z.B. Würfel, Münze

4.3 Frequentistische Wahrscheinlichkeit

- basiert auf relativen Häufigkeiten
- Grundlage der Inferenzstatistik

4.4 Relative Häufigkeit

$$P(A) = \frac{n(A)}{n}$$

4.5 Konjunktion

$$P(A \cap B)$$

→ Wahrscheinlichkeit, dass A und B gemeinsam auftreten

Wichtig:

$$P(A \cap B) \leq P(A)P(A \cap B) \leq P(B)$$

4.6 Bedingte Wahrscheinlichkeit

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

4.7 Unabhängigkeit

$$P(A|B) = P(A)$$

4.8 Produktregel

$$P(A \cap B) = P(A) \cdot P(B)$$

→ gilt nur bei Unabhängigkeit

5 4. Stichprobenverteilung

5.1 Definition

Verteilung einer Statistik über viele Stichproben

5.2 Empirische Stichprobenverteilung

- entsteht durch Simulation / viele Ziehungen

5.3 Theoretische Stichprobenverteilung

- mathematisch hergeleitet
- Grundlage für Konfidenzintervalle und Signifikanztest

5.4 Erwartungswert

$$E(\bar{x}) = \mu$$

→ unverzerrter Schätzer / unbiased estimator, da langfristiger Durchschnitt aller möglichen Stichprobenmittelwerte

5.4.1 Eigenschaften guter Schätzer

Unverzerrtheit

Ein Schätzer ist unverzerrt, wenn sein Erwartungswert genau dem wahren Parameter entspricht:

$$E(\hat{\theta}) = \theta$$

→ trifft im Mittel den wahren Parameter

Konsistenz

Ein Schätzer ist konsistent, wenn er mit wachsendem Stichprobenumfang immer näher am wahren Parameter liegt.

$$n \uparrow \Rightarrow \hat{\theta} \rightarrow \theta$$

→ größere Stichprobe = bessere Schätzung

5.5 Varianz & Standardfehler

Varianz der Stichprobenverteilung des Mittelwertes:

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}$$

Standardfehler des Mittelwertes, wenn σ bekannt:

$$SE_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$$

Da σ in der Praxis meist nicht bekannt, verwendet man:

$$SE_{\bar{x}} = \frac{s}{\sqrt{n}}$$

```
# Mit einzelnen Werten
x <- c(12, 15, 18, 20, 25)

sd(x) / sqrt(length(x))
```

```
[1] 2.213594
```

→ berechnet den Standardfehler der Werte in **x**

```
# Mit Datensatz
sd(mtcars$mpg) / sqrt(length(mtcars$mpg))
```

```
[1] 1.065424
```

→ berechnet den Standardfehler des Mittelwerts der Variable **mpg** (Meilen pro Gallone) aus dem Datensatz **mtcars**

Standardfehler eines Anteils, praktisch nutzt man oft $\hat{p}$, statt p , weil der wahre Anteil unbekannt ist:

$$SE_{\hat{p}} = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

5.5.1 Zusammenhang der Schreibweisen

Der Standardfehler entspricht der geschätzten Standardabweichung der Stichprobenverteilung. Deshalb werden häufig beide Schreibweisen verwendet:

$$SE_{\bar{X}} = \hat{\sigma}_{\bar{X}} = \frac{s}{\sqrt{n}}$$

5.5.2 Formal

Die theoretische Standardabweichung der Stichprobenverteilung wäre:

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

Da σ unbekannt ist, schätzt man:

$$\hat{\sigma}_{\bar{X}} = \frac{s}{\sqrt{n}}$$

Und genau das nennt sich:

$$SE_{\bar{X}} = \frac{s}{\sqrt{n}}$$

5.6 Bedeutung des Standardfehlers

- Streuung der **Stichprobenverteilung**, nicht der Daten
- misst die **Unsicherheit des Schätzers**
- bestimmt die Breite von Konfidenzintervallen

5.7 Konsequenzen

- $n \uparrow \Rightarrow SE \downarrow \Rightarrow$ präziser

→ größere Stichproben liefern präzisere Schätzungen

- $\sigma \uparrow \Rightarrow SE \uparrow$

→ stärkere Datenstreuung erhöht die Unsicherheit

5.7.1 Reminder Standardabweichung vs. Standardfehler:

Standardabweichung = Streuung der Daten

Standardfehler = Streuung der Stichprobenstatistik bzw. des Schätzers (gemeint ist Mittelwert, Anteil, Regressionskoeffizient, etc.)

$n \uparrow \Rightarrow SE \downarrow \rightarrow SD$ wird dadurch nicht automatisch kleiner

Die Daten selbst streuen weiterhin gleich stark.

Nur die Unsicherheit der Schätzung sinkt.

6 5. Zentrale Sätze

6.1 Gesetz der großen Zahlen

Mit wachsendem Stichprobenumfang nähert sich der Stichprobenmittelwert dem wahren Populationsmittelwert an.

$$\bar{x} = \mu$$

- große Stichprobe $\rightarrow$ stabilere Schätzung
- Zufallsschwankungen gleichen sich aus
- Annäherung, aber nicht zwingend monoton

6.2 Zentraler Grenzwertsatz

Die Stichprobenverteilung des Mittelwerts wird für großes n näherungsweise normalverteilt.

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

- gilt asymptotisch für großes n
- unabhängig von der Verteilung der Rohdaten (bei ausreichend großem n)
- Grundlage vieler Signifikanztests und Konfidenzintervalle

7 6. Verteilungen

7.1 Normalverteilung

$$X \sim N(\mu, \sigma^2)$$

- symmetrisch
- Glockenform
- Mittelwert = Median = Modus

7.2 Funktionen der Normalverteilung

7.2.1 Dichtefunktion mit `dnorm()`

```
dnorm(0)
```

```
[1] 0.3989423
```

→ Höhe der Normalverteilung an der Stelle $x = 0$

Mit eigener Verteilung:

```
dnorm(100, mean = 100, sd = 15)
```

```
[1] 0.02659615
```

7.3 Wahrscheinlichkeit mit `pnorm()`

```
pnorm(1.96)
```

```
[1] 0.9750021
```

→ Wahrscheinlichkeit für Werte kleiner oder gleich 1.96

Mit Mittelwert und Standardabweichung:

```
pnorm(130, mean = 100, sd = 15)
```

```
[1] 0.9772499
```

7.4 Quantile mit qnorm()

```
qnorm(0.975)
```

```
[1] 1.959964
```

→ kritischer z-Wert für ein 95%-Konfidenzintervall

Mit eigener Verteilung:

```
qnorm(0.95, mean = 100, sd = 15)
```

```
[1] 124.6728
```

7.5 Zufallszahlen mit rnorm()

```
rnorm(5)
```

```
[1] 0.005764186 0.385280401 -0.370660032 0.644376549 -0.220486562
```

→ erzeugt 5 Zufallszahlen aus der Standardnormalverteilung

Mit eigener Verteilung:

```
rnorm(5, mean = 100, sd = 15)
```

```
[1] 104.97673 116.45259 106.52772 95.11103 117.23211
```

7.5.1 68-95-99 Regel

- $\mu \pm 1\sigma \rightarrow 68\%$
- $\mu \pm 2\sigma \rightarrow 95\%$
- $\mu \pm 3\sigma \rightarrow 99.7\%$

7.6 Standardisierung

Für Populationen:

$$z = \frac{x - \mu}{\sigma}$$

→ gibt Abstand in Standardabweichungen an

Praktisch benutzt man für Stichprobendaten oft:

$$z = \frac{x - \mu}{s}$$

7.7 Standardnormalverteilung

$$Z \sim N(0, 1)$$

- Mittelwert 0
- Standardabweichung 1
- entsteht durch Standardisierung

7.8 t-Verteilung

- breitere Tails als Normalverteilung
- berücksichtigt zusätzliche Unsicherheit
- symmetrisch um 0
- Form abhängig von Freiheitsgraden df

7.8.1 Warum t statt z?

- σ meist unbekannt
- wird durch Stichprobe geschätzt
- für großes n : $t \rightarrow z$

7.8.2 Eigenschaften der t-Verteilung

- kleines $n \rightarrow$ große Unterschiede zur Normalverteilung, breiter
- großes $n \rightarrow$ Annäherung an Normalverteilung

7.9 Freiheitsgrade

für t-Tests für einen Mittelwert

$$df = n - 1$$

```
dt(x, df)
pt(x, df)
qt(p, df)
rt(n, df)
```

7.10 Binomialverteilung

- diskrete Verteilung
- Anzahl Erfolge in n unabhängigen Bernoulli-Experimenten

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$E(X) = np$$

$$\text{Var}(X) = np(1 - p)$$

7.10.1 Wahrscheinlichkeit für genau x Erfolge mit `dbinom()`

```
dbinom(5, size = 10, prob = 0.5)
```

```
[1] 0.2460938
```

→ Wahrscheinlichkeit, bei 10 Würfeln genau 5-mal Kopf zu erhalten

7.10.2 Kumulative Wahrscheinlichkeit mit `pbinom()`

```
pbinom(5, size = 10, prob = 0.5)
```

```
[1] 0.6230469
```

→ Wahrscheinlichkeit, höchstens 5-mal Kopf zu erhalten

7.10.3 Quantile mit `qbinom()`

```
qbinom(0.95, size = 10, prob = 0.5)
```

```
[1] 8
```

→ kleinste Anzahl an Erfolgen, bei der mindestens 95 % der Verteilung erreicht werden

7.10.4 Zufallszahlen mit `rbinom()`

```
rbinom(10, size = 10, prob = 0.5)
```

```
[1] 7 4 6 4 5 5 4 5 7 7
```

→ simuliert 10 Experimente mit jeweils 10 Münzwürfen

7.11 Normalapproximation

$$np \geq 5 \quad \text{und} \quad n(1-p) \geq 5$$

→ Faustregel für die Anwendung der Normalapproximation der Binomialverteilung

7.12 Beispiel

```
n <- 100
p <- 0.5

mu <- n * p
sigma <- sqrt(n * p * (1 - p))

mu
```

```
[1] 50
```

```
sigma
```

```
[1] 5
```

→ Erwartungswert = 50 → Standardabweichung = 5

7.12.1 Wahrscheinlichkeit näherungsweise berechnen

Gesucht:

- Wahrscheinlichkeit für höchstens 60 Köpfe

```
pnorm(60, mean = 50, sd = 5)
```

```
[1] 0.9772499
```

7.13 Stetigkeitskorrektur

Da die Binomialverteilung diskret und die Normalverteilung stetig ist, verwendet man oft eine Stetigkeitskorrektur.

Beispiel:

```
pnorm(60.5, mean = 50, sd = 5)
```

```
[1] 0.9821356
```

→ bessere Approximation für:

```
pbinom(60, size = 100, prob = 0.5)
```

```
[1] 0.9823999
```

8 7. Konfidenzintervalle

Grundidee: Geben einen plausiblen Bereich für den Populationsparameter an

Der Standardfehler entspricht der geschätzten Standardabweichung der Stichprobenverteilung.

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

8.1 Allgemeine Form

Schätzer $\pm$ (kritischer Wert $\cdot SE$)

- kritischer Wert = z- oder t-Wert
- abhängig vom Konfidenzniveau

8.2 Mittelwert (wichtig!)

$$\bar{x} \pm t_{\alpha/2, df} \cdot \frac{s}{\sqrt{n}}$$

8.3 Anteil

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

8.4 Zusammenhang mit Alpha

Konfidenz $1 - \alpha$

Beispiele:

- 95%-KI $\leftrightarrow \alpha = 0.05$
- 99%-KI $\leftrightarrow \alpha = 0.01$

8.5 Einflussfaktoren auf die Breite

- $n \uparrow \Rightarrow$ Intervall schmaler
- Konfidenz $\uparrow \Rightarrow$ Intervall breiter
- Streuung $\uparrow \Rightarrow$ Intervall breiter
- Breites KI: hohe Unsicherheit
- Schmales KI: präzisere Schätzung

8.6 Freiheitsgrade

$$df = n - 1$$

8.7 Interpretation

korrekt:

„X% der Intervalle enthalten μ “

falsch:

„ μ liegt mit X% Wahrscheinlichkeit im Intervall“

8.8 Zusammenhang mit Tests

- H im Intervall → **nicht** signifikant
- H außerhalb → **signifikant**

→ mathematisch äquivalent

→ auf gleichem Niveau α

8.9 R-Code

8.9.1 Konfidenzintervall für den Mittelwert mit `CI()`

```
library(Rmisc)
```

Loading required package: lattice

Loading required package: plyr

```
x <- c(12, 15, 18, 20, 25)
```

```
CI(x)
```

```
      upper      mean      lower  
24.14592 18.00000 11.85408
```

→ berechnet das Konfidenzintervall für den Mittelwert

8.9.2 Konfidenzintervall über `t.test()`

```
x <- c(12, 15, 18, 20, 25)
```

```
t.test(x)$conf.int
```

```
[1] 11.85408 24.14592  
attr(,"conf.level")  
[1] 0.95
```

→ gibt das 95%-Konfidenzintervall des Mittelwerts zurück

8.9.3 Konfidenzintervall für einen Anteil mit `prop.test()`

Beispiel:

- 45 Erfolge
- 100 Versuche

```
prop.test(45, 100)$conf.int
```

```
[1] 0.3514281 0.5524574  
attr(,"conf.level")  
[1] 0.95
```

→ approximatives Konfidenzintervall für einen Anteil

8.9.4 Exaktes Konfidenzintervall mit `binom.test()`

```
binom.test(45, 100)$conf.int
```

```
[1] 0.3503202 0.5527198  
attr(,"conf.level")  
[1] 0.95
```

→ exaktes Konfidenzintervall für einen Anteil

8.9.5 Unterschied

Funktion	Verfahren
<code>prop.test()</code>	approximativ (Normalapproximation)
<code>binom.test()</code>	exakt (Binomialverteilung)

`binom.test()` ist besonders bei kleinen Stichproben sinnvoll.

9 8. Signifikanztests (NHST)

Ziel: Prüfen, ob beobachtete Abweichungen noch durch Zufall erklärbar sind

9.1 Nullhypothese H_0

beschreibt meist:

- keinen Effekt
- keinen Unterschied
- keinen Zusammenhang

Beispiele:

$$\mu_1 = \mu_2$$

$$r = 0$$

$$p = 0.5$$

9.2 Alternativhypothese H_1

beschreibt meist:

- Effekt vorhanden
- Unterschied vorhanden
- Zusammenhang vorhanden

9.3 typische Annahmen parametrischer Tests

- metrische Daten
- (annähernd) Normalverteilung oder großes n
- unabhängige Beobachtungen

9.4 Einseitig vs. zweiseitig

- zweiseitig: $H_1 : \mu \neq \mu_0$
- einseitig: $H_1 : \mu > \mu_0$ oder $\mu < \mu_0$

Unterschied:

- zweiseitig $\rightarrow$ Effekt in beide Richtungen möglich
- einseitig $\rightarrow$ nur eine Richtung getestet
- einseitig $\rightarrow$ mehr Power (nur bei vorheriger Festlegung, sonst wäre es p-Hacking!)

9.5 Teststatistik

$$t = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

9.6 Entscheidungsregel

$$p \leq \alpha \Rightarrow \text{signifikant}$$

$$|t| > t_{\text{krit}} \Rightarrow \text{signifikant}$$

$\rightarrow$ äquivalent

9.7 Kritischer Wert

Grenzwert der Testverteilung

Abhängig von:

- α
- Freiheitsgraden
- ein-/zweiseitigem Test

9.8 p-Wert

$$p = p(\text{Daten oder extreme} \mid H_0)$$

→ Wie extrem sind meine Daten, **wenn H stimmt?**

- p Wahrscheinlichkeit für H
- p Effektgröße
- p Replizierbarkeit

9.9 t vs. z

- bekannt → z-Verteilung
- unbekannt → t-Verteilung (**Standardfall**)

10 9. Fehler & Power

10.1 Fehlerarten

10.1.1 Fehler 1. Art

\$ \$

→ H_0 ablehnen, obwohl sie wahr ist

→ falsch positiv

10.1.2 Fehler 2. Art

\$ \$

→ H_0 beibehalten, obwohl sie falsch ist → falsch negativ

10.2 Zusammenhang

- $\alpha \downarrow \Rightarrow \beta \uparrow$

10.3 Power

$$\text{Power} = 1 - \beta$$

→ Wahrscheinlichkeit, echten Effekt zu entdecken

10.4 Einflussfaktoren

- Stichprobengröße (**wichtigster Hebel**)
- Effektgröße
- Streuung
- Signifikanzniveau

10.4.1 Wichtig

Große Stichproben können winzige Effekte signifikant machen, deshalb zusätzlich betrachten:

- Effektgröße
- Konfidenzintervall
- praktische Relevanz

11 10. Effektgröße / Cohen's d

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s}$$

11.1 Interpretation

- 0.2 → klein
- 0.5 → mittel
- 0.8 → groß

Wichtig:

Signifikanz praktische Relevanz

12 11. Fisher vs. Neyman-Pearson

12.1 Fisher

- p-Wert als Evidenz gegen H_0
- Fokus auf Signifikanz

12.2 Neyman-Pearson

- Entscheidung zwischen H_0 und H_1
- Fokus auf Fehlerarten, Power, Entscheidungsregeln

13 12. Gesamtzusammenhang

→ Zufallsstichprobe → Stichprobenstatistik
→ Stichprobenverteilung
→ Standardfehler
→ Konfidenzintervall / Teststatistik → Inferenz über Population → Signifikanztest

13.1 Gesamtidee

Inferenzstatistik = Schätzen + Testen + Entscheiden unter Unsicherheit

13.2 Grundformel der Signifikanz

$$t = \frac{\text{Effekt}}{\text{Streuung}}$$

13.2.1 Signifikanz entsteht durch:

- großen Effekt
- kleine Streuung
- großes n

14 13. t-Tests

14.1 Überblick

Es gibt drei wichtige Arten von t-Tests:

Test	Zweck
Einstichproben-t-Test	Mittelwert vs. vorgegebener Wert
t-Test für unabhängige Stichproben	Vergleich zweier unabhängiger Gruppen
t-Test für abhängige Stichproben	Vergleich verbundener Messungen

14.2 13.1 t-Test für unabhängige Stichproben

14.2.1 Ziel

Vergleich zweier unabhängiger Gruppenmittelwerte

14.2.2 Voraussetzungen

- unabhängige Gruppen
- metrische Daten
- Normalverteilung
- Varianzhomogenität (sonst: Welch-Test)

Beispiele:

- Therapie vs. Kontrollgruppe
- Männer vs. Frauen

14.2.3 Nullhypothese

$$H_0 : \mu_A = \mu_B$$

bzw.

$$\mu_A - \mu_B = 0$$

14.2.4 Alternativhypothese

14.2.4.1 ungerichtet

$$H_1 : \mu_A \neq \mu_B$$

14.2.4.2 gerichtet

$$H_1 : \mu_A > \mu_B$$

oder

$$H_1 : \mu_A < \mu_B$$

14.2.5 Warum halbiert sich der p-Wert?

Beim gerichteten Test:

- nur eine Seite der Verteilung relevant
- gesamte Alpha-Fehlerfläche auf einer Seite

Dadurch:

- p-Wert halbiert sich
- mehr Power

Der t-Wert bleibt gleich:

- Daten ändern sich nicht
- nur Bewertungsregel ändert sich

Die vereinfachte Prüfgröße für den Fall der Annahme eines Gruppenunterschieds von 0 in der Nullhypothese berechnet sich als:

$$\mu_A - \mu_B = 0$$

und somit:

$$t = \frac{\bar{x}_A - \bar{x}_B}{SE_{\bar{x}_A - \bar{x}_B}}$$

14.2.6 Varianzhomogenität annehmen

14.2.6.1 Vergleich zweier Gruppen

```
t.test(weight ~ group,  
       data = subset(PlantGrowth,  
                     group %in% c("ctrl", "trt1")),  
       var.equal = TRUE)
```

Two Sample t-test

data: weight by group

t = 1.1913, df = 18, p-value = 0.249

alternative hypothesis: true difference in means between group ctrl and group trt1 is not equal to 0

95 percent confidence interval:

-0.2833003 1.0253003

sample estimates:

mean in group ctrl	mean in group trt1
5.032	4.661

→ vergleicht die Mittelwerte der Gruppen "ctrl" und "trt1"

14.2.6.2 Bedeutung von var.equal = TRUE

```
var.equal = TRUE
```

→ nimmt gleiche Varianzen in beiden Gruppen an

Das entspricht dem klassischen Student-t-Test.

14.3 13.2 Welch-Test

Korrektur für ungleiche Varianzen

Eigenschaften:

- robuster gegenüber Varianzheterogenität
- leicht geringere Power
- Standard in R

14.3.1 Prüfgröße

$$t = \frac{(\bar{x}_A - \bar{x}_B) - (\mu_A - \mu_B)}{SE_{\bar{x}_A - \bar{x}_B}}$$

14.3.2 Standardfehler des Mittelwertsunterschieds

Für unabhängige Gruppen:

$$SE_{\bar{x}_A - \bar{x}_B} = \sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}$$

14.3.3 Freiheitsgrade:

Bei gleichen Varianzen:

$$df = n_A + n_B - 2$$

Beim Welch-Test:

- korrigierte Freiheitsgrade
- häufig Kommazahlen

14.3.4 Interpretation des t-Werts

- standardisierter Mittelwertsunterschied
- Effekt relativ zur Streuung

Großer Betrag von t :

→ stärkere Evidenz gegen H_0

14.3.5 Zusammenhang

$$|t| \uparrow \Rightarrow p \downarrow$$

14.3.6 Durchführung in R

```
t.test(weight ~ group,
       data = subset(PlantGrowth,
                     group %in% c("ctrl", "trt1")))
```

Welch Two Sample t-test

```
data: weight by group
t = 1.1913, df = 16.524, p-value = 0.2504
alternative hypothesis: true difference in means between group ctrl and group trt1 is not equal to 0
95 percent confidence interval:
 -0.2875162  1.0295162
sample estimates:
mean in group ctrl mean in group trt1
      5.032          4.661
```

→ vergleicht die Mittelwerte der Gruppen "ctrl" und "trt1"

14.3.6.1 Gerichtete Tests

Gruppe 1 größer als Gruppe 2

```
t.test(weight ~ group,
       data = subset(PlantGrowth,
                     group %in% c("ctrl", "trt1")),
       alternative = "greater")
```

Welch Two Sample t-test

```
data: weight by group
t = 1.1913, df = 16.524, p-value = 0.1252
alternative hypothesis: true difference in means between group ctrl and group trt1 is greater than 0
95 percent confidence interval:
 -0.1716743      Inf
sample estimates:
mean in group ctrl mean in group trt1
      5.032          4.661
```

→ prüft, ob Gruppe 1 einen größeren Mittelwert besitzt

Gruppe 1 kleiner als Gruppe 2

```
t.test(weight ~ group,
       data = subset(PlantGrowth,
                     group %in% c("ctrl", "trt1")),
       alternative = "less")
```

Welch Two Sample t-test

data: weight by group

t = 1.1913, df = 16.524, p-value = 0.8748

alternative hypothesis: true difference in means between group ctrl and group trt1 is less than 0

95 percent confidence interval:

-Inf 0.9136743

sample estimates:

mean in group ctrl	mean in group trt1
5.032	4.661

→ prüft, ob Gruppe 1 einen kleineren Mittelwert besitzt

Argument	Bedeutung
"two.sided"	zweiseitiger Test
"greater"	Gruppe 1 größer
"less"	Gruppe 1 kleiner

14.3.6.2 Mittelwertsunterschied in H_0

Standardmäßig testet `t.test()`, ob der Mittelwertsunterschied 0 ist.

$$H_0 : \mu_A - \mu_B = 1$$

statt nur 0

```
t.test(weight ~ group,
       data = subset(PlantGrowth,
                     group %in% c("ctrl", "trt1")),
       mu = 1)
```

Welch Two Sample t-test

```
data: weight by group
t = -2.0197, df = 16.524, p-value = 0.05994
alternative hypothesis: true difference in means between group ctrl and group trt1 is not equal to 0
95 percent confidence interval:
 -0.2875162  1.0295162
sample estimates:
mean in group ctrl mean in group trt1
          5.032          4.661
```

→ testet, ob sich die Mittelwerte der Gruppen um genau 1 unterscheiden

14.4 13.2 t-Test für abhängige Stichproben

14.4.1 Ziel

Vergleich verbundener Messungen

Beispiele:

- Vorher-Nachher-Messung
- dieselben Personen zweimal getestet
- Matching

14.4.2 Voraussetzungen

- abhängige Messungen
- metrische Daten
- Normalverteilung der Differenzwerte

14.4.3 Idee

Nicht die Rohwerte werden verglichen, sondern die Differenzwerte

$$x_{diff} = x_A - x_B$$

14.4.4 Nullhypothese

$$H_0 : \mu_{diff} = 0$$

14.4.5 Prüfgröße

$$t = \frac{\bar{x}_{diff}}{SE_{\bar{x}_{diff}}}$$

14.4.6 Standardfehler

$$SE_{\bar{x}_{diff}} = \frac{s_{diff}}{\sqrt{n}}$$

14.4.7 Freiheitsgrade

$$df = n - 1$$

14.4.8 Einfluss der Korrelation

hohe positive Korrelation zwischen Messungen:

- kleinere Fehlervarianz
- größerer t-Wert
- höhere Power

14.4.9 Durchführung in R

14.4.9.1 Beispiel mit `mtcars`

Wir vergleichen den Verbrauch desselben Autos in zwei verschiedenen Einheiten:

- `mpg` = miles per gallon
- `mpg * 0.425` alternative Verbrauchsskala

```
head(mtcars[, c("mpg")])
```

```
[1] 21.0 21.0 22.8 21.4 18.7 18.1
```

Zwei abhängige Messreihen erzeugen

```
x1 <- mtcars$mpg  
x2 <- mtcars$mpg * 0.425
```

14.4.9.2 Gepaarter t-Test

```
t.test(x1, x2, paired = TRUE)
```

Paired t-test

```
data: x1 and x2  
t = 18.857, df = 31, p-value < 2.2e-16  
alternative hypothesis: true mean difference is not equal to 0  
95 percent confidence interval:  
 10.30267 12.80155  
sample estimates:  
mean difference  
 11.55211
```

→ vergleicht die Mittelwerte zweier abhängiger Messungen

14.4.9.3 Gerichtete Tests

Gruppe 1 größer als Gruppe 2

```
t.test(x1, x2,  
       paired = TRUE,  
       alternative = "greater")
```

Paired t-test

```
data: x1 and x2  
t = 18.857, df = 31, p-value < 2.2e-16  
alternative hypothesis: true mean difference is greater than 0  
95 percent confidence interval:  
 10.5134      Inf  
sample estimates:
```

```
mean difference
    11.55211
```

→ prüft, ob die erste Messung im Mittel größer ist

Gruppe 1 kleiner als Gruppe 2

```
t.test(x1, x2,
       paired = TRUE,
       alternative = "less")
```

Paired t-test

```
data:  x1 and x2
t = 18.857, df = 31, p-value = 1
alternative hypothesis: true mean difference is less than 0
95 percent confidence interval:
    -Inf 12.59082
sample estimates:
mean difference
    11.55211
```

→ prüft, ob die erste Messung im Mittel kleiner ist

14.5 13.3 Einstichproben-t-Test

14.5.1 Ziel

Vergleich eines Stichprobenmittelwertes mit einem festen Wert

14.5.2 Voraussetzungen

- metrische Daten
- Normalverteilung
- unabhängige Beobachtungen

14.5.3 Nullhypothese

$$H_0 : \mu = \mu_0$$

14.5.4 Prüfgröße

$$t = \frac{\bar{x} - \mu_0}{SE_{\bar{x}}}$$

14.5.5 Durchführung in R

```
t.test(mtcars$mpg, mu = 20)
```

One Sample t-test

```
data: mtcars$mpg
t = 0.08506, df = 31, p-value = 0.9328
alternative hypothesis: true mean is not equal to 20
95 percent confidence interval:
 17.91768 22.26357
sample estimates:
mean of x
 20.09062
```

→ testet, ob sich der Mittelwert von mpg signifikant von 20 unterscheidet

14.5.5.1 Gerichteter Test

Mittelwert kleiner als 20

```
t.test(mtcars$mpg,
      mu = 20,
      alternative = "less")
```

One Sample t-test

```
data: mtcars$mpg
t = 0.08506, df = 31, p-value = 0.5336
alternative hypothesis: true mean is less than 20
95 percent confidence interval:
 -Inf 21.89707
sample estimates:
```

```
mean of x
20.09062
```

→ prüft, ob der Mittelwert kleiner als 20 ist

Mittelwert größer als 20

```
t.test(mtcars$mpg,
      mu = 20,
      alternative = "greater")
```

One Sample t-test

```
data: mtcars$mpg
t = 0.08506, df = 31, p-value = 0.4664
alternative hypothesis: true mean is greater than 20
95 percent confidence interval:
 18.28418      Inf
sample estimates:
mean of x
20.09062
```

→ prüft, ob der Mittelwert größer als 20 ist

14.6 13.4 Effektgrößen bei t-Tests

14.6.1 Cohen's d mit gepoolter SD bei unabhängigen Stichproben

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{pooled}}$$

14.6.1.1 Interpretation

d	Bedeutung
0.2	klein
0.5	mittel
0.8	groß

Wichtig:

- Signifikanz abhängig von n
- Effektgröße hat praktische Relevanz
- bei großen Stichproben können winzige Effekte signifikant werden

14.6.2 Effektgröße basierend auf Differenzwerten bei abhängigen Stichproben

$$d = \frac{\bar{x}_{diff}}{s_{diff}}$$

14.7 13.5 Poweranalyse bei t-Tests

14.7.1 Ziel

Bestimmen, wie groß n sein muss, um einen Effekt zu entdecken

14.7.2 Einflussfaktoren

- Effektgröße d
- Stichprobengröße
- Signifikanzniveau α
- gewünschte Power

Größerer Effekt $\rightarrow$ höhere Power

Größeres $n \rightarrow$ höhere Power

Kleineres $\alpha \rightarrow$ geringere Power

14.7.3 Standardwert

Häufig:

$$1 - \beta = 0.80$$

$\rightarrow$ 80% Wahrscheinlichkeit, einen Effekt zu entdecken

14.8 13.6 Interpretation des p-Wertes

14.8.1 Definition

Der p-Wert ist:

Wahrscheinlichkeit für diese oder extremere Daten, wenn H_0 stimmt

$$p(\text{Daten}|H_0)$$

14.8.2 Entscheidungsregel

$$p > \alpha$$

→ nicht signifikant, H_0 beibehalten

$$p \leq \alpha$$

→ signifikant, Entscheidung für H_1

14.9 13.7 Zentrale Kritikpunkte am NHST (Kurzüberblick)

14.9.1 p-Wert ist nicht:

- Wahrscheinlichkeit für H_0
- Wahrscheinlichkeit, dass Daten “durch Zufall” entstanden
- Effektgröße
- praktische Relevanz
- Replizierbarkeit

14.9.2 Probleme

14.9.2.1 Dichotomes Denken

- signifikant vs. nicht signifikant
- künstliche Grenze

14.9.2.2 Abhängigkeit von n

- große Stichproben → leichter signifikant

14.9.2.3 Unrealistische Nullhypothesen

- exact 0 oft unrealistisch

14.10 13.8 Alternativen:

14.10.1 Obergrenze Bayes-Faktor

$$\text{Bayesfaktor } B = \frac{p(D|H_1)}{p(D|H_0)}$$

Vergleicht:

- wie gut H_1 vs. H_0 zu den Daten passt

Großer Wert: $\rightarrow$ Evidenz für H_1

14.10.1.1 Berechnung händisch

$$B \leq \bar{B} = \frac{1}{-e \cdot p \cdot \ln(p)}$$

```
1 / (-exp(1) * 0.00047 * log(0.00047))
```

```
[1] 102.146
```

$\rightarrow$ berechnet den e -Wert aus einem bereits bekannten p-Wert

14.10.1.2 Direkte Berechnung aus einem t-Test

```
t <- t.test(mtcars$mpg, mu = 20)
1 / (-exp(1) * t$p.value * log(t$p.value))
```

```
[1] 5.666104
```

$\rightarrow$ berechnet den e -Wert direkt aus dem p-Wert des Tests

14.10.1.3 Bedeutung

Der e -Wert beschreibt die maximale Evidenz gegen die Nullhypothese.

Große Werte sprechen für stärkere Evidenz gegen H_0 .

14.10.2 Shannon-Information (s-Wert)

$$S = -\log_2(p)$$

14.10.3 Interpretation:

- Evidenz gegen H_0
- vergleichbar mit mehrfach “Kopf” bei Münzwurf

14.10.4 Berechnung in R

über händisches Einsetzen des p-Wertes

```
-log2(0.00047)
```

```
[1] 11.05505
```

Berechnung über Einfügen der Syntax zur Berechnung des p-Wertes (genauer)

```
t <- t.test(mtcars$mpg, mu = 20)
-log2(t$p.value)
```

```
[1] 0.1004212
```

14.11 13.9 APA-Bericht

14.11.1 Format

$$t(df) = Wert, p = Wert$$

Beispiel:

$$t(81.96) = 3.64, p < .001$$

14.11.2 Regeln

- t kursiv
- p kursiv
- zwei Nachkommastellen bei t
- drei Nachkommastellen bei p

Außerdem berichten:

- Mittelwerte
- Standardabweichungen
- Richtung des Tests

15 14. Einfaktorielle Varianzanalyse

15.1 Grundidee

Die Varianzanalyse prüft, ob sich die Mittelwerte von mehr als zwei Gruppen statistisch signifikant unterscheiden.

ANOVA = Analysis of Variance

Obwohl Mittelwerte verglichen werden, läuft der Test über Varianzen.

15.2 Wann verwendet man ANOVA?

- abhängige Variable metrisch / intervallskaliert
- unabhängige Variable kategorial mit mindestens 3 Gruppen
- Gruppen unabhängig voneinander

Beispiel:

- AV: Gefährlichkeit
- UV/Faktor: Meer mit mehreren Gruppen

15.3 Warum nicht mehrere t-Tests?

Mehrere t-Tests erhöhen die Wahrscheinlichkeit für einen Fehler 1. Art.

$$\alpha_{\text{kumuliert}} = 1 - (1 - \alpha)^j$$

mit j = Anzahl der Tests

Deshalb verwendet man bei mehr als zwei Gruppen eine ANOVA statt vieler einzelner t-Tests.

15.4 Alternative: Bonferroni-Korrektur

kontrolliert die α -Fehler-Kumulierung

$$\alpha' = \frac{\alpha}{j}$$

Nachteil:

- konservativ
- geringere Power
- höhere β -Fehler-Wahrscheinlichkeit

15.5 Hypothesen

Nullhypothese:

$$H_0 : \mu_1 = \mu_2 = \mu_3 = \dots = \mu_k$$

Alternativhypothese:

$$H_1 : \text{mindestens ein Mittelwert unterscheidet sich}$$

Wichtig: Die ANOVA ist ein Omnibus-Test.

Das bedeutet:

- sie sagt nur, ob irgendein Unterschied besteht
- sie sagt nicht, welche Gruppen sich unterscheiden
- sie sagt nicht, in welche Richtung ein Unterschied besteht
- dafür: Post-hoc-Tests oder Kontrastanalysen

15.6 Logik der ANOVA

Die ANOVA vergleicht zwei Varianzschätzungen:

1. Varianz zwischen den Gruppen
→ systematische Variation / Effekt
2. Varianz innerhalb der Gruppen
→ Fehlervarianz / unsystematische Variation

Grundidee:

- große Unterschiede zwischen Gruppen → spricht für einen Effekt
- große Streuung innerhalb Gruppen → spricht gegen einen klaren Effekt

$$F = \frac{\hat{\sigma}_{zw}^2}{\hat{\sigma}_{inn}^2}$$

15.6.1 Varianzzerlegung

Gesamtvariation wird zerlegt in:

$$QS_{gesamt} = QS_{zwischen} + QS_{innerhalb}$$

- zwischen Gruppen: systematische Variation
- innerhalb Gruppen: Fehlervariation / unsystematische Variation

15.7 F-Wert

$$F = \frac{\text{Varianz zwischen Gruppen}}{\text{Varianz innerhalb Gruppen}}$$

oder:

$$F = \frac{MS_{zwischen}}{MS_{innerhalb}}$$

Interpretation:

- $F \approx 1$: Gruppenunterschiede nicht größer als zufällige Streuung
- $F > 1$: Gruppen unterscheiden sich stärker als durch Fehlervarianz erklärbar
- je größer F , desto eher signifikant

15.8 F-Verteilung

- nur positive Werte
- rechtsschief
- abhängig von:
 - Zählerfreiheitsgraden
 - Nennerfreiheitsgraden

großes F: $\rightarrow$ spricht gegen H_0

15.9 Quadratsummen

Gesamtvariation:

$$QS_{\text{gesamt}} = QS_{\text{zwischen}} + QS_{\text{innerhalb}}$$

Bedeutung:

- QS_{zwischen} : Variation der Gruppenmittelwerte um den Gesamtmittelwert
- $QS_{\text{innerhalb}}$: Variation der Einzelwerte um ihren Gruppenmittelwert

$$QS_{\text{gesamt}} = \sum (x_{ij} - \bar{x})^2$$

15.9.1 Innerhalb Gruppen

$$QS_{\text{inn}} = \sum (x_{ij} - \bar{x}_j)^2$$

15.9.2 Zwischen Gruppen

$$QS_{\text{zw}} = \sum n_j (\bar{x}_j - \bar{x})^2$$

15.10 Freiheitsgrade

Zwischen Gruppen:

$$df_{\text{zwischen}} = k - 1$$

Innerhalb Gruppen:

$$df_{\text{innerhalb}} = N - k$$

Gesamt:

$$df_{\text{gesamt}} = N - 1$$

Dabei gilt:

- k = Anzahl der Gruppen
- N = Gesamtstichprobengröße

15.11 ANOVA-Tabelle

Quelle	QS	df	MS	F	p
zwischen Gruppen	QS_{zw}	$k - 1$	$MS_{zw} =$ QS_{zw}/df_{zw}	$F =$ MS_{zw}/MS_{inn}	p
innerhalb Gruppen	QS_{inn}	$N - k$	$MS_{inn} =$ QS_{inn}/df_{inn}		
gesamt	QS_{ges}	$N - 1$			

mit:

$$MS = \frac{QS}{df}$$

$$F = \frac{MS_{zw}}{MS_{inn}}$$

15.12 Voraussetzungen

- abhängige Variable intervallskaliert / metrisch
- unabhängige Gruppen / Beobachtungen
- Normalverteilung innerhalb der Gruppen
- Varianzhomogenität

Wichtig:

- ANOVA ist relativ robust gegenüber Verletzungen der Normalverteilung besonders bei großen und ähnlich großen Gruppen
- bei gleich großen Gruppen auch relativ robust gegenüber ungleichen Varianzen
- Unabhängigkeit ist besonders wichtig
- problematisch: ungleiche Gruppengrößen + heterogene Varianzen

15.13 Interpretation

Wenn $p \leq \alpha$:

- Ergebnis signifikant
- H_0 wird verworfen
- mindestens ein Gruppenmittelwert unterscheidet sich

Wenn $p > \alpha$:

- Ergebnis nicht signifikant
- kein ausreichender Hinweis auf Gruppenunterschiede

Nicht signifikant bedeutet nicht automatisch, dass alle Mittelwerte gleich sind.

15.14 R-Code

```
# ANOVA rechnen
modell <- aov(weight ~ group, data = PlantGrowth)

# ANOVA-Tabelle anzeigen
summary(modell)
```

```

      Df Sum Sq Mean Sq F value Pr(>F)
group      2  3.766   1.8832   4.846 0.0159 *
Residuals 27 10.492   0.3886
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

```

#Output lesen
# Df      = Freiheitsgrade
# Sum Sq  = Quadratsummen
# Mean Sq = Mittelquadrat / Varianzschätzungen
# F value = empirischer F-Wert
# Pr(>F)  = p-Wert

```

15.14.1 Welch-ANOVA

Bei verletzter Varianzhomogenität kann eine Welch-ANOVA verwendet werden.

```

oneway.test(weight ~ group,
             data = PlantGrowth,
             var.equal = FALSE)

```

One-way analysis of means (not assuming equal variances)

```

data:  weight and group
F = 5.181, num df = 2.000, denom df = 17.128, p-value = 0.01739

```

15.15 Post-hoc-Tests

Nach einer signifikanten ANOVA weiß man nur, dass irgendein Unterschied besteht.

Post-hoc-Tests prüfen anschließend, welche Gruppen sich unterscheiden.

Beispiele:

- Tukey-Test
- Scheffé-Test

Auch Bonferroni-Korrektur kann als Post-hoc-Test angewendet werden zur Kontrolle des α -Fehlers

15.15.1 Tukey-Post-hoc-Test

```
modell <- aov(weight ~ group, data = PlantGrowth)

TukeyHSD(modell)
```

Tukey multiple comparisons of means
95% family-wise confidence level

Fit: aov(formula = weight ~ group, data = PlantGrowth)

```
$group
      diff      lwr      upr      p adj
trt1-ctrl -0.371 -1.0622161 0.3202161 0.3908711
trt2-ctrl  0.494 -0.1972161 1.1852161 0.1979960
trt2-trt1  0.865  0.1737839 1.5562161 0.0120064
```

→ vergleicht alle Gruppenpaare miteinander

15.16 Effektgröße Eta-Quadrat

$$\eta^2 = \frac{QS_{\text{zwischen}}}{QS_{\text{gesamt}}}$$

Bedeutung:

Anteil der Gesamtvariation, der durch die Gruppenzugehörigkeit erklärt wird. aka Anteil erklärter Varianz

Interpretation nach Cohen:

η^2	Bedeutung
0.01	klein
0.06	mittel
0.14	groß

Alternative Formel:

$$\eta^2 = \frac{F \cdot df_{\text{zwischen}}}{F \cdot df_{\text{zwischen}} + df_{\text{innerhalb}}}$$

```
modell <- aov(weight ~ group, data = PlantGrowth)

anova_tab <- summary(modell)[[1]]

qs_zwischen <- anova_tab$`Sum Sq`[1]
qs_gesamt <- sum(anova_tab$`Sum Sq`)

qs_zwischen / qs_gesamt
```

```
[1] 0.2641483
```

15.17 Power bei ANOVA

Power hängt ab von:

- Effektgröße
- Stichprobengröße pro Gruppe
- Anzahl der Gruppen
- Signifikanzniveau α

Größeres $n \rightarrow$ höhere Power

Größerer Effekt $\rightarrow$ höhere Power

Kleineres $\alpha \rightarrow$ geringere Power

15.18 APA-Bericht

$$F(df_{zw}, df_{inn}) = Wert, p = \dots$$

Beispiel:

Eine einfaktorielle ANOVA ergab einen signifikanten Effekt des Meeres auf die Gefährlichkeit, $F(2, 81) = 8.52, p < .001$.

Berichtet werden:

- Art der ANOVA
- F-Wert
- Zähler- und Nennerfreiheitsgrade
- p-Wert

15.19 weitere Varianten

- zweifaktorielle ANOVA
- ANOVA mit Messwiederholung
- gemischte Designs

16 15. Inferenzstatistik der Korrelation

16.1 Stichprobe vs Population

Symbol	Bedeutung
r	Stichprobenkorrelation
ρ	Populationskorrelation

16.2 Ziel

Prüfen, ob sich eine Korrelation signifikant von 0 unterscheidet

Frage:

Existiert ein linearer Zusammenhang in der Population oder ist die beobachtete Korrelation nur Zufall?

16.3 Voraussetzungen

- intervallskalierte Variablen
- bivariate Normalverteilung
 - Nicht: jede Variable einzeln normalverteilt
 - sondern: gemeinsame Verteilung annähernd normal
- unabhängige Beobachtungen

Der Test ist relativ robust gegenüber kleineren Verletzungen der Normalverteilung.

Problematisch: - starke Schiefe - starke Ausreißer - nichtlineare Zusammenhänge

16.4 Hypothesen

16.4.1 Ungerichtete Hypothese

Nullhypothese:

$$H_0 : \rho = 0$$

Alternativ Hypothese

$$H_1 : \rho \neq 0$$

→ Zusammenhang kann positiv oder negativ sein

16.4.2 Gerichtete Hypothese

Positive Richtung:

$$H_1 : \rho > 0$$

Negative Richtung:

$$H_1 : \rho < 0$$

Wichtig:

- Richtung muss vorher festgelegt werden
- einseitige Tests haben mehr Power
- falsche Richtung kann zu nicht-signifikanten Ergebnissen (trotz eigentlicher Signifikanz) führen

16.5 Teststatistik

Der Signifikanztest für die Korrelation benutzt einen t-Test:

$$t = \frac{r\sqrt{n-2}}{\sqrt{1-r^2}}$$

16.6 Bedeutung der Bestandteile

Symbol	Bedeutung
r	Stichprobenkorrelation
n	Anzahl der Wertepaare
$n - 2$	Freiheitsgrade

16.7 Freiheitsgrade

$$df = n - 2$$

Warum? Bei der Schätzung:

- Mittelwert von X
- Mittelwert von Y

gehen zwei Freiheitsgrade verloren

16.8 Logik des Tests

Wenn:

- r groß
- und Stichprobe groß

dann wird:

- t groß
- p-Wert klein
- Ergebnis eher signifikant

Wenn:

- r nahe 0

dann wird: - t klein - p-Wert groß

16.9 Interpretation der Korrelation

16.9.1 Richtung

Wert	Bedeutung
$r > 0$	positiver Zusammenhang
$r < 0$	negativer Zusammenhang
$r = 0$	kein linearer Zusammenhang

16.9.2 Stärke

$ r $	Interpretation
0.1	kleiner Effekt
0.3	mittlerer Effekt
0.5	großer Effekt

(nach Cohen)

16.10 Effektgröße

Die Korrelation selbst ist bereits eine Effektgröße.

Vorteil: - unabhängig von Stichprobengröße interpretierbar

Wichtig:

- große Stichproben können kleine Korrelationen signifikant machen
- kleine Stichproben können große Korrelationen nicht-signifikant machen

16.11 Konfidenzintervall

R gibt meist ein 95%-Konfidenzintervall für r aus.

Interpretation:

- enthält das KI den Wert 0:
 - $\rightarrow$ Zusammenhang nicht signifikant
- enthält das KI den Wert 0 nicht:
 - $\rightarrow$ Zusammenhang signifikant

16.12 Unterschied t-Test vs z-Test

16.12.1 t-Test

Benutzt für:

$$H_0 : \rho = 0$$

16.12.2 z-Test

Benutzt:

- wenn gegen andere Korrelationswerte getestet wird
- oder zwei Korrelationen verglichen werden

Test mit R nicht Bestandteil des Moduls.

16.13 APA-Bericht

- r
- Freiheitsgrade
- p-Wert
- Richtung des Tests

Beispiel:

Zwischen Alter und Gefährlichkeit bestand kein signifikanter Zusammenhang,
 $r(89) = .06, p = .267$

16.14 R-Code

```
# Korrelation  
cor(mtcars$mpg,  
    mtcars$wt)
```

→ berechnet die Pearson-Korrelation zwischen Verbrauch und Gewicht

```
# Signifikanztest  
cor.test(mtcars$mpg,  
         mtcars$wt)
```

Pearson's product-moment correlation

```
data: mtcars$mpg and mtcars$wt
t = -9.559, df = 30, p-value = 1.294e-10
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9338264 -0.7440872
sample estimates:
      cor
-0.8676594
```

→ testet, ob die Korrelation signifikant von 0 verschieden ist

```
# gerichtete Hypothese
cor.test(mtcars$mpg,
         mtcars$wt,
         alternative = "greater")
```

Pearson's product-moment correlation

```
data: mtcars$mpg and mtcars$wt
t = -9.559, df = 30, p-value = 1
alternative hypothesis: true correlation is greater than 0
95 percent confidence interval:
 -0.9259151  1.0000000
sample estimates:
      cor
-0.8676594
```

→ prüft, ob die wahre Korrelation größer als 0 ist

```
# nur vollständige Fälle
cor.test(mtcars$mpg,
         mtcars$wt,
         use = "pairwise.complete.obs")
```

Pearson's product-moment correlation

```
data: mtcars$mpg and mtcars$wt
t = -9.559, df = 30, p-value = 1.294e-10
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9338264 -0.7440872
sample estimates:
      cor
-0.8676594
```

→ verwendet nur Beobachtungen ohne fehlende Werte (NA)

17 16. Inferenzstatistik der Regression

17.1 Ziel

Prüfen, ob ein Regressionsmodell signifikant Varianz erklärt.

Frage:

unterscheidet sich der Regressionskoeffizient von 0? erklärt das Gesamtmodell signifikant Varianz

17.2 Grundlagen

17.2.1 Regressionsgleichung

$$\hat{y} = a + bx$$

Symbol	Bedeutung
a	Achsenabschnitt
b	Regressionskoeffizient / Steigung
$\hat{y}$	vorhergesagter Wert

17.2.2 Interpretation von b

b gibt an:

- um wie viele Einheiten y sich verändert, wenn x um eine Einheit steigt

17.3 Hypothesen

17.3.1 Regressionskoeffizient

Nullhypothese:

$$H_0 : b = 0$$

Alternativhypothese:

$$H_1 : b \neq 0$$

17.3.2 Bedeutung

Wenn:

$$b = 0$$

dann:

- keine lineare Vorhersage möglich

Wenn:

$$b \neq 0$$

dann:

- signifikanter linearer Zusammenhang
- signifikanter Prädiktor

17.4 t-Test für den Regressionskoeffizienten

R überprüft inferenzstatistisch: unterscheidet sich b signifikant von 0?

Hinweis:

Bei multipler Regression können unterschiedliche Prädiktoren unterschiedliche p-Werte haben.

17.5 Voraussetzungen

- Linearität
- unabhängige Beobachtungen
- Homoskedastizität (Die Streuung der Residuen soll über alle vorhergesagten Werte hinweg ähnlich groß sein.)
- Normalverteilung der Residuen

17.6 Hypothesen

- Die Nullhypothese lautet: Der Regressionskoeffizient beträgt 0.
- Die Alternativhypothese lautet: Der Regressionskoeffizient ist von 0 verschieden.

17.7 Teststatistik

$$t = \frac{b}{SE_b}$$

Symbol	Bedeutung
b	geschätzter Regressionskoeffizient
SE_b	Standardfehler des Koeffizienten

17.8 Interpretation

17.8.1 Großes t :

- kleiner p-Wert
- signifikanter Prädiktor

17.8.2 Kleines t :

- großer p-Wert
- kein signifikanter Prädiktor

17.9 R-Code

```
# Modell erstellen
modell <- lm(mpg ~ wt,
             data = mtcars)
```

→ erstellt ein lineares Regressionsmodell

```
# Zusammenfassung
summary(modell)
```

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-4.5432 -2.3647 -0.1252  1.4096  6.8727
```

Coefficients:

```
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  37.2851     1.8776   19.858 < 2e-16 ***
wt           -5.3445     0.5591   -9.559 1.29e-10 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 3.046 on 30 degrees of freedom

Multiple R-squared: 0.7528, Adjusted R-squared: 0.7446

F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10

- mpg = abhängige Variable / Kriterium
- wt = unabhängige Variable / Prädiktor

17.9.1 wichtige Teile des Outputs

Teil	Bedeutung
Estimate	geschätzter Koeffizient
Std. Error	Standardfehler
t value	t-Wert
$Pr(> t)$	p-Wert
Multiple R-squared	Determinationskoeffizient

Teil	Bedeutung
F-statistic	F-Test Gesamtmodell


R gibt oft Konfidenzintervalle für Regressionskoeffizienten aus.

Enthält das KI den Wert 0 nicht:

→ Koeffizient signifikant

17.9.2 Regressionsgerade visualisieren

```
plot(mtcars$wt,
     mtcars$mpg)
abline(modell)
```



→ zeichnet die Regressionsgerade in das Streudiagramm

17.10 Zusammenhang mit Korrelation

Bei einfacher linearer Korrelation gilt:

- Test auf b
- Test auf r
- F-Test für Gesamtmodell

führen zum gleichen p-Wert.

Das gilt nur:

- bei einem einzigen Prädiktor

Nicht:

- bei multipler Regression

17.11 Residuen

Residuals = Vorhersagefehler

$$e_i = y_i - \hat{y}_i$$

→ Differenz zwischen:

- tatsächlichem Wert
- vorhergesagtem Wert

Große Residuen:

- schlechte Vorhersage

Kleine Residuen:

- gute Vorhersage

17.12 Determinationskoeffizient R^2

ist der Anteil aufgeklärter Varianz

17.12.1 Interpretation

Beispiel:

$$R^2 = 0.37$$

→ 37% der Varianz von y werden durch x erklärt.

Hohe Varianzaufklärung bedeutet nicht automatisch Kausalität.

17.12.2 Zusammenhang mit Korrelation

bei einfacher linearer Regression gilt:

$$R^2 = r^2$$

17.12.3 Varianzzerlegung

Gesamtvarianz wird zerlegt in:

$$QS_{gesamt} = QS_{Regression} + QS_{Fehler}$$

17.12.4 Regressionsquadratsumme (erklärte Variation)

$$QS_{Regression}$$

17.12.5 Fehlerquadratsumme (nicht erklärte Variation)

$$QS_{Fehler}$$

17.13 R-Code

```
modell <- lm(mpg ~ wt,  
            data = mtcars)  
  
summary(modell)$r.squared
```

[1] 0.7528328

→ gibt den Anteil erklärter Varianz des Modells zurück

17.14 APA-Bericht

Das Gewicht eines Autos war ein signifikanter negativer Prädiktor für den Verbrauch, $b = -5.34$, $p < .001$, $R^2 = .75$.

18 17. F-Test

Frage:

Erklärt das Gesamtmodell signifikant Varianz?

18.1 Teststatistik:

$$F = \frac{\sigma_{Regression}^2}{\sigma_{Fehler}^2}$$

18.2 Interpretation

Großes F :

- Modell erklärt viel Varianz
- eher signifikant

Kleines F :

- Modell erklärt kaum mehr als Zufall
- nicht signifikant

18.3 Freiheitsgrade

18.3.1 Zählerfreiheitsgrade

Anzahl der Prädiktoren:

$$df_1 = p$$

18.3.2 Nennerfreiheitsgrade

$$df_2 = n - p - 1$$

mit:

- p = Anzahl Prädiktoren
- n = Stichprobengröße

18.4 standardisierte Koeffizienten

18.4.1 Beta-Gewichte β

Vorteil:

- Variablen vergleichbar
- einheitenunabhängig

Bei z-standardisierten Variablen:

$$\beta = r$$

(gilt bei einfacher Regression)

18.5 APA-Bericht

Das Regressionsmodell war signifikant, $F(1, 30) = 91.38, p < .001, R^2 = .75$

18.6 Zusammenhang mit R^2

Ein großes F führt häufig auch zu einem großen R^2 .

- großes $F \rightarrow$ Modell erklärt viel Varianz
- kleines $F \rightarrow$ Modell erklärt kaum zusätzliche Varianz

18.7 F-Test in R

```
modell <- lm(mpg ~ wt, data = mtcars)

summary(modell)
```

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.5432	-2.3647	-0.1252	1.4096	6.8727

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.2851	1.8776	19.858	< 2e-16 ***
wt	-5.3445	0.5591	-9.559	1.29e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom

Multiple R-squared: 0.7528, Adjusted R-squared: 0.7446

F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10

Der F-Wert steht im unteren Teil der Ausgabe:

```
F-statistic: 91.38 on 1 and 30 DF
```

19 18. Chi-Quadrat-Test (χ^2)

19.1 Ziel

Analyse nominalskalierten Daten (Häufigkeiten)

Fragen:

- weichen beobachtete Häufigkeiten von erwarteten Häufigkeiten ab?
- besteht ein Zusammenhang zwischen zwei nominalskalierten Variablen?

19.2 Grundidee

Der Chi-Quadrat-Test vergleicht:

- beobachtete Häufigkeiten
- erwartete Häufigkeiten unter H_0

Wenn die Abweichungen groß sind:

- großer χ^2 -Wert
- kleiner p -Wert
- Ergebnis eher signifikant

Wenn beobachtete und erwartete Häufigkeiten ähnlich sind:

- kleiner χ^2 -Wert
- großer p -Wert

19.3 Eigenschaften

Non-parametrischer Test, also:

- keine Mittelwerte oder Varianzen nötig
- keine Normalverteilung nötig
- geeignet für nominalskalierte Variablen

19.4 Chi-Quadrat-Test für eine Variable

(auch Anpassungstest oder Goodness-of-Fit-Test)

19.4.1 Ziel

Prüfen, ob eine beobachtete Häufigkeitsverteilung von einer erwarteten Verteilung abweicht

Beispiel:

- Jahreszeiten gleich häufig?
- Parteien gleich häufig gewählt?

19.4.2 Nullhypothese

oft:

$$H_0 : \text{Gleichverteilung}$$

allgemein:

$$H_0 : \text{beobachtete Häufigkeiten entsprechen den erwarteten Häufigkeiten}$$

19.4.3 Alternativhypothese

$$H_1 : \text{Verteilung weicht ab}$$

Omnibus-Hypothese:

- sagt nur: irgendein Unterschied existiert
- keine Richtung

19.4.4 Erwartete Häufigkeiten

19.4.5 Bei Gleichverteilung:

$$f_{e,i} = \frac{N}{k}$$

mit N = Stichprobengröße und k = Anzahl der Kategorien

19.4.6 Bei vorgegebenen Anteilen

$$f_{e,i} = N \cdot P_i$$

mit P_i = erwarteter Anteil

19.4.7 Teststatistik

$$\chi^2 = \sum_{i=1}^k \frac{(f_{b,i} - f_{e,i})^2}{f_{e,i}}$$

mit f_b = beobachtete Häufigkeit und f_e = erwartete Häufigkeit

19.4.7.1 Logik der Formel

Quadrierung:

- verhindert Aufhebung positiver und negativer Abweichungen

Division durch erwartete Häufigkeit:

- Standardisierung
 - gleiche Abweichung ist bei kleinen erwarteten Häufigkeiten bedeutsamer als bei großen

Beispiel:

- Abweichung 8 bei erwarteten 10 → groß
- Abweichung 8 bei erwarteten 1000 → klein

19.4.7.2 Interpretation von χ^2

Kleines χ^2 :

- beobachtete und erwartete Häufigkeiten ähnlich
- spricht eher für H_0

Großes χ^2

- starke Abweichungen
- spricht gegen H_0

19.4.8 Freiheitsgrade

$$df = k - 1$$

Wenn:

- $k - 1$ Häufigkeiten bekannt

Dann:

- letzte Häufigkeit festgelegt

19.4.9 Chi-Quadrat-Verteilung

Eigenschaften:

- rechtsschief
- nur positive Werte möglich
- Form abhängig von Freiheitsgraden

Grund:

- Quadrierung verhindert negative Werte

19.5 Effektgröße w

19.5.1 Ziel

Standardisierte Effektgröße unabhängig von N

19.5.2 Formel

$$w = \sqrt{\sum_{i=1}^k \frac{(P_{b,i} - P_{e,i})^2}{P_{e,i}}}$$

Alternative:

$$\sqrt{\frac{\chi^2}{N}}$$

19.5.3 Interpretation nach Cohen

w	Interpretation
0.1	kleiner Effekt
0.3	mittlerer Effekt
0.5	großer Effekt

19.5.4 Power beim χ^2 -Test

Einflussfaktoren sind:

- Effektgröße w
- Stichprobengröße
- Signifikanzniveau α
- Freiheitsgrade

19.5.5 Wichtig

Kleine erwartete Häufigkeiten:

- geringere Power
- höheres Risiko für β -Fehler

19.6 Chi-Quadrat-Test für zwei Variablen

(Test auf Unabhängigkeit)

19.6.1 Ziel

Prüfen, ob zwei nominalskalierte Variablen zusammenhängen

Beispiel:

- Geschlecht x Partei
- Studienfach x Lebensziel

19.6.2 Kreuztabellen / Kontingenztafeln

Darstellung gemeinsamer Häufigkeiten zweier Variablen

- Zeilen = Variable 1
- Spalten = Variable 2
- Zellen = Kombination

19.6.3 Nullhypothese

H_0 : Variablen sind unabhängig

19.6.4 Alternativhypothese

H_1 : Variablen hängen zusammen

Wichtig:

- keine Aussage über Richtung
- nur: irgendein Zusammenhang

19.6.5 Erwartete Häufigkeiten

Unter Unabhängigkeit:

$$f_{e,i,j} = \frac{\text{Zeilenhäufigkeit} \cdot \text{Spaltenhäufigkeit}}{N}$$

19.6.6 Teststatistik

$$\chi^2 = \sum_{i=1}^k \sum_{j=1}^m \frac{(f_{b,ij} - f_{e,ij})^2}{f_{e,ij}}$$

19.6.7 Freiheitsgrade

$$df = (k - 1)(m - 1)$$

Symbol	Bedeutung
k	Anzahl Zeilen
m	Anzahl Spalten

19.6.8 Interpretation

Großes χ^2 :

- starke Abweichung von Unabhängigkeit
- spricht für Zusammenhang

Kleines χ^2 :

- beobachtete Häufigkeiten ähnlich zu erwarteten Häufigkeiten
- spricht eher für Unabhängigkeit

19.7 Effektgrößen bei zwei Variablen

19.7.1 Phi-Koeffizient ϕ

Nur bei:

- 2 x 2 Tabellen
- zwei dichotome Variablen

Formel:

$$\phi = \sqrt{\frac{\chi^2}{N}}$$

Interpretation wie Korrelation r

ϕ	Interpretation
0.1	kleiner Effekt
0.3	mittlerer Effekt
0.5	großer Effekt

19.7.2 Cramers V / selten auch Cramers ϕ

Wenn mindestens eine Variable mehr als zwei Ausprägungen besitzt

$$V = \sqrt{\frac{\chi^2}{N \cdot df_{\text{kleiner}}}}$$

mit:

$$df_{\text{kleiner}} = \min(k - 1, m - 1)$$

19.7.2.1 Eigenschaften von Cramers V

- Werte zwischen 0 und 1
- berücksichtigt Tabellengröße
- gebräuchteste Effektgröße bei größeren Kreuztabellen

19.7.3 Zusammenhang der Effektgrößen

Bei Vierfeldertafel:

$$\phi = w$$

Bei $df_{\text{kleiner}} = 1$

$$V = w$$

19.7.4 Voraussetzungen

1. Eindeutige Zuordnung

- Jede Person darf nur:
 - genau einer Kategorie
 - bzw. einer Zellkombination

zugeordnet werden

2. Unabhängige Beobachtungen

keine mehrfachen Messungen derselben Person

3. Mindesthäufigkeiten

Ungefähr:

- erwartete Häufigkeit in 80% der Zellen > 5
- keine erwartete Häufigkeit < 1

19.8 Wichtige Hinweise

Chi-Quadrat-Test zeigt keinen kausalen Zusammenhang

Ein signifikanter Zusammenhang bedeutet nicht:

- Ursache-Wirkung
- Zusammenhang $\neq$ Stärke

Ein signifikanter Zusammenhang kann:

- praktisch klein sein

deshalb:

- Effektgröße berichten

19.9 APA-Bericht

Zwischen Geschlecht und Lebensziel bestand ein signifikanter Zusammenhang,
 $\chi^2(2, N = 84) = 27.15, p < .001, V = .57$

19.10 R-Code

19.10.1 Chi-Quadrat-Test für eine Variable

Beispiel:

Prüfen, ob die drei Gruppen im Datensatz `PlantGrowth` gleich häufig vorkommen.

```
table(PlantGrowth$group)
```

```
ctrl trt1 trt2  
  10   10   10
```

19.10.2 Gleichverteilung testen

```
chisq.test(table(PlantGrowth$group))
```

Chi-squared test for given probabilities

```
data: table(PlantGrowth$group)
X-squared = 0, df = 2, p-value = 1
```

→ prüft, ob die Gruppen gleich häufig verteilt sind

19.10.3 Eigene erwartete Wahrscheinlichkeiten

```
chisq.test(table(PlantGrowth$group),
           p = c(.5, .25, .25))
```

Chi-squared test for given probabilities

```
data: table(PlantGrowth$group)
X-squared = 3.3333, df = 2, p-value = 0.1889
```

→ prüft, ob die beobachteten Häufigkeiten zu den erwarteten Anteilen passen

19.10.4 Chi-Quadrat-Test für zwei Variablen

Beispiel mit mtcars:

- cyl = Anzahl Zylinder
- am = Schaltung
 - 0 = automatisch
 - 1 = manuell

```
table(mtcars$cyl,
      mtcars$am)
```

	0	1
4	3	8
6	4	3
8	12	2

→ erstellt eine Kreuztabelle

19.10.5 Chi-Quadrat-Test berechnen

```
chisq.test(table(mtcars$cyl,
                 mtcars$am))
```

Warning in chisq.test(table(mtcars\$cyl, mtcars\$am)): Chi-squared approximation may be incorrect

Pearson's Chi-squared test

```
data:  table(mtcars$cyl, mtcars$am)
X-squared = 8.7407, df = 2, p-value = 0.01265
```

→ prüft, ob Zusammenhang zwischen Zylinderzahl und Schaltung besteht

19.10.6 Erwartete Häufigkeiten anzeigen

```
test <- chisq.test(table(mtcars$cyl,
                         mtcars$am))
```

Warning in chisq.test(table(mtcars\$cyl, mtcars\$am)): Chi-squared approximation may be incorrect

```
test$expected
```

	0	1
4	6.53125	4.46875
6	4.15625	2.84375
8	8.31250	5.68750

→ zeigt die erwarteten Häufigkeiten unter H_0

19.10.7 Erweiterte Kreuztabelle

```
library(gmodels)

CrossTable(mtcars$cyl,
           mtcars$am,
           expected = TRUE,
           chisq = TRUE)
```

Warning in `chisq.test(t, correct = FALSE, ...)`: Chi-squared approximation may be incorrect

```

      Cell Contents
|-----|
|              N |
|      Expected N |
| Chi-square contribution |
|      N / Row Total |
|      N / Col Total |
|      N / Table Total |
|-----|
```

Total Observations in Table: 32

	mtcars\$am		
mtcars\$cyl	0	1	Row Total
4	3	8	11

	6.531	4.469	
	1.909	2.790	
	0.273	0.727	0.344
	0.158	0.615	
	0.094	0.250	

6	4	3	7
	4.156	2.844	
	0.006	0.009	
	0.571	0.429	0.219
	0.211	0.231	
	0.125	0.094	

8	12	2	14
	8.312	5.688	
	1.636	2.391	
	0.857	0.143	0.438
	0.632	0.154	
	0.375	0.062	

Column Total	19	13	32
	0.594	0.406	

Statistics for All Table Factors

Pearson's Chi-squared test

Chi² = 8.740733 d.f. = 2 p = 0.01264661

→ zeigt beobachtete und erwartete Häufigkeiten sowie den Chi-Quadrat-Test

19.10.8 Fisher-Exact-Test

Bei kleinen erwarteten Häufigkeiten:

```
fisher.test(table(mtcars$cyl,  
                 mtcars$am))
```

Fisher's Exact Test for Count Data

```
data:  table(mtcars$cyl, mtcars$am)  
p-value = 0.009105  
alternative hypothesis: two.sided
```

→ exakter Test für Zusammenhang in Kreuztabellen

19.10.9 Hinweis

Wenn erwartete Häufigkeiten zu klein sind, gibt R oft folgende Warnung aus:

```
Chi-squared approximation may be incorrect
```

Dann kann ein exakter Test sinnvoller sein.

20 19. Resampling-Verfahren und non-parametrische Tests

20.1 19.1 Problem parametrischer Tests

Parametrische Tests (z. B. t-Test, ANOVA, Regression) setzen häufig voraus:

- Normalverteilung
- Varianzhomogenität
- intervallskalierte Daten
- unabhängige Beobachtungen

Bei starken Verletzungen:

- p-Werte können falsch werden
- α und β -Fehler weichen ab
- klassische Prüfverteilungen (t-, F-Verteilung) sind evtl. unangemessen

Alternativen:

- Resampling-Verfahren
- non-parametrische Tests

20.2 19.2 Grundidee von Resampling

20.2.1 Idee

Nicht:

- theoretische Stichprobenverteilung ableiten

sondern:

- empirische Stichprobenverteilung simulieren

Dazu werden aus der vorhandenen Stichprobe wiederholt neue Stichproben gezogen.

Die Stichprobe wird dabei als Annäherung an die Population behandelt.

20.2.2 Ziehen mit Zurücklegen

Dadurch:

- kann ein Fall mehrfach vorkommen
- manche Fälle kommen gar nicht vor

So entstehen viele leicht unterschiedliche Stichproben.

20.2.3 Ziel

Erzeugung einer empirischen Stichprobenverteilung für:

- Mittelwerte
- Mediane
- Korrelationen
- Regressionskoeffizienten
- Effektgrößen
- beliebige andere Kennwerte

Großer Vorteil:

- auch für Kennwerte möglich, für die keine theoretische Stichprobenverteilung existiert

20.3 19.3 Bootstrap

20.3.1 Grundidee

Bootstrap erzeugt viele neue Stichproben aus der Originalstichprobe. Damit simuliert Bootstrap das wiederholte Ziehen vieler Stichproben aus der Population.

Für jede Bootstrap-Stichprobe wird ein Kennwert berechnet.

Die Verteilung dieser Kennwerte ergibt die:

- Bootstrap-Stichprobenverteilung

Bootstrap erzeugt empirisch eine Stichprobenverteilung, anstatt sie theoretisch herzuleiten.

```
# Bootstrap-Paket  
library(boot)
```

Attaching package: 'boot'

The following object is masked from 'package:lattice':

melanoma

Parametrische Verfahren	Bootstrap
theoretische Prüfverteilung	empirische Stichprobenverteilung
stärkere Voraussetzungen	weniger restriktive Voraussetzungen
oft Normalverteilung notwendig	keine Verteilungsannahmen notwendig

20.3.2 Ablauf des Bootstrap

1. Originalstichprobe mit Größe n
2. Ziehe viele neue Stichproben der Größe n
 - mit Zurücklegen
3. Berechne pro Stichprobe den Kennwert
4. Wiederhole das sehr oft

- häufig:
 - 1000
 - 5000
 - 10000

5. Nutze die Verteilung der Kennwerte:

- Standardfehler
- Konfidenzintervalle
- Bias-Schätzung

20.3.3 Bootstrap-Konfidenzintervall

Konfidenzintervalle werden über Quantile bestimmt.

Beispiel:

95%-KI:

- untere Grenze:
 - 2.5%-Quantil
- obere Grenze:
 - 97.5%-Quantil

```
boot.ci(boot.obj, type = "bca")
```

- `bca` = bias corrected accelerated
- häufig verwendete Bootstrap-Methode

20.3.4 Vorteile des Bootstrap

- keine Normalverteilung notwendig
- flexibel
- für fast beliebige Kennwerte nutzbar
- gut bei kleinen / schiefen Verteilungen
- keine theoretische Stichprobenverteilung nötig

20.3.5 Nachteile

- Stichprobe sollte repräsentativ sein
- rechenintensiver
- schlechte Stichprobe → schlechter Bootstrap

20.3.6 Typische Anwendungen

- Konfidenzintervalle
- Standardfehler
- Bias-Schätzung
- Signifikanztests

20.3.7 R-Code

```
library(boot)

daten <- mtcars
```

20.3.7.1 Mittelwert

Bootstrap-KI für:

$$\bar{x}$$

```
# Funktion für Bootstrap-Mittelwert
mean.fun <- function(daten, i) {
  mean(daten$mpg[i], na.rm = TRUE)
}

# Bootstrap-Objekt erstellen
mean.obj <- boot(daten,
  mean.fun,
  R = 2000)

# Bootstrap-Output anzeigen
mean.obj
```

ORDINARY NONPARAMETRIC BOOTSTRAP

Call:

```
boot(data = daten, statistic = mean.fun, R = 2000)
```

Bootstrap Statistics :

	original	bias	std. error
t1*	20.09062	0.01191094	1.050384

```
# Konfidenzintervall berechnen  
boot.ci(mean.obj, type = "bca")
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = mean.obj, type = "bca")
```

Intervals :

Level	BCa
95%	(18.26, 22.36)

Calculations and Intervals on Original Scale

→ berechnet ein Bootstrap-Konfidenzintervall für den Mittelwert von mpg

20.3.7.2 Median

Bootstrap besonders sinnvoll, da für Median klassische Verfahren schwieriger sind.

```
# Funktion für Bootstrap-Median  
median.fun <- function(daten, i){  
  median(daten$mpg[i], na.rm = TRUE)  
}  
  
# Bootstrap-Objekt  
median.obj <- boot(daten,  
  median.fun,  
  R = 2000)
```

```
# Konfidenzintervall
boot.ci(median.obj, type = "bca")
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = median.obj, type = "bca")
```

Intervals :

Level BCa

95% (16.1, 21.2)

Calculations and Intervals on Original Scale

→ berechnet ein Bootstrap-Konfidenzintervall für den Median von mpg

20.3.7.3 Standardabweichung

```
# Funktion für Bootstrap-SD
sd.fun <- function(daten, i){
  sd(daten$mpg[i], na.rm = TRUE)
}
```

Bootstrap-Objekt

```
sd.obj <- boot(daten,
               sd.fun,
               R = 2000)
```

90%-Konfidenzintervall

```
boot.ci(sd.obj,
        type = "bca",
        conf = .90)
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = sd.obj, conf = 0.9, type = "bca")
```

Intervals :

```
Level      BCa
90%    ( 4.949,  7.346 )
Calculations and Intervals on Original Scale
```

→ berechnet ein 90%-Bootstrap-Konfidenzintervall für die Standardabweichung von `mpg`

20.3.7.4 Korrelation

Bootstrap-KI für:

r

```
# Funktion für Bootstrap-Korrelation
cor.fun <- function(daten, i) {
  cor(daten$mpg[i],
      daten$wt[i],
      use = "pairwise.complete.obs")
}

# Bootstrap-Objekt
cor.obj <- boot(daten,
                cor.fun,
                R = 2000)

# Konfidenzintervall
boot.ci(cor.obj,
        type = "bca")
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = cor.obj, type = "bca")
```

Intervals :

```
Level      BCa
95%    (-0.9179, -0.7745 )
Calculations and Intervals on Original Scale
```

→ berechnet ein Bootstrap-Konfidenzintervall für die Korrelation zwischen `mpg` und `wt`

20.3.7.5 Regression

Bootstrap-KI für:

- b -Gewichte

```
# Funktion für Bootstrap-b
b.fun <- function(daten, i){
  summary(
    lm(mpg[i] ~ wt[i],
      data = daten)
  )$coefficients[2,1]
}

# Bootstrap-Objekt
b.obj <- boot(daten,
              b.fun,
              R = 2000)

# Konfidenzintervall
boot.ci(b.obj,
        type = "bca")
```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = b.obj, type = "bca")
```

Intervals :

Level BCa

95% (-6.821, -4.023)

Calculations and Intervals on Original Scale

→ berechnet ein Bootstrap-Konfidenzintervall für das Regressionsgewicht von wt

- R^2

```
# Funktion für Bootstrap- $R^2$ 
r2.fun <- function(daten, i){
  summary(
    lm(mpg[i] ~ wt[i],
      data = daten)
  )
```

```

    )$r.squared
  }

# Bootstrap-Objekt
r2.obj <- boot(daten,
               r2.fun,
               R = 2000)

# Konfidenzintervall
boot.ci(r2.obj,
        type = "bca")

```

BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS

Based on 2000 bootstrap replicates

CALL :

```
boot.ci(boot.out = r2.obj, type = "bca")
```

Intervals :

```

Level      BCa
95%      ( 0.5983, 0.8428 )

```

Calculations and Intervals on Original Scale

→ berechnet ein Bootstrap-Konfidenzintervall für (R^2)

20.4 19.4 Randomisierungstests (Permutationstests)

20.4.1 Grundidee

Randomisierungstests sind Resampling-Verfahren für Signifikanztests.

Ziel:

- empirische Nullverteilung erzeugen

statt theoretischer Prüfverteilung.

```

# Gruppenzugehörigkeit zufällig permutieren
gruppe <- PlantGrowth$group

sample(gruppe)

```

```
[1] trt2 trt1 trt1 trt2 trt2 trt1 trt1 trt2 trt2 ctrl ctrl ctrl ctrl ctrl ctrl
[16] trt1 trt2 trt1 ctrl trt2 ctrl trt1 trt2 trt1 ctrl trt1 ctrl trt1 trt2 trt2
Levels: ctrl trt1 trt2
```

20.4.2 Idee der Nullhypothese

Wenn H_0 wahr ist:

→ Gruppenzugehörigkeit sollte egal sein.

Deshalb:

- Werte zufällig neu auf Gruppen verteilen
- Teststatistik berechnen
- sehr oft wiederholen

Dadurch entsteht die Nullverteilung.

20.4.3 Ablauf

1. beobachtete Teststatistik berechnen
2. Daten zufällig permutieren
3. neue Teststatistik berechnen
4. viele Wiederholungen
5. prüfen:
 - wie extrem ist der beobachtete Wert?

20.4.4 p-Wert

Anteil der permutierten Werte, die mindestens so extrem sind wie der beobachtete Wert.

20.4.5 Vorteile

- keine Verteilungsannahmen
- sehr flexibel
- oft robuster als parametrische Tests

20.4.6 Einfacher Permutationstest für Mittelwertsdifferenz

```
daten <- subset(PlantGrowth,
               group %in% c("ctrl", "trt1"))

# beobachtete Mittelwertsdifferenz
obs.diff <- mean(daten$weight[daten$group == "ctrl"]) -
            mean(daten$weight[daten$group == "trt1"])

obs.diff
```

```
[1] 0.371
```

→ tatsächlicher Unterschied zwischen den Gruppenmittelwerten

```
# Anzahl Permutationen
B <- 5000

# Vektor für permutierte Teststatistiken
perm.diff <- numeric(B)

for(i in 1:B){

  # Gruppenlabels zufällig mischen
  perm.gruppe <- sample(daten$gruppe)

  # neue Mittelwertsdifferenz
  perm.diff[i] <-
    mean(daten$weight[perm.gruppe == "ctrl"]) -
    mean(daten$weight[perm.gruppe == "trt1"])
}

# empirischer p-Wert
mean(abs(perm.diff) >= abs(obs.diff))
```

```
[1] NA
```

→ berechnet den empirischen p-Wert des Permutationstests

20.5 19.5 Unterschied Bootstrap vs. Randomisierungstest

Bootstrap	Randomisierungstest
Schätzung von Parametern	Testen von Hypothesen
Fokus auf Konfidenzintervallen	Fokus auf p-Werten
Ziehen mit Zurücklegen	häufig Permutation ohne Zurücklegen
„Wie groß ist der Effekt?“	„Ist der Effekt zufällig?“

20.6 19.6 Non-parametrische Tests

20.6.1 Grundidee

Non-parametrische Tests wurden ursprünglich für ordinalskalierte Daten entwickelt.

Nicht mit Rohwerten rechnen,

sondern mit:

- Rangplätzen

20.6.2 Rangbildung

Kleinster Wert:

\$ \text{Rang} = 1 \$

größter Wert:

\$ \text{Rang} = n \$

Bei gleichen Werten:

- mittlere Rangplätze vergeben

20.6.3 Vorteile

- keine Normalverteilung notwendig
- auch für ordinale Daten geeignet
- robust gegen Ausreißer
- Bei deutlichen Verletzungen der Voraussetzungen können non-parametrische Verfahren eine höhere Power besitzen als parametrische Verfahren.

20.6.4 Nachteile

- Informationsverlust
- geringere Aussagekraft über echte Mittelwerte, da nur Aussagen über Rangplätze, nicht über tatsächliche Mittelwerte getroffen werden.
- manchmal geringere Power
- Wenn die Voraussetzungen parametrischer Tests erfüllt sind, haben parametrische Verfahren häufig die höhere Power.

20.6.5 R-Code

```
x <- c(12, 5, 20, 12, 8)

rank(x)
```

```
[1] 3.5 1.0 5.0 3.5 2.0
```

→ berechnet die Rangplätze der Werte

20.6.5.1 Umgang mit gleichen Werten (ties)

```
rank(x,
      ties.method = "average")
```

```
[1] 3.5 1.0 5.0 3.5 2.0
```

→ gleiche Werte erhalten den durchschnittlichen Rangplatz

20.6.5.2 Weitere Möglichkeiten für ties.method

Methode	Bedeutung
"average"	mittlerer Rang
"first"	Reihenfolge des Auftretens
"min"	kleinster Rang
"max"	größter Rang
"random"	zufälliger Rang

20.7 19.7 Wichtige non-parametrische Tests

Parametrischer Test	Non-parametrisches Pendant
t-Test unabhängig	Mann-Whitney-U-Test
t-Test abhängig	Wilcoxon-Test
einfaktorielle ANOVA	Kruskal-Wallis-Test
Pearson-Korrelation	Spearman-Rangkorrelation

20.8 19.8 Mann-Whitney-U-Test

20.8.1 Einsatz

Vergleich von:

- zwei unabhängigen Gruppen

Alternative zu:

- t-Test für unabhängige Stichproben

20.8.2 Idee

- alle Werte gemeinsam in Ränge umwandeln
- kleine U-Werte $\rightarrow$ starke Gruppenunterschiede
- basiert auf Rangsummen statt Mittelwerten
- Rangsummen vergleichen

20.8.3 Formel

$$U = n_1 n_2 + \frac{n_1(n_1 + 1)}{2} - R_1$$

mit:

- n_1 = Gruppengröße Gruppe 1
- n_2 = Gruppengröße Gruppe 2
- R_1 = Rangsumme Gruppe 1

20.8.4 Hypothesen

H_0 : Gruppen unterscheiden sich nicht

20.8.5 R-Code

```
daten <- subset(PlantGrowth,  
               group %in% c("ctrl", "trt1"))
```

```
# ungerichtet  
wilcox.test(weight ~ group,  
            data = daten)
```

→ prüft, ob sich die Gruppen unterscheiden

```
# gerichtet  
wilcox.test(weight ~ group,  
            data = daten,  
            alternative = "greater")
```

Warning in wilcox.test.default(x = DATA[[1L]], y = DATA[[2L]], ...): cannot compute exact p-value with ties

Wilcoxon rank sum test with continuity correction

data: weight by group

W = 67.5, p-value = 0.0993

alternative hypothesis: true location shift is greater than 0

→ prüft, ob Gruppe 1 größere Werte besitzt

20.9 19.9 Wilcoxon-Test

20.9.1 Einsatz

Vergleich von:

- zwei abhängigen Messungen

Alternative zu:

- t-Test für abhängige Stichproben

20.9.2 Idee

- Differenzen berechnen
- Beträge der Differenzen ranken
- positive vs. negative Rangsumme vergleichen

$$W = \sum R_+$$

mit R_+ = positive Ränge

20.9.3 R-Code

```
x1 <- mtcars$mpg
x2 <- mtcars$mpg * 0.425
```

```
wilcox.test(x1,
            x2,
            paired = TRUE)
```

→ prüft, ob sich die beiden abhängigen Messreihen unterscheiden

```
# gerichteter Test
wilcox.test(x1,
            x2,
            paired = TRUE,
            alternative = "greater")
```

Warning in wilcox.test.default(x1, x2, paired = TRUE, alternative = "greater"):
cannot compute exact p-value with ties

Wilcoxon signed rank test with continuity correction

data: x1 and x2

V = 528, p-value = 4.155e-07

alternative hypothesis: true location shift is greater than 0

→ prüft, ob die Werte von x1 tendenziell größer sind

20.10 19.10 Kruskal-Wallis-Test

20.10.1 Einsatz

Vergleich von:

- mehr als zwei unabhängigen Gruppen

Alternative zu:

- einfaktorielle ANOVA

20.10.2 Idee

- Werte in Ränge umwandeln
- Rangmittelwerte / Rangsummen vergleichen

20.10.3 Formel

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k \frac{R_j^2}{n_j} - 3(N+1)$$

mit:

- R_j = Rangsumme Gruppe j
- n_j = Gruppengröße
- N = Gesamtstichprobe

20.10.4 Interpretation

- großes $H \rightarrow$ Gruppen unterscheiden sich
- analog zur ANOVA auf Rangbasis

```
kruskal.test(weight ~ group,  
             data = PlantGrowth)
```

Kruskal-Wallis rank sum test

data: weight by group

Kruskal-Wallis chi-squared = 7.9882, df = 2, p-value = 0.01842

→ prüft, ob sich mindestens eine Gruppe von den anderen unterscheidet

20.11 19.11 Spearman-Rangkorrelation

20.11.1 Einsatz

Zusammenhang zwischen ordinalen Variablen

Alternative zu:

- Pearson-Korrelation

20.11.2 Idee

Korrelation der Rangplätze statt der Rohwerte.

20.11.3 Formel

$$r_s$$

$$\frac{6 \sum d_i^2}{n(n^2 - 1)}$$

$$r_s = 1 - \frac{6 \sum d_i^2}{n(n^2 - 1)}$$

```
cor(mtcars$mpg,  
    mtcars$wt,  
    method = "spearman")
```

```
[1] -0.886422
```

→ berechnet die Spearman-Rangkorrelation

20.12 Rangkorrelation direkt über Ränge

```
cor(rank(mtcars$mpg),  
     rank(mtcars$wt))
```

```
[1] -0.886422
```

→ berechnet die Pearson-Korrelation der Rangplätze

20.13 Signifikanztest

```
cor.test(mtcars$mpg,  
         mtcars$wt,  
         method = "spearman")
```

```
Warning in cor.test.default(mtcars$mpg, mtcars$wt, method = "spearman"): Cannot  
compute exact p-value with ties
```

Spearman's rank correlation rho

```
data: mtcars$mpg and mtcars$wt  
S = 10292, p-value = 1.488e-11  
alternative hypothesis: true rho is not equal to 0  
sample estimates:  
      rho  
-0.886422
```

→ prüft, ob die Rangkorrelation signifikant von 0 verschieden ist

20.14 19.14 Wann welches Verfahren?

Situation	Verfahren
Voraussetzungen erfüllt	parametrischer Test
starke Verletzung der Voraussetzungen	Bootstrap
ordinale Daten	non-parametrische Tests

Situation	Verfahren
kleine / schiefe Stichproben robuste Alternative gesucht	Bootstrap oder non-parametrisch Resampling

Wenn ursprünglich ein parametrisches Verfahren geplant war, wird heute häufig Bootstrap anstelle non-parametrischer Verfahren bevorzugt.

21 20. Kritik am NHST (Vertiefung)

21.1 20.1 Grundidee der Kritik

Das klassische Nullhypothesen-Signifikanztesten (NHST) ist der Standardansatz der Inferenzstatistik in vielen empirischen Wissenschaften.

Dabei wird geprüft, ob ein beobachteter Effekt unter Annahme der Nullhypothese unwahrscheinlich wäre.

Der zentrale Kennwert ist der p-Wert:

$$p(\text{Daten}|H_0)$$

Der p-Wert gibt die Wahrscheinlichkeit an, die beobachteten Daten (oder extremere Daten) zu erhalten, wenn die Nullhypothese wahr ist.

Das NHST steht jedoch seit Jahrzehnten in der Kritik. Besonders bekannt wurde die Kritik durch:

- Cohen (1994): “The Earth Is Round(<.05)”
- Wasserstein et al. (2019) “Moving to a World Beyond $p < .05$ ”

21.2 20.2 Zentrale Fehlinterpretationen des p-Werts

Der p-Wert ist NICHT:

- die Wahrscheinlichkeit, dass H_0 wahr ist
- die Wahrscheinlichkeit, dass H_1 wahr ist
- die Wahrscheinlichkeit, dass die Daten “durch Zufall” entstanden sind
- ein Maß für die Größe eines Effekts
- ein Maß für praktische Relevanz
- ein Maß für Replizierbarkeit

Der p-Wert liefert nur:

$$p(\text{Daten}|H_0)$$

und NICHT:

$$p(H_0|\text{Daten})$$

Ein einzelner p-Wert enthält wenig Information.

Selbst bei identischem Populationseffekt streuen p-Werte stark zwischen Replikationen.

→ signifikante Ergebnisse können zufällig stark schwanken

Cumming zeigt:

- hohe Variabilität von p-Werten
- geringe Replizierbarkeit einzelner Ergebnisse

21.3 20.3 Probleme des NHST

21.3.1 20.3.1 Dichotomes Denken

Im NHST wird meist eine künstliche Grenze verwendet:

$$\alpha = 0.05$$

Dann gilt:

- $p < 0.05 \rightarrow$ “signifikant”
- $p > 0.05 \rightarrow$ “nicht signifikant”

Problem:

Ein Ergebnis mit:

$$p = 0.049$$

wird völlig anders behandelt als:

$$p = 0.051$$

obwohl praktisch überhaupt kein Unterschied besteht.

Wasserstein et al.:

Die Differenz zwischen „signifikant“ und „nicht signifikant“ ist selbst nicht signifikant.

21.3.2 20.3.2 Abhängigkeit von der Stichprobengröße

Der p-Wert hängt stark von n ab.

Große Stichproben:

- kleine Effekte werden signifikant

Kleine Stichproben:

- selbst relevante Effekte werden evtl. nicht signifikant

Deshalb bedeutet Signifikanz nicht automatisch:

- großer Effekt
- wichtiger Effekt
- relevanter Effekt

21.3.3 20.3.4 Unrealistische Nullhypothesen

Im NHST wird oft geprüft:

$$H_0 : Effekt = 0$$

Solche exakten Nullhypothesen sind in vielen realen Situationen unrealistisch.

Beispiel:

Zwischen zwei psychologischen Variablen existiert fast immer irgendein minimaler Zusammenhang. Daher oft wenig informative Hypothese.

Die Frage sollte oft eher sein:

- Wie groß ist der Effekt?
- Ist er praktisch relevant?

statt:

- Ist der Effekt exakt 0?

Cohen (1994) bezeichnete solche Nullhypothesen als häufig wenig informativ.

21.3.4 20.3.4 Signifikanz $\neq$ praktische Relevanz

Ein statistisch signifikanter Effekt kann praktisch völlig irrelevant sein.

Beispiel:

Ein Medikament verbessert einen Wert statistisch signifikant, aber nur minimal.

Dann ist der Effekt zwar statistisch nachweisbar, aber praktisch bedeutungslos.

Der p-Wert allein liefert keine Information über die Größe oder Wichtigkeit eines Effekts.

21.3.5 20.3.5 Replikationskrise

Viele veröffentlichte Ergebnisse lassen sich nicht replizieren.

Das bedeutet:

Spätere Studien finden denselben Effekt nicht erneut.

Mögliche Ursachen:

- geringe Teststärke (Power)
- kleine Stichproben
- kleine Effektgrößen $\rightarrow$ geringe Power
- p-Hacking
- HARKing
- Publication Bias
 - Nicht-signifikante Ergebnisse verschwinden in der „Schublade“.
- selektive Berichterstattung / Positivity Bias
 - Positive / signifikante Ergebnisse werden bevorzugt publiziert.
- Überinterpretation einzelner signifikanter Ergebnisse

21.3.5.1 Unterschied HARKing vs. p-Hacking

HARKing: Hypothesizing after Results are Known

Begriff	Bedeutung
HARKing	Hypothese nach Sichtung der Ergebnisse umformulieren
p-Hacking	Analysen/Stichprobe manipulieren bis $p < .05$

Optional Stopping ist dabei:

$\rightarrow$ spezielle Form von p-Hacking.

21.3.6 20.3.6 Positive Predictive Value (PPV)

Der positive Vorhersagewert beschreibt:

$$P(H_1|\text{signifikant})$$

also die Wahrscheinlichkeit, dass die Alternativhypothese tatsächlich wahr ist, wenn ein signifikantes Ergebnis gefunden wurde.

Das ist etwas völlig anderes als der p-Wert.

Bei realistischen Annahmen kann trotz:

$$p < 0.05$$

ein großer Anteil der Ergebnisse falsch positiv sein.

Beispiel aus Sedlmeier & Renkewitz:

- Basisrate korrekter Hypothesen: 10%
- $\alpha = 0.05$

→ nur etwa:

$$PPV \approx 0.53$$

Das bedeutet:

Etwa 47 % signifikanter Ergebnisse könnten falsch positiv sein.

Ioannidis:

Viele publizierte Ergebnisse sind falsch positiv.

Ursachen:

- geringe Power
- Bias
- kleine Effekte
- Selektionsprozesse

21.3.7 20.3.7 Publication Bias / File Drawer Problem

Signifikante Ergebnisse:

- werden häufiger publiziert

Nicht-signifikante Ergebnisse:

- verschwinden in der „Schublade“

Folge:

- verzerrte Literatur
- Überschätzung von Effekten

21.4 20.4 Kritik von Wasserstein et al. (2019)

„Statistical significance should not determine scientific conclusions.“

Die American Statistical Association (ASA) kritisiert insbesondere:

- starre Signifikanzgrenzen
- Fehlinterpretationen des p-Werts
- Überbewertung signifikanter Ergebnisse
- Vernachlässigung von Unsicherheit

Die Autoren empfehlen:

“Accept uncertainty. Be thoughtful, open, and modest.”

(ATOM-Prinzip)

22 21 Verbesserungen innerhalb des NHST

Zentrale Kritikpunkte am klassischen NHST

- dichotomes Denken
- Überbetonung des p-Werts
- Vernachlässigung praktischer Relevanz
- Abhängigkeit von Stichprobengröße
- schlechte Replizierbarkeit
- Fehlinterpretationen des p-Werts
- publication bias
- p-hacking

22.1 Exkurs: Geoff Cumming und die „New Statistics“

Geoff Cumming kritisiert den starken Fokus auf:

- p-Werte
- dichotome Entscheidungen („signifikant / nicht signifikant“)

Stattdessen betont er:

- Effektgrößen
- Konfidenzintervalle
- Replikationen
- Meta-Analysen

Zentrale Idee:

Unsicherheit sichtbar machen, statt nur Signifikanzgrenzen zu betrachten.

Bekanntes Konzept:

- „Dance of the p-values“

→ p-Werte schwanken stark zwischen Stichproben, selbst bei gleichem wahren Effekt.

Folge: - einzelne signifikante Studien oft instabil - Replikationen wichtig

22.2 21.1 Effektgrößen berichten

22.2.1 Grundidee:

Signifikanztests beantworten nur die Frage:

Ist ein Effekt statistisch nachweisbar?

Sie beantworten NICHT:

Wie groß ist der Effekt?

22.2.2 Warum sind Effektgrößen wichtig?

Effektgrößen ermöglichen Aussagen über:

- die praktische Relevanz eines Effekts
- die Stärke eines Zusammenhangs
- Vergleiche zwischen Studien
- Meta-Analysen

Ein kleiner Effekt kann bei großer Stichprobe signifikant werden, obwohl er praktisch kaum relevant ist.

Umgekehrt kann ein großer Effekt bei kleiner Stichprobe nicht signifikant werden.

22.2.3 Beispiele für Effektgrößen

Situation	Effektgröße
Mittelwertsunterschiede	Cohen's d , Hedges' g
Varianzanalyse	η^2
Korrelationen	r
Nominalskalierte Variablen	ϕ , Cramers V

Effektgrößen können direkt aus Testergebnissen berechnet werden.

Dadurch können Effekte auch dann bestimmt werden, wenn nur Teststatistiken veröffentlicht wurden.

Das ist besonders wichtig für:

- Metaanalysen
- Vergleich verschiedener Studien
- Poweranalysen zukünftiger Studien

22.2.4 R-Code

```
# Benötigte Pakete  
library(effectsize)  
library(pwr)
```

22.2.4.1 Effektgröße für einen Einstichproben t-Test

Verwendung:

- Mittelwert vs. vorgegebener Wert
- Effektgröße aus t-Wert berechnen

$$g = \frac{t}{\sqrt{n}}$$

22.2.4.2 Effektgröße für zwei unabhängige Stichproben

Verwendung:

- Mittelwertsunterschied zweier unabhängiger Gruppen
- Cohen's d / Hedges' g

$$dbzw.g = \frac{\bar{x}_A - \bar{x}_B}{\hat{\sigma}_{AB}}$$

```
daten <- subset(PlantGrowth,
               group %in% c("ctrl", "trt1"))
```

Effektgröße berechnen

```
cohens_d(weight ~ group,
          data = daten)
```

Cohen's d	95% CI
0.53	[-0.37, 1.42]

- Estimated using pooled SD.

→ berechnet Cohen's d bzw. Hedges' g

Anderes Konfidenzniveau

```
cohens_d(weight ~ group,
          data = daten,
          ci = .90)
```

Cohen's d	90% CI
0.53	[-0.22, 1.28]

- Estimated using pooled SD.

→ berechnet ein 90%-Konfidenzintervall für die Effektgröße
Effektgröße aus t-Wert berechnen

```
t_to_d(t = 3.6441,
      df = 81.956)
```

d	95% CI
0.81	[0.35, 1.25]

→ berechnet Cohen's d aus einem t-Wert und Freiheitsgraden

22.2.4.3 Gepoolte Standardabweichung

Verwendung:

- gemeinsame Streuung beider Gruppen
- notwendig für Cohen's d

$$\hat{\sigma}_{AB} = \sqrt{\frac{\hat{\sigma}_A^2(n_A - 1) + \hat{\sigma}_B^2(n_B - 1)}{n_A + n_B - 2}}$$

```
# automatisch in cohens_d()
cohens_d(weight ~ group,
      data = daten)
```

Cohen's d	95% CI
0.53	[-0.37, 1.42]

- Estimated using pooled SD.

22.2.4.4 Effektgröße aus t-Wert bei unabhängigen Stichproben

Verwendung:

- Effektgröße berechnen, wenn nur Testergebnis vorliegt

$$g = t \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}$$

äquivalent:

$$g = t \sqrt{\frac{n_A + n_B}{n_A n_B}}$$

22.2.4.5 Korrelative Effektgröße aus t-Test

Verwendung:

- Zusammenhangsmaß aus t-Test berechnen
- Interpretation als Korrelation

$$r = \sqrt{\frac{t^2}{t^2 + df}}$$

```
t_to_r(t = 2.8, df = 58)
```

r		95% CI
0.35		[0.10, 0.53]

22.2.4.6 Effektgröße für abhängige Stichproben

Verwendung:

- Pre-Post-Vergleiche
- Messwiederholungen
- abhängiger t-Test

$$dbzw.g = \frac{\bar{x}_{\text{Differenzwerte}}}{\hat{\sigma}_{\text{Differenzwerte}}}$$

22.2.4.7 Effektgröße aus t-Wert bei abhängigen Stichproben

Verwendung:

- Effektgröße direkt aus t-Test berechnen

$$g = \frac{t}{\sqrt{n}}$$

22.2.4.8 Korrigierte Effektgröße für abhängige Stichproben

Verwendung:

- Vergleichbarkeit mit unabhängigen Stichproben
- berücksichtigt Korrelation der Messungen

$$g = t_{AS} \sqrt{\frac{2(1-r)}{n}}$$

22.2.4.9 Cohens d / Hedges' g bei abhängigen Stichproben

```
x1 <- mtcars$mpg
x2 <- mtcars$mpg * 0.425
```

```
cohens_d(x1,
          x2,
          paired = TRUE)
```

For paired samples, 'repeated_measures_d()' provides more options.

```
Cohen's d |          95% CI
-----|-----
3.33      | [2.43, 4.22]
```

```
# abhängige Stichproben aus t-Wert und Freiheitsgraden
t_to_d(t = 0.28672,
        df = 83,
        paired = TRUE)
```

```
d      |          95% CI
-----|-----
0.03   | [-0.18, 0.25]
```

22.2.4.10 Eta-Quadrat

Verwendung:

- Effektgröße der ANOVA
- Anteil erklärter Varianz

$$\eta^2 = \frac{QS_{zwischen}}{QS_{gesamt}}$$

Interpretation:

- Anteil der Gesamtvarianz, der durch Gruppenzugehörigkeit erklärt wird

22.2.4.11 Zusammenhang zwischen η^2 und Cohen's f

Verwendung:

- Poweranalyse für ANOVA
- `pwr.anova.test()` nutzt f

$$f = \sqrt{\frac{\eta^2}{1 - \eta^2}}$$

```
# Eta-Quadrat für ANOVA aus Rohdaten
modell.aov <- aov(weight ~ group,
                 data = PlantGrowth)

eta_squared(modell.aov)
```

For one-way between subjects designs, partial eta squared is equivalent to eta squared. Returning eta squared.

```
# Effect Size for ANOVA
```

Parameter	Eta2	95% CI
group	0.26	[0.04, 1.00]

- One-sided CIs: upper bound fixed at [1.00].

```
# Eta-Quadrat aus F-Wert und Freiheitsgraden
F_to_eta2(f = 8.523,
          df = 2,
          df_error = 81)
```

Eta2 (partial)	95% CI
0.17	[0.06, 1.00]

- One-sided CIs: upper bound fixed at [1.00].

22.2.4.12 Phi-Koeffizient

Verwendung:

- Zusammenhang zweier dichotomer Variablen
- Effektgröße für 2×2-Kontingenztafeln

$$\phi = \sqrt{\frac{\chi^2}{N}}$$

22.2.4.13 Cramers V

Verwendung:

- Zusammenhang nominalskaliert Variablen
- Tabellen größer als 2×2

$$V = \sqrt{\frac{\chi^2}{N \cdot df_{\text{kleiner}}}}$$

```
# Phi für zwei dichotome nominalskalierte Variablen
phi(x = mtcars$vs,
    y = mtcars$am)
```

Phi (adj.)	95% CI
0.00	[0.00, 1.00]

- One-sided CIs: upper bound fixed at [1.00].

```
# Cramers V für größere Kreuztabellen
cramers_v(x = mtcars$cyl,
          y = mtcars$gear)
```

```
Cramer's V (adj.) |          95% CI
-----
0.48              | [0.07, 1.00]
```

- One-sided CIs: upper bound fixed at [1.00].

```
# Phi aus Chi-Quadrat-Kennwerten
chisq_to_phi(chisq = 1.6827,
             nrow = 2,
             ncol = 2,
             n = 75)
```

```
Phi (adj.) |          95% CI
-----
0.09       | [0.00, 1.00]
```

- One-sided CIs: upper bound fixed at [1.00].

```
# Cramers V aus Chi-Quadrat-Kennwerten
chisq_to_cramers_v(chisq = 27.145,
                  nrow = 2,
                  ncol = 3,
                  n = 84)
```

```
Cramer's V (adj.) |          95% CI
-----
0.55              | [0.34, 1.00]
```

- One-sided CIs: upper bound fixed at [1.00].

22.2.4.14 Effektgrößen bei Regression

22.2.4.15 Cohen's f^2

Verwendung:

- Effektgröße der Regression
- Poweranalyse für Regression

$$f^2 = \frac{R^2}{1 - R^2}$$

Interpretation:

- Verhältnis erklärter zu nicht erklärter Varianz

```
F_to_f2(f = 5.2, df = 1, df_error = 80)
```

```
Cohen's f2 (partial) |      95% CI
```

```
-----  
0.07                | [0.00, Inf]
```

- One-sided CIs: upper bound fixed at [Inf].

```
# oder manuell:
```

```
r2 <- 0.25
```

```
r2 / (1 - r2)
```

```
[1] 0.3333333
```

22.2.5 Umrechnung von Effektgrößen

22.2.5.1 Cohen's d in Korrelation r

Verwendung:

- Vergleich verschiedener Effektgrößen
- Metaanalysen

$$r = \frac{d}{\sqrt{d^2 + 4}}$$

```
# Effektgrößen umrechnen
```

```
# Beispiel: d in r
```

```
d_to_r(0.79)
```

[1] 0.3673783

22.3 21.2 Konfidenzintervalle berichten

22.3.1 Grundidee:

Ein p-Wert liefert nur eine Ja/Nein-Entscheidung.

22.3.2 Konfidenzintervalle zeigen:

- plausible Werte für den wahren Effekt (Wenn das Verfahren unendlich oft wiederholt würde, würden 95 % der berechneten Intervalle den wahren Parameter enthalten.)
- Präzision der Schätzung
- Unsicherheit der Schätzung
- praktische Relevanz

Sie liefern also deutlich mehr Information als nur:

- „signifikant“ / „nicht signifikant“

Dadurch entsteht weniger dichotomes Denken.

22.4 21.3 Poweranalysen durchführen

22.4.1 Problem

Nicht-signifikante Ergebnisse können entstehen durch:

- tatsächlich keinen Effekt
- zu kleine Stichprobe

NHST allein kann diese Situationen nicht unterscheiden.

22.4.2 Lösung: Poweranalyse

Die Power beschreibt die Wahrscheinlichkeit, einen tatsächlich vorhandenen Effekt zu entdecken.

$$\text{Power} = 1 - \beta$$

22.4.2.1 Apriori-Poweranalyse

Vor der Studie wird berechnet:

Wie groß muss die Stichprobe sein?

Benötigt werden:

- erwartete Effektgröße
- Signifikanzniveau α
- gewünschte Power

Eine Power von mindestens 80 % wird häufig empfohlen. :contentReferenceoaicite:7

22.4.2.2 Post-hoc-Poweranalyse

Nach der Studie kann überprüft werden:

War die Stichprobe groß genug?

Das ist besonders wichtig bei:

- nicht-signifikanten Ergebnissen
- Untersuchungen kleiner Effekte

22.4.3 R-Code: Poweranalysen

```
# Paket laden  
library(pwr)
```

22.4.3.1 A-priori-Poweranalyse: unabhängiger t-Test

```
# Benötigtes n pro Gruppe bei erwarteter Effektgröße d  
pwr.t.test(d = 1 / 1.87,  
           sig.level = .05,  
           power = .80,  
           type = "two.sample",  
           alternative = "two.sided")
```

Two-sample t test power calculation

```
n = 55.87014
d = 0.5347594
sig.level = 0.05
power = 0.8
alternative = two.sided
```

NOTE: n is number in *each* group

```
# Gerichtete Hypothese
pwr.t.test(d = 1 / 1.87,
  sig.level = .05,
  power = .80,
  type = "two.sample",
  alternative = "greater")
```

Two-sample t test power calculation

```
n = 43.93193
d = 0.5347594
sig.level = 0.05
power = 0.8
alternative = greater
```

NOTE: n is number in *each* group

22.4.3.2 Post-hoc-Poweranalyse: unabhängiger t-Test mit ungleichen Gruppengrößen

```
# Beispieltest
t.test(wt ~ am,
  data = mtcars)
```

Welch Two Sample t-test

data: wt by am

t = 5.4939, df = 29.234, p-value = 6.272e-06

alternative hypothesis: true difference in means between group 0 and group 1 is not equal to

95 percent confidence interval:
0.8525632 1.8632262
sample estimates:
mean in group 0 mean in group 1
3.768895 2.411000

```
# Power für maximal vernachlässigbaren Effekt d = 1.5 / 8.26
pwr.t2n.test(n1 = 19,
             n2 = 13,
             d = 0.5,
             sig.level = .05,
             alternative = "two.sided")
```

t test power calculation

```
n1 = 19
n2 = 13
d = 0.5
sig.level = 0.05
power = 0.2697112
alternative = two.sided
```

22.4.3.3 A-priori-Poweranalyse: abhängiger t-Test

```
# n = Anzahl der Messwertpaare
pwr.t.test(d = -0.5 / 1.87,
           sig.level = .05,
           power = .80,
           type = "paired",
           alternative = "less")
```

Paired t test power calculation

```
n = 87.84789
d = -0.2673797
sig.level = 0.05
power = 0.8
alternative = less
```

NOTE: n is number of *pairs*

22.4.3.4 Post-hoc-Poweranalyse: abhängiger t-Test

```
x1 <- mtcars$mpg
x2 <- mtcars$mpg * 0.425
```

```
# SD der Differenzwerte
sd.diff <- sd(x1 - x2,
             na.rm = TRUE)

sd.diff
```

```
[1] 3.465495
```

```
# Power für maximal vernachlässigbaren Unterschied von 1
pwr.t.test(n = 84,
           d = 1 / sd.diff,
           sig.level = .05,
           type = "paired",
           alternative = "two.sided")
```

Paired t test power calculation

```
      n = 84
      d = 0.2885591
sig.level = 0.05
  power = 0.7434505
alternative = two.sided
```

NOTE: n is number of *pairs*

22.4.3.5 Poweranalyse: einfaktorielle ANOVA

```
# A-priori: benötigtes n pro Gruppe
pwr.anova.test(k = 3,
               f = .10,
               sig.level = .05,
               power = .95)
```

Balanced one-way analysis of variance power calculation

```
k = 3
n = 515.7746
f = 0.1
sig.level = 0.05
power = 0.95
```

NOTE: n is number in each group

```
# Umrechnung  $\eta^2 \rightarrow f$ 
eta2_to_f(.02)
```

```
[1] 0.1428571
```

```
# Post-hoc: Power bei ungefähr gleichen Gruppengrößen
pwr.anova.test(k = 3,
               n = 28,
               f = eta2_to_f(.02),
               sig.level = .05)
```

Balanced one-way analysis of variance power calculation

```
k = 3
n = 28
f = 0.1428571
sig.level = 0.05
power = 0.1925807
```

NOTE: n is number in each group

22.4.3.6 Poweranalyse: Korrelation

```
# A-priori: benötigte Stichprobengröße
pwr.r.test(r = -.30,
           sig.level = .05,
           power = .90,
           alternative = "less")
```

approximate correlation power calculation (arctangh transformation)

```
n = 91.41024
r = -0.3
sig.level = 0.05
power = 0.9
alternative = less
```

```
# Korrelationsanalyse
cor.test(mtcars$mpg,
         mtcars$wt,
         use = "pairwise.complete.obs")
```

Pearson's product-moment correlation

```
data: mtcars$mpg and mtcars$wt
t = -9.559, df = 30, p-value = 1.294e-10
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 -0.9338264 -0.7440872
sample estimates:
      cor
-0.8676594
```

```
# Post-hoc: Power bei n = 82 und maximal irrelevanter Korrelation r = .10
pwr.r.test(n = 82,
           r = .10,
           sig.level = .05,
           alternative = "two.sided")
```

approximate correlation power calculation (arctangh transformation)

```
n = 82
r = 0.1
sig.level = 0.05
power = 0.1457137
alternative = two.sided
```

22.4.3.7 Poweranalyse: Regression

```
# A-priori-Poweranalyse für einfache lineare Regression
#  $f^2 = R^2 / (1 - R^2)$ 
pwr.f2.test(u = 1,
            f2 = .45 / (1 - .45),
            sig.level = .05,
            power = .80)
```

Multiple regression power calculation

```
u = 1
v = 9.859406
f2 = 0.8181818
sig.level = 0.05
power = 0.8
```

```
# benötigtes n = u + v + 1

# Regressionsmodell
modell.reg <- lm(mpg ~ wt,
               data = mtcars)

summary(modell.reg)
```

Call:

```
lm(formula = mpg ~ wt, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-4.5432	-2.3647	-0.1252	1.4096	6.8727

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	37.2851	1.8776	19.858	< 2e-16 ***
wt	-5.3445	0.5591	-9.559	1.29e-10 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.046 on 30 degrees of freedom
Multiple R-squared: 0.7528, Adjusted R-squared: 0.7446
F-statistic: 91.38 on 1 and 30 DF, p-value: 1.294e-10

```
# Post-hoc-Poweranalyse bei maximal irrelevanter Varianzaufklärung  $R^2 = .01$   
pwr.f2.test(u = 1,  
            v = 80,  
            f2 = .01 / (1 - .01),  
            sig.level = .05)
```

Multiple regression power calculation

```
u = 1  
v = 80  
f2 = 0.01010101  
sig.level = 0.05  
power = 0.1465242
```

22.5 21.4 Shannon-Information / s-Wert

Die Shannon-Information ist ein alternativer Ansatz zur Interpretation von p-Werten.
Statt einer dichotomen Entscheidung („signifikant“ vs. „nicht signifikant“) wird betrachtet:

Wie überraschend sind die Daten unter H_0 ?

Der s-Wert transformiert den p-Wert in eine Informationsmenge.

22.5.1 21.4.1 Formel

$$s = -\log_2(p)$$

22.5.2 21.4.2 Interpretation

Großer s-Wert:

- Daten stärker überraschend unter H_0
- mehr Evidenz gegen H_0

Kleiner s-Wert:

- Daten weniger überraschend
- weniger Evidenz gegen H_0

22.5.3 21.4.3 Beispiele

$$p = 0.05$$

$$s \approx 4.32$$

Interpretation:

Die Daten enthalten ungefähr dieselbe Überraschungsinformation wie:

- etwa 4-mal hintereinander Kopf beim Münzwurf

22.5.4 21.4.4 Warum ist das sinnvoll?

Der klassische p-Wert:

- wird oft fehlinterpretiert
- erzeugt dichotomes Denken
- suggeriert klare Grenzen

Die Shannon-Information betrachtet Evidenz dagegen kontinuierlich.

Dadurch:

- weniger Fokus auf starre Schwellenwerte
- bessere Interpretation der Stärke der Evidenz

22.5.5 21.4.5 Wichtig

Die Shannon-Information liefert:

- Evidenz gegen H_0

aber NICHT:

- Wahrscheinlichkeit für H_0
- Wahrscheinlichkeit für H_1

22.5.6 R-Code: Shannon-Information berechnen

```
# Funktion für s-Wert
s_wert <- function(p){
  -log2(p)
}

# Beispiele
s_wert(.05)
```

```
[1] 4.321928
```

```
s_wert(.01)
```

```
[1] 6.643856
```

```
s_wert(.001)
```

```
[1] 9.965784
```

```
# Tabelle verschiedener p-Werte und s-Werte
p_werte <- c(.10, .05, .01, .001)

data.frame(
  p = p_werte,
  s = s_wert(p_werte)
)
```

	p	s
1	0.100	3.321928
2	0.050	4.321928
3	0.010	6.643856
4	0.001	9.965784

22.5.7 21.4.6 Zusammenhang mit NHST-Kritik

Die Shannon-Information ist ein Versuch,

- p-Werte informativer zu interpretieren
- dichotomes Denken zu reduzieren
- Evidenz kontinuierlich statt kategorisch zu betrachten

Sie gehört damit zu den modernen Erweiterungen des klassischen NHST.

Second-Generation-p-values Likelihood-Ansätze

Diese sollen Evidenz differenzierter bewerten als ein bloßer Schwellenwert bei $p = 0.05$.

Die Shannon-Information ist nur einer von mehreren modernen Ansätzen, die versuchen, die Schwächen klassischer p-Werte zu reduzieren.

Weitere Ansätze sind:

- Second-Generation-p-values
- Likelihood-Ansätze
- Bayes-Faktoren

22.6 21.5 Weitere moderne erweiterungen des NHST

22.6.1 21.5.1 Second-Generation-p-values

Second-Generation-p-values (SGPV) sind ein moderner Ansatz, um die Schwächen klassischer p-Werte zu reduzieren.

Die Grundidee:

Nicht nur prüfen,

ob ein Effekt „signifikant“ ist,

sondern:

ob die Daten praktisch relevante Effekte unterstützen.

22.6.1.1 Problem klassischer p-Werte

Ein klassischer p-Wert beantwortet nur:

Wie ungewöhnlich wären die Daten unter H_0 ?

Dabei entstehen Probleme:

- dichotomes Denken
- starke Abhängigkeit von Stichprobengröße
- praktisch irrelevante Effekte können signifikant werden
- keine Aussage über praktische Relevanz

22.6.2 21.5.2 Grundidee der SGPV

Beim Second-Generation-p-value wird geprüft:

Überlappt das Konfidenzintervall mit einem Bereich praktisch irrelevanter Effekte?

Dazu definiert man vorher:

- einen Bereich trivialer Effekte
- die sogenannte *Region of Practical Equivalence* (ROPE)

Beispiel:

Ein Effekt zwischen

$$-0.1 \leq d \leq 0.1$$

könnte als praktisch irrelevant gelten.

22.6.3 21.5.3 Interpretation

22.6.3.1 Fall 1:

Konfidenzintervall vollständig außerhalb der ROPE

→ Evidenz für einen relevanten Effekt

22.6.3.2 Fall 2:

Konfidenzintervall vollständig innerhalb der ROPE

→ Evidenz für praktisch keinen relevanten Effekt

22.6.3.3 Fall 3:

Teilweise Überlappung

→ Ergebnis unklar / weitere Daten nötig

22.6.4 Vorteil

Second-Generation-p-values:

- reduzieren dichotomes Denken
- berücksichtigen praktische Relevanz
- verbinden Effektgrößen mit Unsicherheit
- verhindern Überinterpretation winziger Effekte

22.6.5 Nachteil

Es muss vorher festgelegt werden:

Welche Effektgrößen praktisch relevant sind.

Diese Entscheidung ist teilweise subjektiv.

22.6.6 21.5.4 Likelihood-Ansätze

Likelihood-Ansätze bewerten,

wie gut verschiedene Hypothesen die beobachteten Daten erklären.

Im Mittelpunkt steht die sogenannte Likelihood:

$$L(H \mid \text{Daten})$$

Sie beschreibt:

Wie wahrscheinlich die beobachteten Daten unter einer bestimmten Hypothese sind.

22.6.6.1 Unterschied zum klassischen NHST

Klassischer p-Wert:

$$P(\text{Daten} \mid H_0)$$

Likelihood-Ansätze vergleichen dagegen direkt:

$$\frac{L(H_1)}{L(H_0)}$$

also:

Welche Hypothese erklärt die Daten besser?

22.6.6.2 Likelihood-Ratio

Die zentrale Größe ist häufig die Likelihood-Ratio:

$$LR = \frac{L(H_1)}{L(H_0)}$$

Interpretation:

- große Werte $\rightarrow$ Evidenz für H_1
- kleine Werte $\rightarrow$ Evidenz für H_0

22.6.6.3 Vorteile von Likelihood-Ansätzen

- kontinuierliche Evidenzbewertung
- kein starres Signifikanzniveau
- weniger dichotomes Denken
- direkter Hypothesenvergleich

22.6.6.4 Zusammenhang mit Bayesianischer Statistik

Likelihood-Ansätze bilden die Grundlage vieler bayesianischer Verfahren.

Der Bayes-Faktor basiert ebenfalls auf einem Vergleich von Likelihoods.

22.6.6.5 Einordnung

Second-Generation-p-values und Likelihood-Ansätze gehören zu modernen Versuchen,

- NHST zu verbessern
- Evidenz differenzierter zu bewerten
- praktische Relevanz stärker zu berücksichtigen
- starre Signifikanzgrenzen zu vermeiden

22.7 21.6 Open Science

Wichtige Maßnahmen:

- Präregistrierung
- offene Daten
- offene Analyseskripte
- Replikationsstudien
- transparente Berichterstattung

Ziel:

höhere Reproduzierbarkeit wissenschaftlicher Ergebnisse.

22.7.1 21.6.1 Präregistrierung und Replikation

22.7.1.1 Präregistrierung

Vor der Datenerhebung werden festgelegt:

- Hypothesen
- Analysen
- Ausschlusskriterien

Dadurch werden reduziert:

- p-Hacking
- selektive Berichterstattung
- nachträgliche Hypothesenbildung

22.7.1.2 Replikation

Ein einzelnes signifikantes Ergebnis reicht nicht aus.

Wichtig ist:

Lassen sich Ergebnisse reproduzieren?

Replikationen erhöhen:

- Reliabilität
- wissenschaftliche Glaubwürdigkeit
- Stabilität von Befunden

22.8 21.7 Meta-Analysen

Einzelne Studien liefern oft instabile Ergebnisse.

Meta-Analysen kombinieren Effektgrößen aus vielen Studien, um den tatsächlichen Populationseffekt präziser zu schätzen.

Vorteile:

- höhere Präzision
- größere Stichprobenbasis
- stabilere Effektschätzung
- bessere Reproduzierbarkeit

Meta-Analysen spielen daher eine zentrale Rolle innerhalb moderner statistischer Methodik.

23 22 Alternativen zu NHST (Bayesianische Statistik)

23.1 22.1 Grundidee

Die Bayesianische Statistik ist ein inferenzstatistischer Ansatz zur Schätzung von Wahrscheinlichkeiten von Hypothesen anhand von Daten.

Im Gegensatz zur frequentistischen Statistik interessiert man sich direkt für:

$$P(H \mid D)$$

also:

Wahrscheinlichkeit der Hypothese gegeben die Daten

Der frequentistische Ansatz betrachtet dagegen:

$$P(D \mid H_0)$$

also:

Wahrscheinlichkeit der Daten unter Annahme der Nullhypothese

23.1.1 Unterschiedlicher Wahrscheinlichkeitsbegriff

Frequentistisch: - Wahrscheinlichkeit = relative Häufigkeit bei unendlich vielen Wiederholungen

Bayesianisch: - Wahrscheinlichkeit = subjektiver Grad der Überzeugung / Unsicherheit

23.2 22.2 Bedingte Wahrscheinlichkeit

Grundlage ist die bedingte Wahrscheinlichkeit:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

Interpretation:

- Wahrscheinlichkeit von A , wenn B bereits eingetreten ist

23.3 22.3 Bayes-Theorem

Aus der bedingten Wahrscheinlichkeit ergibt sich:

$$P(H \mid D) = \frac{P(D \mid H) \cdot P(H)}{P(D)}$$

mit:

Term	Bedeutung
$P(H)$	Prior
$P(D \mid H)$	Likelihood
$P(D)$	Evidenz
$P(H \mid D)$	Posterior

Alternativ:

$$P(H | D) = \frac{P(D | H) \cdot P(H)}{P(H)P(D | H) + P(\neg H)P(D | \neg H)}$$

23.4 22.4 Prior-Verteilung

Der Prior beschreibt das Vorwissen über einen Parameter vor der Datenerhebung.

Beispiel:

- erwarteter Mittelwert
- erwartete Effektgröße

Man nimmt also bereits vor den Daten eine Wahrscheinlichkeitsverteilung für den Parameter an.

23.4.1 Noninformative Prior

- kaum Vorwissen
- große Varianz
- alle Werte ähnlich plausibel

Formal oft:

$$P(\theta) = \text{konstant}$$

23.4.2 Informative Prior

- enthält Vorwissen
- bestimmte Werte wahrscheinlicher

Beispiel:

$$\theta \sim \mathcal{N}(100, 10^2)$$

Interpretation:

- Mittelwert vermutlich nahe 100
- Standardabweichung 10

Je kleiner die Varianz:

$$\text{Precision} = \frac{1}{\sigma^2}$$

desto präziser der Prior.

23.4.3 Sensitivitätsanalyse

Vergleich verschiedener Prior-Spezifikationen.

Ziel: - prüfen, wie stark Ergebnisse vom Prior abhängen

23.5 22.5 Likelihood

Die Likelihood beschreibt:

Wie wahrscheinlich sind die beobachteten Daten für bestimmte Parameterwerte?

Formal:

$$L(\theta \mid D) = P(D \mid \theta)$$

Bei Normalverteilung:

$$L(\mu \mid x) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x_i - \mu)^2}{2\sigma^2}\right)$$

Maximum der Likelihood:

→ ML-Schätzer.

23.6 22.6 Posterior-Verteilung

Prior und Likelihood werden kombiniert, der Posterior ist ein Kompromiss aus:

- Vorwissen (Prior)
- beobachteten Daten (Likelihood)

$$P(\theta \mid D) \propto P(D \mid \theta) \cdot P(\theta)$$

Der Posterior ist also proportional zu:

`Likelihood × Prior`

Interpretation:

- aktualisierte Verteilung des Parameters nach Beobachtung der Daten

23.7 22.7 Posterior Mean

Bayesianischer Punktschätzer:

$$E(\theta \mid D)$$

= Erwartungswert der Posteriorverteilung.

23.8 22.8 Credible Interval / Posterior Probability Interval

Bayesianisches Analogon zum Konfidenzintervall.

95%-Credible-Interval:

$$P(a \leq \theta \leq b \mid D) = 0.95$$

Interpretation:

Mit 95% Wahrscheinlichkeit liegt der wahre Parameter zwischen a und b .

Das ist eine echte Wahrscheinlichkeitsaussage.

23.8.1 Posterior Predictive Checking

Bayesianische Modellprüfung durch Vergleich von:

- beobachteten Daten
- simulierten Daten aus dem Modell

Posterior predictive p value (ppp):

- Werte nahe 0.5 $\rightarrow$ guter Modellfit

23.9 22.9 Unterschied zum Konfidenzintervall

Frequentistisch:

$$P(a \leq \theta \leq b) = ?$$

nicht erlaubt, weil:

- Parameter fest
- Intervall zufällig

Korrekte Interpretation:

95% aller so konstruierten Intervalle enthalten den wahren Parameter.

Bayesianisch:

- Parameter zufällig
- Wahrscheinlichkeitsaussage direkt möglich

23.10 22.10 Einfluss des Priors

Posterior hängt ab von:

- Prior
- Datenmenge

23.10.1 Große Stichprobe

Likelihood dominiert:

$$Posterior \approx Likelihood$$

Prior kaum relevant.

23.10.2 Kleine Stichprobe

Prior hat starken Einfluss.

23.10.3 Misspezifizierter Prior

Falscher Prior:

- verzerrt Posterior
- verschiebt Schätzungen

23.11 22.11 MCMC-Verfahren

Posteriorverteilungen oft analytisch nicht lösbar.

Deshalb numerische Approximation:

- Markov Chain Monte Carlo (MCMC)

Idee:

- wiederholtes Sampling aus Posteriorverteilung

Wichtige Verfahren:

- Gibbs Sampling
- Metropolis-Hastings

23.12 22.12 Vorteile

23.12.1 Vorwissen integrierbar

$$P(H)$$

kann frühere Forschung enthalten.

23.12.2 Updating Knowledge

Bayesianische Statistik erlaubt:

- neue Daten mit bestehendem Wissen zu kombinieren
- Wissen schrittweise zu aktualisieren

→ Wissenschaft wird kumulativ

23.12.3 Direkte Wahrscheinlichkeitsaussagen

$$P(H \mid D)$$

23.12.4 Kleinere Stichproben möglich

Bayesianische Verfahren können bei kleinen Stichproben Vorteile haben, insbesondere wenn sinnvolle Priors verfügbar sind. Bayesianische Verfahren oft stabiler bei kleinen n .

23.12.5 Flexibel

- komplexe Modelle
- asymmetrische Verteilungen
- hierarchische Modelle

23.13 22.13 Kritik

23.13.1 Subjektivität des Priors

Priorwahl kann Ergebnisse beeinflussen.

23.13.2 Hoher Rechenaufwand

MCMC benötigt viele Iterationen.

23.13.3 Sensitivität

Bei kleinen Stichproben:

- starker Prior-Effekt

23.14 22.14 Vergleich Frequentismus vs. Bayes

Frequentistisch	Bayesianisch
$P(D H_0)$	$P(H D)$
Parameter fest	Parameter zufällig
p-Wert	Posterior
Konfidenzintervall	Credible Interval
keine Priors	Priors möglich
relative Häufigkeit	subjektive Wahrscheinlichkeit

24 23. Gute wissenschaftliche Praxis / Wissenschaftlicher Forschungsprozess

24.1 23.1 Grundprinzip

24.1.1 ATOM-Prinzip

Accept uncertainty. Be thoughtful, open, and modest.

Bedeutung:

- Unsicherheit akzeptieren
- transparent arbeiten
- kritisch bleiben
- Ergebnisse vorsichtig interpretieren

24.2 23.2 Regeln guter wissenschaftlicher Praxis

- lege artis (“nach den Regeln der Kunst”) arbeiten
 - Man arbeitet nach den aktuell anerkannten fachlichen Standards und Methoden.
- ethische Standards einhalten
- Primärdaten sichern
- Ergebnisse dokumentieren
- eigene Ergebnisse kritisch hinterfragen
- ehrlich berichten
- transparent arbeiten
- replizierbar forschen
- Plagiate vermeiden
- wissenschaftliche Transparenz
- Wissenschaft als kumulativen Prozess verstehen

24.3 23.3 Präregistrierung

24.3.1 Grundidee

Vor Datenerhebung festlegen:

- Hypothesen
- Stichprobengröße
- Variablen
- Ausschlusskriterien
- Auswertungsmethoden
- relevante Effekte

24.3.2 Vorteile

Verhindert:

- P-Hacking
- HARKing
- selektives Berichten
- flexible Datenauswertung

24.4 23.4 Idealer Forschungsprozess

1. Forschungsfrage / Hypothesen
2. Grobplanung
3. Feinplanung
4. Präregistrierung
5. Datenerhebung
6. Datenanalyse
7. Publikation
8. Veröffentlichung von Daten & Materialien

24.5 23.5 Konfidenzintervall und Effektgrößen

Statt nur:

- signifikant / nicht signifikant

sollte man berichten:

- Effektgrößen
- Konfidenzintervalle

24.6 23.6 Open Science

24.6.1 Ziele

- Transparenz
- Reproduzierbarkeit
- offene Daten
- offene Materialien

24.6.2 Open Science Framework (OSF)

Plattform für:

- Präregistrierungen
- Datenspeicherung
- Materialbereitstellung

24.7 23.7 Replikationen

24.7.1 Warum wichtig?

Eine einzelne Studie hat geringe Aussagekraft.

Erst viele Replikationen erhöhen Sicherheit.

24.7.2 Arten

- direkte Replikation
- konzeptuelle Replikation
- Registered Replication Reports